

Laboratorio 7. Spark MLlib

1. Datos y preparación

Se usaron las bases de Personas de la ENEIC: 2025 T1 a T4 para desarrollo y 2026 T1 para la prueba final. Cada archivo se leyó por separado con pandas (.xlsx) o pyreadstat (.sav), se convirtió a Spark con un esquema explícito y se unió con unionByName. Todo el análisis y los modelos se hicieron con Spark 3.5.

IV-2025 tiene 302 columnas y los demás 270. El orden cambia desde la posición 7, así que no se puede apilar por posición. El período se tomó del nombre del archivo, no de TRIMESTRE: II-2025 trae 175 registros con TRIMESTRE = 2.

La población es: 15 años o más, ocupados, asalariados (P05C16 de 1 a 4) y salario P05D01 positivo. Los filtros se aplicaron siempre en el mismo orden.


Archivo	Antes	Después	Conservado
2025 T1	51,588	13,419	26.0 %
2025 T2	51,167	13,492	26.4 %
2025 T3	51,583	13,450	26.1 %
2025 T4	49,338	12,664	25.7 %
2026 T1	49,843	13,258	26.6 %
Total 2025	203,676	53,025	26.0 %

- Casi toda la exclusión viene de menores de 15, no ocupados y no asalariados. Los pasos de salario, antigüedad y horas no excluyen registros.
- El salario falta en 74 % de los registros, pero todo es estructural: fuera del universo asalariado falta en 100 % y dentro en 0 %.
- No hay claves repetidas por período. 61,056 personas aparecen en más de un trimestre y se conservan: la ENEIC es un panel con rotación.
- Los resultados no se ponderan con FACTOR. Describen la muestra, no la población del país. FACTOR serviría para estimar totales y promedios poblacionales.

2. Estadística descriptiva


Variable	Media	Mediana	DE	P25	P75	P95	Máy.
Salario (Q)	3,422	3,000	2,902	1,800	4,000	8,000	99,000
Edad	35.2	33	13.5	24	44	61	89
Antigüedad	5.6	2.0	7.8	0.5	7	22	70
Horas	46.3	45	18.6	40	55	80	126

El salario es asimétrico a la derecha (asimetría 6.0). La media supera a la mediana en Q422 porque los salarios altos la jalan hacia arriba. No se eliminaron extremos.



Muestra de 5,000 registros. Media y mediana calculadas sobre el total. Panel derecho en escala logarítmica.


Empresa privada concentra 54 % de los registros, diversificado y primaria suman 62 % y el dominio urbano metropolitano 42 %. La mediana sube con la educación: Q1,500 sin educación, Q3,600 con diversificado y Q10,000 con maestría. Gobierno tiene la mediana más alta (Q5,000) y servicio doméstico la más baja (Q1,000).



Entre trimestres la muestra es estable (12,664 a 13,492 registros). La mediana pasa de Q3,000 a Q3,200.

3. Correlaciones


Se usó VectorAssembler y Correlation.corr() sobre los 53,025 registros de 2025. Ninguna variable numérica tiene una asociación lineal fuerte con el salario: antigüedad 0.18, edad 0.15 y horas 0.08. Edad y antigüedad tienen una relación positiva moderada (0.49).



4. Segmentación con KMeans


Se agruparon edad, antigüedad y horas, estandarizadas con StandardScaler. Agregar el salario bajó la silueta en todos los K, porque sus extremos arrastran los centroides. Por eso el salario solo se usa para describir los grupos.

K = 2 tiene la mayor silueta (0.55), pero solo separa jóvenes de mayores. Elegimos K = 4 por el codo del WSSSE, una silueta de 0.47 y porque ningún grupo queda por debajo del 10 %.



Perfil	%	Edad	Antig.	Horas	Mediana Q
Jóvenes que empiezan	46.0	26	2.4	41	3,000
Jornada extendida	17.5	30	3.4	74	3,000
Adultos con poca antigüedad	23.6	49	4.1	40	3,000
Trayectoria estable	12.9	50	22.3	41	3,800

Los perfiles se separan por edad, antigüedad y jornada, no por salario. Solo el de trayectoria estable gana claramente más, y ahí 31 % trabaja en gobierno.



Muestra de 5,000 registros coloreada por cluster.

5. Regresión lineal

Entrenamiento: 2025 T1 a T3 (40,361 registros). Validación: 2025 T4 (12,664). El pipeline usa StringIndexer y OneHotEncoder para las categóricas, VectorAssembler y LinearRegression con estandarización interna. La referencia predice siempre la media de entrenamiento.

Se probaron ocho configuraciones de regParam (0, 0.01, 0.1, 1) y elasticNetParam (0, 0.5, 1). Todas dieron casi el mismo RMSE; ganó regParam = 0. La regresión bajó el RMSE de Q2,890 a Q2,186 y llegó a $R^2 = 0.43$.

6. Random forest

Mismo pipeline de preparación con RandomForestRegressor y semilla fija. Se probaron 50 y 100 árboles con profundidad 5 y 10. La profundidad pesó más que el número de árboles. Ganó 50 árboles con profundidad 10.

Modelo (validación 2025 T4)	MAE	RMSE	R^2
Referencia (media)	1,673	2,890	0.00
Regresión lineal	1,210	2,186	0.43
Random forest	1,076	1,969	0.53

Random forest ganó porque capta relaciones no lineales e interacciones, por ejemplo que el salario crezca más rápido en los niveles educativos altos. La regresión lineal solo suma efectos fijos. Su RMSE de entrenamiento (Q1,943) es parecido al de validación, así que no hay sobreajuste fuerte.

7. Evaluación final en 2026


Cada modelo se reentrenó con todo 2025 y se evaluó sobre los mismos 13,258 registros de 2026 T1.

Modelo (prueba 2026 T1)	MAE	RMSE	R ²
Referencia (media)	1,718	2,871	0.00
Regresión lineal	1,241	2,164	0.43
Random forest	1,104	1,958	0.53

Las métricas de prueba son casi iguales a las de validación. Random forest sigue siendo el mejor.


8. Análisis de errores

Residuo = real – predicho. Positivo indica subestimación. Las gráficas usan la misma muestra de 5,000 registros para ambos modelos.



- Los residuos se abren en abanico: el error crece con el salario. La regresión lineal forma un grupo aparte cerca de Q11,000 a Q12,000 (maestría y doctorado).
- El MAE crece con la educación porque crece el salario: menos de Q900 hasta básico y más de Q4,600 en maestría. En doctorado los modelos subestiman unos Q6,000, con solo 12 registros.

- Urbano metropolitano tiene el mayor MAE (Q1,446 LR y Q1,321 RF) y rural el menor (Q914 y Q774).



Los errores no son parejos. En el decil más bajo los modelos sobreestiman unos Q900 y en el más alto subestiman más de Q3,200. Las predicciones van de Q1,090 (p5) a Q11,000 (p99), mientras los salarios reales van de Q720 a Q15,000. Con pocas variables, los modelos empujan las predicciones hacia el centro.

9. Conclusiones

- El salario de los asalariados analizados es muy asimétrico. La educación y la categoría ocupacional son lo que más lo separa.
- KMeans encontró cuatro perfiles laborales. El salario casi no cambia entre ellos, salvo en el de trayectoria estable.
- Random forest estima mejor el salario que la regresión lineal (R^2 0.53 contra 0.43) y mantiene su desempeño en 2026.
- Ambos modelos sobreestiman salarios bajos y subestiman altos. Faltan variables como ocupación, rama y tamaño de empresa.
- Los resultados no están ponderados y no son causales. No indican cuánto debería ganar una persona.