

Universidad del Valle de Guatemala

Facultad de Ingeniería Departamento de Ciencias de la Computación CC3084 Data Science,
Semestre II 2026

Laboratorio 1: Series de Tiempo

Análisis de series de tiempo sobre el ingreso de viajeros internacionales a Guatemala.

Integrantes

Nombre	Carné
Esteban Cárcamo	23016
Hugo Daniel Barillas	23556
Ernesto Ascencio	23009

Fecha: 26 de julio de 2026 **Repositorio:** <https://github.com/ecarcamo/CC3084-DATA-SCIENCE/tree/lab1>

Índice

- 1. Datos y limpieza
- 2. Análisis exploratorio de datos
- 3. Análisis preliminar de series
- 4. Análisis de las series de tiempo
- 5. Modelos y predicción
- 6. Análisis comparativo

1. Datos y limpieza

Origen y dimensiones

La base de datos contiene el registro mensual del ingreso de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026: 210 meses consecutivos, sin huecos, y 161,036 registros en formato largo (una fila por combinación de mes, vía de ingreso, frontera, país o agrupación de residencia y tipo de viajero). Los datos se proporcionan únicamente para uso académico y no corresponden a cifras oficiales de INGUAT ni del Instituto Guatemalteco de Migración.

La base combina tres tramos con distinta fuente y metodología: 2009-2020 proviene de respaldos históricos, 2021-2022 de una entrega del Instituto Guatemalteco de Migración, y 2023 en adelante de un sistema depurado de conteos de INGUAT. Esto implica que los niveles no siempre son perfectamente comparables entre tramos, en particular alrededor del quiebre metodológico de 2022 a 2023.

Además, desde 2023 la columna de país deja de reportar país individual (226 posibles hasta 2022) y pasa a reportar por agrupación de mercado (27 grupos). Los mercados principales (El Salvador, Estados Unidos, Honduras, México, entre otros) siguen siendo comparables como serie a lo largo de todo el período; los países más pequeños quedan absorbidos dentro de su agrupación a partir de 2023.

Limpieza aplicada

Sobre la base cruda se detectaron y corrigieron cuatro inconsistencias, sin eliminar ninguna fila y conservando siempre el valor original en una columna paralela con sufijo `_raw`:

- **Región dos:** la categoría de cruceros aparece partida en dos etiquetas según el año (“Cruceristas” de 2009 a 2021, “Cruceros” en 2022), cuando en realidad es la misma categoría. Se unificó en un solo valor. Adicionalmente existía el valor literal “0” en 13 registros de 2022 (821 viajeros), que se reetiquetó como “Sin especificar”.
- **País:** se detectaron 13 pares de valores que representan el mismo país pero con capitalización distinta (por ejemplo, “OTROS PAISES DEL MUNDO” frente a “Otros Paises Del Mundo”, o variantes con conectores en mayúscula como “República De Corea”). En todos los casos la variante mal escrita corresponde a un puñado de registros aislados de 2020-2021, mientras que la forma correcta se usa de manera consistente en el resto del período. Se unificaron ambas hacia la variante con más registros.
- **Regiones OMT:** existían los valores basura “0x2a” y “SIN ESPECIFICAR”, que se unificaron en la etiqueta “Sin especificar”.
- **Frontera:** la categoría “Cruceros” aparece mezclada en la misma columna junto con fronteras terrestres, aéreas y marítimas legítimas (y junto con la categoría genérica “Otra frontera”). Se decidió no modificarla, ya que corregirla requeriría inventar una frontera específica que no está en los datos; queda documentado aquí para quien la use más adelante.
- **Viajero:** 51,272 registros (cerca de un tercio de la base) tienen valores decimales. No son errores: corresponden a estimaciones y prorrateos de la fuente, no a conteos exactos de personas. Además, 54 registros valen exactamente 0. En ningún caso se redondeó ni se descartó esta información; se documenta como una característica conocida de los datos.

Tras aplicar la limpieza se confirmó por código que la base no contiene valores nulos ni filas duplicadas exactas.

Decisiones fijadas

Guatemala como país de residencia. El valor “Guatemala” en la columna de país acumula aproximadamente 14.8 millones de viajeros a lo largo de todo el período, un 28% del total. Estos registros corresponden a residentes guatemaltecos que regresan al país, no a viajeros internacionales entrantes en el sentido habitual. Se decidió **mantenerlos dentro de la serie total** de viajeros, para no alterar el total oficial reportado por la fuente, pero **excluirlos del ranking de países de residencia**. Bajo este criterio, el Top 3 de países de residencia queda: El Salvador, Estados Unidos de América y Honduras.

2026 como año parcial. El último año de la base solo cubre de enero a junio. Cualquier comparación de totales anuales que incluya 2026 debe advertir explícitamente que ese año está incompleto; no es comparable en la misma base que los años completos.

Quiebre en “Tipo de Viajero”. Esta variable toma cuatro valores: Turista, Excursionista, Viajero y Cruceristas. Entre 2022 y 2023 la categoría “Viajero” cae fuertemente (de aproximadamente 1.06 millones a 0.33 millones) porque el sistema depurado de 2023 excluye a los viajeros no turísticos de alta frecuencia (comercio fronterizo, tránsito), mientras que el tramo anterior sí los incluía. Esta caída es un efecto de cambio de criterio metodológico, no una caída real de actividad, y debe tenerse en cuenta al interpretar la serie total o cualquier serie que dependa de esta variable. Para comparaciones de visitantes consistentes en todo el período se recomienda usar la suma de Turista + Excursionista.

Split de entrenamiento y prueba

El split es temporal, nunca aleatorio, sobre los 210 meses de la base:

- **Entrenamiento:** 2009-01 a 2021-03 (147 meses, 70% de los datos).
- **Prueba:** 2021-04 a 2026-06 (63 meses, 30% de los datos).

Este corte no es arbitrario: deja la caída provocada por la pandemia (colapso a partir de marzo de 2020, con un piso en 2020-2021 de aproximadamente 27% del nivel de 2019) **dentro** del conjunto de entrenamiento, mientras que la **recuperación completa** posterior a 2022 queda **dentro** del conjunto de prueba. Esto significa que cualquier modelo entrenado con este split aprende a partir de un choque y su punto más bajo, pero es evaluado prediciendo una dinámica de recuperación distinta a la que vio durante el entrenamiento. Es un punto que debe justificarse explícitamente al interpretar el desempeño de los modelos, no una limitación que deba ocultarse.

Series construidas

Las categorías de análisis elegidas por el equipo son **vías de ingreso** y **países de residencia (Top 3, excluyendo Guatemala)**. Todas las series son mensuales, con exactamente dos columnas (**fecha** y **viajeros**) e índice completo sin huecos (los meses sin registros quedan en 0). Cada serie tiene además una versión de entrenamiento truncada a 2021-03.

Serie	Inicio	Fin	Frecuencia
Total de viajeros	2009-01	2026-06	Mensual
Vía aérea	2009-01	2026-06	Mensual
Vía terrestre	2009-01	2026-06	Mensual
Vía marítima	2009-01	2026-06	Mensual
País: El Salvador	2009-01	2026-06	Mensual
País: Estados Unidos de América	2009-01	2026-06	Mensual
País: Honduras	2009-01	2026-06	Mensual

Se verificó por código que la suma de las series de las tres vías de ingreso reproduce, mes a mes, la serie total de viajeros.

2. Análisis exploratorio de datos

El análisis se realizó sobre la base ya limpia (`data/processed/base_limpia.csv`), producida por el bloque de carga y limpieza. El notebook reproducible es `notebooks/02_eda.ipynb` y todas las figuras referidas se guardan en `informe/figuras/` a 150 dpi. Se usó únicamente `matplotlib`, según la convención del equipo.

Panorama general y estadísticas descriptivas

La base agrega **52,287,937 viajeros** repartidos en **161,036 registros** y **210 meses** consecutivos (enero 2009 a junio 2026). A nivel de fila, la variable de conteo **Viajero** está fuertemente sesgada a la derecha: la mediana es de apenas **7 viajeros** por combinación mes/vía/frontera/país, mientras que la media es de **~325** y el máximo llega a **92,336**. Es decir, conviven muchísimas combinaciones pequeñas (países lejanos en meses concretos) con unas pocas combinaciones enormes (El Salvador por vía terrestre). Esta asimetría obliga a analizar la serie **agregada por mes** en lugar de las filas individuales.

a. Comportamiento temporal

La serie mensual total (figura `eda_serie_temporal.png`) promedia **~249,000 viajeros por mes** y muestra una estacionalidad regular muy marcada. Se distinguen tres regímenes: crecimiento sostenido de 2009 a 2019; el **colapso por la pandemia** desde marzo de 2020, con el mínimo histórico en **abril 2020 (9,779 viajeros)**, alrededor del 4% de un mes normal; y la recuperación posterior a 2022, que retoma el nivel prepandemia. El corte train/test (2021-03) deja la caída en entrenamiento y la recuperación en prueba.




Figure 1: Serie mensual total de viajeros

Los totales anuales (figura `eda_totales_anuales.png`) confirman el crecimiento estructural: de **2.03M** en 2009 a **4.69M** en 2019 (máximo histórico). En 2020 y 2021 el volumen se desploma a **~1.27M** anuales; en 2022 hay un rebote fuerte y desde 2023 el nivel se estabiliza entre 3.2M y 3.6M, algo por debajo del pico de 2019 (en parte por el cambio metodológico de 2023). **2026 es parcial** (solo enero-junio) y no es comparable con los años completos.




Figure 2: Totales anuales de viajeros

El patrón estacional (figura `eda_estacionalidad.png`) es claro y estable: **diciembre y enero** son los meses más altos (fin de año y vacaciones), con un repunte secundario en **Semana Santa (marzo-abril)** y el valle anual en **septiembre**. Esta estacionalidad anual es la señal más relevante para el modelado posterior.




Figure 3: Patrón estacional mensual

b. Países con mayor cantidad de viajeros

Siguiendo la decisión del bloque de limpieza, **Guatemala se excluye del ranking** (residentes retornando, **14.79M**, ~28.3% del total). El ranking de países de residencia (figura `eda_top_paises.png`) está dominado por los vecinos centroamericanos y Norteamérica:

Puesto	País	Viajeros acumulados
1	El Salvador	16.21M
2	Estados Unidos de América	7.05M
3	Honduras	2.79M
4	México	1.81M

Puesto	País	Viajeros acumulados
5	Belice	1.33M




Figure 4: Top países de residencia

El peso de El Salvador y Honduras refleja el intenso tráfico terrestre fronterizo, mientras que Estados Unidos representa el principal mercado aéreo. Los tres primeros son precisamente las series por país que construye el bloque 1.

c. Regiones con mayor cantidad de viajeros

La distribución regional (figura `eda_regiones.png`, sobre **Región dos**) es muy concentrada: **América del Centro** aporta **37.4M** (~71%), seguida de lejos por **América del Norte** (**9.38M**, ~18%). Europa (~2.2M), América del Sur y el Caribe (~1.4M) y Cruceristas (~1.1M) completan el grueso; Asia, Oceanía y Oriente Medio son marginales. En síntesis, el ingreso a Guatemala es **fundamentalmente regional**: casi 9 de cada 10 viajeros provienen del continente americano.




Figure 5: Distribución regional de viajeros

d. Vías de ingreso y fronteras más utilizadas

La vía **terrestre** domina con **31.99M (~61%)**, seguida de la **aérea (19.06M, ~36%)** y muy detrás la **marítima (1.23M, ~2%)** (figura eda_vias_fronteras.png). Consistente con esto, la frontera más usada es el aeropuerto **La Aurora (19.03M)** (que concentra casi toda la vía aérea), seguido de los pasos terrestres con El Salvador y México: **Valle Nuevo (10.73M)**, **San Cristóbal (5.36M)** y **Pedro de Alvarado (4.39M)**. El predominio terrestre explica por qué El Salvador y Honduras encabezan el ranking de países. La categoría “Cruceros” aparece mezclada como si fuera una frontera, tal como se documentó en el bloque de limpieza.




Figure 6: Vías de ingreso y fronteras más utilizadas

e. Valores faltantes, duplicados y atípicos

Tras la limpieza, la base **no tiene valores nulos ni filas duplicadas exactas**. Persisten dos características conocidas y legítimas: **51,272 registros con valores decimales** (estimaciones/prorratesos de la fuente, no errores) y **54 registros en exactamente 0** (combinaciones sin ingresos ese mes). Ninguna se corrige.

Para los valores atípicos se aplicó el criterio de rango intercuartílico (IQR) sobre la serie mensual (figura `eda_atipicos.png`). El criterio marca solo **2 atípicos, ambos altos: diciembre 2019 (515,820) y diciembre 2022 (526,190)**, que **no son errores** sino los picos estacionales de fin de año. Es notable que el **desplome pandémico (mínimo de 9,779 en abril 2020) no se marca como atípico por IQR** (el límite inferior resulta negativo): es un evento estructural, no un valor a depurar. A nivel de fila, la distribución es de cola larga (visible en escala logarítmica): unas pocas combinaciones grandes concentran el volumen. **Conclusión: no se elimina ningún atípico**; todos son datos reales relevantes para el modelado.




Figure 7: Detección de valores atípicos en la serie mensual

f. Síntesis

- **Temporal:** estacionalidad fuerte (picos diciembre-enero y Semana Santa, valle en septiembre), crecimiento 2009-2019, colapso pandémico 2020-2021 y recuperación 2022+.
- **Países:** El Salvador, Estados Unidos y Honduras concentran el ingreso (Guatemala se excluye por ser retorno de residentes).
- **Regiones:** América del Centro (~71%) y del Norte (~18%) dominan; el ingreso es esencialmente regional.
- **Vías y fronteras:** terrestre (~61%) sobre aérea (~36%); La Aurora, Valle Nuevo y San Cristóbal son las fronteras clave.
- **Calidad:** sin nulos ni duplicados; decimales y ceros son legítimos; los únicos atípicos estadísticos son picos de diciembre, no errores.
- **Tipos de viajero:** Turista (~72%) y Excursionista (~17%) son consistentes en todo el período; la categoría “Viajero” sufre el quiebre metodológico de 2023 documentado en el bloque de limpieza.

3. Análisis preliminar de series

Este bloque analiza dos series mensuales de viajeros sobre el **conjunto de entrenamiento** (enero 2009 a marzo 2021, 147 observaciones): la **Total mensual** (obligatoria) y la de **Vía Aérea**, elegida por contraste, ya que colapsó a casi cero en 2020 mientras la vía terrestre mantuvo flujo. El notebook reproducible es `notebooks/03_series_preliminar.ipynb` y las figuras se guardan en `informe/figuras/` con prefijo `serie_` a 150 dpi, usando solo `matplotlib` y `statsmodels`. El objetivo es **diagnosticar** cada serie (tendencia, estacionalidad, estacionariedad y órdenes de diferenciación), **no** ajustar modelos: eso corresponde a la entrega final.

Serie 1: Total mensual

Ficha. Inicio enero 2009, fin marzo 2021, frecuencia mensual (12 observaciones por año), **147 observaciones**. Media **~237,000** viajeros/mes; mínimo **9,779 (mayo 2020)** por el colapso pandémico y máximo **515,820 (diciembre 2019)** en el pico prepandemia.

Lectura del gráfico. La serie en niveles (figura `serie_total_nivel.png`) muestra un **nivel creciente** (de ~169,000 en 2009 a ~391,000 en 2019), una **estacionalidad anual marcada** y el **quiebre abrupto de 2020**. La amplitud de las oscilaciones **crece con el nivel**: la desviación estándar pasa de ~32,000 en 2009-2013 a ~74,000 en 2014-2019. Esa amplitud creciente justifica una descomposición **multiplicativa** y una transformación que estabilice la varianza.




Figure 8: Serie total en niveles

Descomposición. La descomposición multiplicativa (figura `serie_total_descomposicion.png`) separa tendencia, estacionalidad y residuo. La **tendencia** crece de forma sostenida hasta 2019 y se desploma en 2020. La **estacionalidad** es estable, con **pico en diciembre** (factor ~1.35) y **valle en septiembre** (~0.80), más un repunte secundario en Semana Santa (marzo). Para el INGUAT esto implica dimensionar capacidad hotelera y fronteriza para el fin de año y aprovechar el valle de septiembre para mantenimiento y promoción. El **residuo no se comporta como ruido**: 2020 deja una estructura enorme sin explicar y distorsiona los factores multiplicativos de ese año, por lo que la lectura estacional se toma del tramo estable 2009-2019. En consecuencia, la serie **no es estacionaria en media ni en varianza**.




Figure 9: Descomposición de la serie total

Transformación. Se aplica $\log_{1p}$ (hay meses de valores muy bajos, por eso $\log_{1p}$ y no $\log$) y se compara con la original (figura `serie_total_log.png`). La transformación **estabiliza la varianza** y vuelve aproximadamente aditiva la estacionalidad, condición útil para el modelado.




Figure 10: Serie total con transformación $\log_{1p}$

Estacionariedad en media. La ACF en niveles (figura `serie_total_acf_niveles.png`) decae lenta-

mente y se mantiene alta en muchos rezagos, evidencia clásica de no estacionariedad; la PACF muestra un primer rezago dominante. La prueba de Dickey-Fuller aumentada confirma el diagnóstico:




Figure 11: ACF de la serie total en niveles

Serie	Estadístico ADF	p-valor	V. críticos (1% / 5% / 10%)	Conclusión
Log niveles	-2.236	0.194	-3.480 / -2.883 / -2.578	No se rechaza H0: no estacionaria
Log con d=1	-3.100	0.027	-3.480 / -2.883 / -2.578	Se rechaza al 5%: estacionaria
Log con d=1 y D=1 (s=12)	-6.148	<0.001	-3.485 / -2.886 / -2.580	Fuertemente estacionaria

La hipótesis nula del ADF es la existencia de una **raíz unitaria**; con $p=0.194$ en niveles no se rechaza, así que la serie no es estacionaria en media. Una **diferencia regular ($d=1$)** ya la vuelve estacionaria al 5%, y añadir una **diferencia estacional ($D=1$, $s=12$)** la limpia por completo (figura `serie_total_acf_diff.png`). **Conclusión: $d=1$, $D=1$.** La ACF de la serie diferenciada sugiere componentes de media móvil de orden bajo ($q \sim 1$) y estacional ($Q \sim 1$), y la PACF, componentes autorregresivos de orden bajo ($p \sim 1$, $P \sim 1$). Hasta aquí llega el diagnóstico: no se ajusta ningún modelo.




Figure 12: ACF de la serie total diferenciada

Serie 2: Vía Aérea

Ficha. Inicio enero 2009, fin marzo 2021, frecuencia mensual, **147 observaciones**. Media **~89,000** viajeros/mes; mínimo **489 (abril 2020)** (el aeropuerto La Aurora prácticamente cerró) y máximo **157,842 (diciembre 2019)**.

Lectura del gráfico. La serie en niveles (figura `serie_aerea_nivel.png`) tiene una tendencia creciente **más suave** que la total (de ~78,000 en 2009 a ~124,000 en 2019) y una caída aún más profunda en 2020. La amplitud también crece con el nivel (std ~12,000 en 2009-2013 a ~18,000 en 2014-2019), de nuevo a favor de descomposición multiplicativa y transformación.




Figure 13: Serie vía aérea en niveles

Descomposición. La descomposición multiplicativa (figura `serie_aerea_descomposicion.png`) muestra tendencia creciente hasta 2019 y estacionalidad con **pico en diciembre** (~1.28) y **valle en septiembre** (~0.81), con un repunte adicional en julio, coherente con las vacaciones del hemisferio norte y el peso del mercado estadounidense en la vía aérea. El residuo tampoco es ruido: 2020 domina la varianza. Ni la media ni la varianza son constantes.




Figure 14: Descomposición de la serie vía aérea

Transformación. $\log_{1p}$ es imprescindible aquí porque el valor de abril 2020 (489) está muy cerca de cero (figura `serie_aerea_log.png`); estabiliza la varianza.




Figure 15: Serie vía aérea con transformación $\log_{1p}$

Estacionariedad en media. Caso matizado. La ADF en niveles da un resultado que formalmente rechazaría la raíz unitaria, pero la ACF (figura `serie_aerea_acf_niveles.png`) decae lentamente y la tendencia y la

estacionalidad son evidentes: el ADF está siendo **engañado por la fuerte reversión pandémica** (la caída y el rebote imitan una media estable).

Serie	Estadístico ADF	p-valor	V. críticos (1% / 5% / 10%)	Conclusión
Log niveles	-4.018	0.001	-3.477 / -2.882 / -2.578	Rechazo formal, pero ACF y tendencia contradicen
Log con d=1	-3.213	0.019	-3.480 / -2.883 / -2.578	Estacionaria al 5%
Log con d=1 y D=1 (s=12)	-6.396	<0.001	-3.485 / -2.886 / -2.580	Fuertemente estacionaria




Figure 16: ACF de la serie vía aérea en niveles

El diagnóstico robusto (ACF de decaimiento lento y estacionalidad clara) indica diferenciar igualmente: con **d=1** y **D=1** (s=12) la ACF/PACF quedan limpias (figura `serie_aerea_acf_diff.png`). **Conclusión práctica:** **d=1**, **D=1**, con órdenes sugeridos $p \sim 1$, $q \sim 1$ y estacionales $P \sim 1$, $Q \sim 1$. No se ajusta ningún modelo. Este caso ilustra por qué la ADF no debe leerse aislada de la ACF.




Figure 17: ACF de la serie vía aérea diferenciada

Comportamiento durante y después de la pandemia

Ambas series colapsan en marzo-abril de 2020, pero **no en la misma magnitud** (figura `serie_pandemia_comparacion.png`, índice base media 2019 = 100):

Serie	Media 2019	Mínimo pandémico	Caída
Total	~390,985	9,779 (mayo 2020)	~ 97.5%
Vía Aérea	~123,615	489 (abril 2020)	~ 99.6%




Figure 18: Comparación del impacto pandémico, base 2019=100

La aérea cae casi por completo porque el aeropuerto cerró, mientras que el total conserva un **piso mayor** gracias a la vía terrestre, que nunca se detuvo del todo por el tráfico fronterizo esencial. En el índice base 2019=100 la aérea toca prácticamente cero mientras el total mantiene un pequeño colchón. La recuperación posterior queda **fuera del entrenamiento** (el corte es marzo 2021), pero el distinto fondo de caída anticipa dinámicas de recuperación diferentes: la aérea, más golpeada, parte de más abajo. Para el modelado esto confirma que **cada serie necesita su propio diagnóstico**; total y aérea no comparten el mismo comportamiento pandémico.

Síntesis

- **Total mensual:** tendencia creciente 2009-2019, estacionalidad con pico en diciembre y valle en septiembre, varianza creciente (requiere $\log 1p$), no estacionaria en niveles (ADF $p=0.194$); $d=1$, $D=1$, órdenes sugeridos $p \sim 1$, $q \sim 1$, $P \sim 1$, $Q \sim 1$.
- **Vía Aérea:** misma forma general con caída pandémica más profunda; la ADF en niveles rechaza de forma engañosa, pero la ACF exige diferenciar igual; $d=1$, $D=1$, órdenes sugeridos $p \sim 1$, $q \sim 1$, $P \sim 1$, $Q \sim 1$.
- **Pandemia:** caída de ~97.5% (total) frente a ~99.6% (aérea); la vía terrestre explica el piso mayor del total. Cada serie requiere diagnóstico y modelado propios.
- **Alcance:** el bloque se detiene en el diagnóstico; el ajuste de modelos y la evaluación de pronósticos corresponden a la entrega final.

4. Análisis de las series de tiempo

Criterio común

Las siete series se estudiaron sobre el conjunto de entrenamiento, desde enero de 2009 hasta marzo de 2021, con frecuencia mensual y 147 observaciones. Este corte evita usar información del test durante el diagnóstico.

Se aplicó $\log 1p$ de manera uniforme. La amplitud de las oscilaciones crece con el nivel en varias series y cuatro de ellas contienen ceros. Por esa razón, una descomposición multiplicativa en niveles no es válida. La descomposición aditiva sobre $\log 1p$ representa cambios proporcionales y tolera los ceros, lo que permite comparar todas las series bajo el mismo criterio.

Los factores estacionales se estimaron con el tramo prepandemia. Un factor mayor que uno identifica un mes por encima del nivel medio, mientras uno menor que uno indica un valle. La estacionariedad en media se contrastó con ADF al 5 % en niveles transformados, con una diferencia regular y con una diferencia regular más otra estacional de orden 12.

Total de viajeros

La serie total tiene media mensual de 237,121 viajeros. Su mínimo es 9,779 en mayo de 2020 y el máximo, 515,820 en diciembre de 2019. El gráfico muestra crecimiento hasta 2019, estacionalidad anual y una ruptura abrupta durante el cierre de fronteras.

Diciembre es el pico estacional, con factor 1.372, y septiembre el valle, con 0.802. Esta concentración implica mayor demanda de personal, control y servicios turísticos al cierre del año. La desviación estándar aumenta de 31,782 en 2009-2013 a 74,036 en 2014-2019, evidencia de varianza asociada al nivel que justifica $\log 1p$.

El ADF en niveles produce $p=0.1936$, por lo que no se rechaza raíz unitaria. Con $d=1$ el p -valor baja a 0.0265 y con $d=1$, $D=1$ a menos de 0.0001. La ACF en niveles presenta persistencia y señal anual; luego de diferenciar se acorta. Se concluye $d=1$ y $D=1$.

Vía aérea

La media de la vía aérea es 89,141 viajeros por mes. Se observa un mínimo de 489 en abril de 2020 y un máximo de 157,842 en diciembre de 2019. Antes del cierre existe una tendencia creciente con oscilación anual clara.

El máximo estacional ocurre en diciembre, con factor 1.288, y el mínimo en septiembre, con 0.815. Para INGUAT, esto sugiere concentrar capacidad aeroportuaria y atención turística en el cierre del año. La desviación estándar pasa de 11,554 a 18,464 entre los dos tramos prepandemia, por lo que la transformación reduce una variación que aumenta con el nivel.

Aunque el ADF en niveles rechaza raíz unitaria con $p=0.0013$, la ACF conserva persistencia y estacionalidad. Los resultados con $d=1$, $p=0.0192$, y $d=1$, $D=1$, p menor que 0.0001, respaldan una especificación comparable que absorbe la señal anual. Se emplean $d=1$ y $D=1$, con vigilancia de sobrediferenciación.

Vía terrestre

La vía terrestre concentra una media mensual de 139,988 viajeros. Su mínimo es 5,715 en diciembre de 2020 y alcanza 348,626 en diciembre de 2019. La trayectoria crece con fuerza antes de la pandemia y luego se contrae.

Diciembre tiene el factor máximo, 1.400, y febrero el mínimo, 0.806. El patrón respalda refuerzos fronterizos y de transporte durante las fiestas de fin de año. La desviación estándar crece de 20,032 a 57,068 viajeros, una diferencia marcada que $\log 1p$ ayuda a estabilizar.

La ACF en niveles decae lentamente y muestra dependencia en el rezago 12. El ADF no rechaza raíz unitaria en niveles, $p=0.5619$, pero sí con $d=1$, $p=0.0091$, y con $d=1$, $D=1$, p menor que 0.0001. En consecuencia, se fijan $d=1$ y $D=1$.

Vía marítima

Marítima es la serie más irregular. Su media es 7,991 viajeros, el máximo es 29,506 en enero de 2018 y existen 16 observaciones iguales a cero. Los ceros incluyen meses aislados antes de la pandemia y el cierre prolongado al final del entrenamiento. La desviación estándar cambia de 5,148 a 7,742 viajeros.

El factor prepandemia máximo corresponde a diciembre, 3.328, y el mínimo a junio, 0.153. La amplitud extrema y los cambios de nivel hacen que esos factores sean menos estables que en las otras vías, por lo que no deben usarse como una regla operativa rígida.

El ADF arroja $p=1.0000$ en niveles, $p=0.5750$ con $d=1$ y $p=0.1327$ con $d=1$, $D=1$. Tampoco $d=2$ resuelve el problema, pues obtiene $p=0.6994$. Por tanto, no se afirma estacionariedad al 5 %. Se explora $d=2$ y $D=1$ en modelación, pero la conclusión estadística sigue siendo que persiste una raíz unitaria.

La serie también cambia de régimen fuera del train. El total anual pasa de 130,789 viajeros en 2019 a 41,992 en 2020 y 3,908 en 2021. Tras una recuperación a 26,030 en 2022, se estabiliza en solo 6,617, 6,605 y 6,944 viajeros durante 2023, 2024 y 2025. Este nivel es muy inferior al prepandemia y limita cualquier extrapolación de la historia anterior.

País de residencia: El Salvador

La serie tiene media mensual de 61,502 viajeros, máximo de 165,263 en agosto de 2019 y cinco ceros, correspondientes al cierre de abril a agosto de 2020. El gráfico combina crecimiento previo, patrón anual y ruptura pandémica.

Diciembre es el pico, con factor 1.381, y febrero el valle, con 0.800. El resultado ayuda a anticipar presión en fronteras terrestres al cierre del año. La desviación estándar sube de 9,515 a 28,199 viajeros, de modo que $\log 1p$ estabiliza una heterocedasticidad importante.

El ADF en niveles no rechaza raíz unitaria, $p=0.4325$. Con $d=1$ y con $d=1$, $D=1$ los p-valores son menores que 0.0001. La ACF diferenciada pierde la persistencia de niveles, por lo que se adoptan $d=1$ y $D=1$.

País de residencia: Estados Unidos

La media mensual es 27,955 viajeros. La serie alcanza 54,990 en julio de 2019 y presenta cinco ceros durante abril-agosto de 2020. Antes de ese quiebre mantiene crecimiento y una temporada alta de mitad de año.

Julio registra el factor máximo, 1.449, y septiembre el mínimo, 0.606. Esto señala mayor demanda turística y aeroportuaria durante el verano boreal. La desviación estándar aumenta de 6,840 a 9,226 viajeros; el cambio es menor que en El Salvador, pero aún favorece la escala logarítmica.

El ADF en niveles queda en el límite, con $p=0.0501$. La primera diferencia rechaza raíz unitaria con $p=0.0307$ y la combinación $d=1$, $D=1$ lo hace con p menor que 0.0001. Junto con la señal anual de la ACF, esto lleva a $d=1$ y $D=1$.

País de residencia: Honduras

Honduras promedia 9,124 viajeros mensuales y alcanza 23,061 en enero de 2020. También contiene cinco ceros por el cierre de abril-agosto de 2020. La tendencia prepandemia es ascendente, con una estacionalidad menos extrema que la de Estados Unidos.

Enero es el pico, con factor 1.216, y febrero el valle, con 0.824. El patrón aconseja reforzar atención terrestre al inicio del año. La desviación estándar pasa de 1,366 a 3,717 viajeros, por lo que $\log 1p$ mejora la estabilidad de la varianza.

El ADF ya rechaza raíz unitaria en niveles con $p=0.0040$. Aun así, la ACF muestra persistencia y señal estacional. Con $d=1$ y con $d=1$, $D=1$ los p-valores son menores que 0.0001. Se usan $d=1$ y $D=1$ para capturar esa estructura y mantener comparabilidad, revisando posible sobrediferenciación.

Comparación de estacionariedad

Serie	Media	Ceros	ADF nivel	ADF d=1	ADF d=1, D=1	d	D
Total	237,121	0	0.1936	0.0265	<0.0001	1	1
Vía aérea	89,141	0	0.0013	0.0192	<0.0001	1	1
Vía terrestre	139,988	0	0.5619	0.0091	<0.0001	1	1
Vía marítima	7,991	16	1.0000	0.5750	0.1327	2	1
El Salvador	61,502	5	0.4325	<0.0001	<0.0001	1	1
Estados Unidos	27,955	5	0.0501	0.0307	<0.0001	1	1
Honduras	9,124	5	0.0040	<0.0001	<0.0001	1	1

La conclusión común es que la diferenciación regular y estacional resulta adecuada para seis series. Marítima queda como excepción: sus ceros, quiebres y cambio de régimen impiden sostener estacionariedad incluso después de aplicar diferencias adicionales.

5. Modelos y predicción

Selección de órdenes

La identificación parte de las ACF y PACF sobre `log1p`. En las series con persistencia, p y q se exploraron entre 0 y 2. Los picos en el rezago 12 motivaron P y Q entre 0 y 1, con periodo estacional 12. Las conclusiones del ADF fijaron $d=1$ y $D=1$ en seis series. Para marítima se probó $d=2$ y $D=1$, sin interpretar esta decisión como evidencia de estacionariedad.

Serie	Modelo seleccionado por AIC	Fundamento de p y q
Total	SARIMA(2,1,2)(1,1,1)12	PACF corta y ACF persistente con señal anual
Vía aérea	SARIMA(2,1,2)(0,1,1)12	Dependencia corta regular y pico estacional
Vía terrestre	SARIMA(0,1,1)(1,1,0)12	Corte dominante de ACF y componente anual
Vía marítima	SARIMA(1,2,2)(1,1,1)12	ACF irregular, diferencias adicionales y ciclo anual
El Salvador	SARIMA(2,1,2)(1,1,1)12	Dependencia regular mixta y estacionalidad marcada
Estados Unidos	SARIMA(1,1,2)(0,1,1)12	ACF persistente y PACF concentrada en pocos rezagos
Honduras	SARIMA(2,1,2)(1,1,0)12	Dependencia corta con efecto estacional de media móvil

La rejilla manual evaluó todas las combinaciones de esos rangos y conservó los tres menores AIC estables por serie. `auto_arima` se ejecutó con la misma diferenciación y límites. Sus propuestas fueron de orden bajo y coherentes con las ACF y PACF, aunque no siempre coincidieron con el mínimo manual porque su búsqueda es escalonada.

Comparación ARIMA

Serie	order	seasonal order	AIC	BIC	Ljung-Box p
Total	(2,1,2)	(1,1,1,12)	67.96	87.41	0.0003
Total	(1,1,2)	(1,1,1,12)	68.55	85.22	0.0046
Total	(2,1,2)	(1,1,0,12)	68.96	85.69	0.0012
Vía aérea	(2,1,2)	(0,1,1,12)	169.72	186.40	<0.0001
Vía aérea	(0,1,1)	(0,1,1,12)	176.29	184.65	0.0060
Vía aérea	(0,1,2)	(0,1,1,12)	176.98	188.10	0.0059
Vía terrestre	(0,1,1)	(1,1,0,12)	124.18	132.59	0.5395
Vía terrestre	(1,1,0)	(1,1,0,12)	124.32	132.70	0.8681
Vía terrestre	(2,1,2)	(0,1,1,12)	124.94	141.62	<0.0001
Vía marítima	(1,2,2)	(1,1,1,12)	498.40	515.02	0.0199
Vía marítima	(2,2,2)	(1,1,1,12)	500.35	519.74	0.0202
Vía marítima	(1,2,2)	(0,1,1,12)	504.06	517.91	0.0052
El Salvador	(2,1,2)	(1,1,1,12)	400.62	420.07	0.1020
El Salvador	(2,1,2)	(0,1,1,12)	411.54	428.21	0.0481
El Salvador	(1,1,2)	(0,1,1,12)	411.80	425.70	0.0770
Estados Unidos	(1,1,2)	(0,1,1,12)	367.14	381.03	0.0427
Estados Unidos	(2,1,1)	(0,1,1,12)	371.51	385.45	0.0373
Estados Unidos	(2,1,2)	(0,1,1,12)	371.96	388.64	0.0154
Honduras	(2,1,2)	(1,1,0,12)	359.01	375.74	0.1854

Serie	order	seasonal order	AIC	BIC	Ljung-Box p
Honduras	(1,1,2)	(0,1,1,12)	360.21	374.10	0.0107
Honduras	(0,1,2)	(0,1,1,12)	370.32	381.44	0.0277

El menor AIC entre especificaciones estables decide el modelo llevado al test, pero los residuos matizan la elección. Vía terrestre, El Salvador y Honduras no rechazan ausencia de autocorrelación al 5 %. Total, vía aérea, marítima y Estados Unidos sí retienen dependencia residual. Jarque-Bera rechaza normalidad en todos los modelos seleccionados. Esto limita la inferencia paramétrica, aunque para pronóstico es más preocupante la autocorrelación restante.




Figure 19: Residuos del SARIMA seleccionado, total




Figure 20: Residuos del SARIMA seleccionado, vía aérea




Figure 21: Residuos del SARIMA seleccionado, vía terrestre




Figure 22: Residuos del SARIMA seleccionado, vía marítima




Figure 23: Residuos del SARIMA seleccionado, El Salvador




Figure 24: Residuos del SARIMA seleccionado, Estados Unidos




Figure 25: Residuos del SARIMA seleccionado, Honduras

Además del AIC, la selección exige que el pronóstico a 63 pasos, revertido a viajeros, no supere tres veces el máximo histórico de la serie. El filtro es necesario porque el ajuste se hizo sin restricciones de estacionariedad ni de invertibilidad, de modo que la rejilla completa pudiera converger. De las 36 especificaciones ajustadas por serie se descartaron 0 en total, 18 en vía aérea, 2 en terrestre, 2 en marítima, 1 en El Salvador, 24 en Estados Unidos y 23 en Honduras. Sin ese criterio, varias especificaciones con buen AIC habrían producido trayectorias explosivas fuera de muestra.

Algoritmos alternativos

Holt-Winters usa tendencia y estacionalidad aditivas sobre $\log_{10}p$. SES modela únicamente el nivel suavizado. Seasonal naive repite los últimos doce meses observados y sirve como referencia simple. Prophet incorpora estacionalidad anual también sobre $\log_{10}p$. Los cuatro algoritmos pudieron ejecutarse, y sus predicciones se revirtieron a viajeros antes de evaluar.

AIC y BIC solo aparecen para SARIMA. No son comparables entre algoritmos distintos, ni entre series, porque dependen de la función de verosimilitud, la muestra y la parametrización.

Resultados fuera de muestra

Serie	Modelo	MAE	RMSE	MAPE
Total	SARIMA	250,723	274,290	83.48 %
Total	Holt-Winters	196,956	216,457	65.30 %
Total	SES	175,088	194,791	58.11 %
Total	Seasonal naive	235,731	253,203	83.86 %
Total	Prophet	264,527	282,313	92.50 %
Vía aérea	SARIMA	73,966	77,680	77.57 %
Vía aérea	Holt-Winters	48,043	52,231	48.51 %
Vía aérea	SES	36,109	41,368	35.62 %
Vía aérea	Seasonal naive	75,104	79,077	80.58 %
Vía aérea	Prophet	89,054	92,266	93.17 %
Vía terrestre	SARIMA	174,971	192,354	88.63 %
Vía terrestre	Holt-Winters	148,023	164,246	73.92 %
Vía terrestre	SES	140,428	156,310	71.75 %
Vía terrestre	Seasonal naive	160,013	176,653	83.47 %
Vía terrestre	Prophet	175,767	191,877	91.07 %
Vía marítima	SARIMA	858	1,732	100.00 %
Vía marítima	Holt-Winters	858	1,732	100.00 %
Vía marítima	SES	858	1,732	100.00 %
Vía marítima	Seasonal naive	858	1,732	100.00 %
Vía marítima	Prophet	784	1,645	86.12 %
El Salvador	SARIMA	113,109	123,010	97.70 %
El Salvador	Holt-Winters	101,044	111,527	81.05 %
El Salvador	SES	94,064	104,531	74.32 %
El Salvador	Seasonal naive	107,474	117,633	91.60 %
El Salvador	Prophet	106,744	117,498	86.64 %
Estados Unidos	SARIMA	42,093	45,541	88.57 %
Estados Unidos	Holt-Winters	34,195	37,642	69.37 %
Estados Unidos	SES	25,115	28,953	49.93 %
Estados Unidos	Seasonal naive	41,168	44,196	88.19 %
Estados Unidos	Prophet	43,686	46,870	91.73 %
Honduras	SARIMA	21,841	24,115	90.17 %
Honduras	Holt-Winters	18,900	21,200	74.17 %
Honduras	SES	17,240	19,587	66.05 %
Honduras	Seasonal naive	21,190	23,244	90.95 %
Honduras	Prophet	21,239	23,497	86.70 %

Los valores de AIC y BIC de cada SARIMA seleccionado ya se listan en la tabla de la subsección anterior; no se repiten aquí porque no son comparables contra los otros cuatro algoritmos. El MAPE marítimo excluye 11 meses del test con valor real igual a cero. En las demás series no fue necesario excluir observaciones.




Figure 26: Predicción sobre el conjunto de prueba, total




Figure 27: Predicción sobre el conjunto de prueba, vía aérea




Figure 28: Predicción sobre el conjunto de prueba, vía terrestre




Figure 29: Predicción sobre el conjunto de prueba, vía marítima




Figure 30: Predicción sobre el conjunto de prueba, El Salvador




Figure 31: Predicción sobre el conjunto de prueba, Estados Unidos




Figure 32: Predicción sobre el conjunto de prueba, Honduras

Modelo seleccionado por serie

Serie	Mejor modelo	MAE	RMSE	Evaluación
Total	SES	175,088	194,791	Error alto, subpredice la recuperación
Vía aérea	SES	36,109	41,368	Mejor resultado relativo, aún insuficiente
Vía terrestre	SES	140,428	156,310	Error alto por cambio de nivel
Vía marítima	Prophet	784	1,645	Menor error absoluto, MAPE todavía alto
El Salvador	SES	94,064	104,531	Baja precisión operativa
Estados Unidos	SES	25,115	28,953	Supera alternativas, pero MAPE cercano a 50 %
Honduras	SES	17,240	19,587	Mejor del grupo, con error relativo alto

SES gana en seis series porque el final del entrenamiento está dominado por la pandemia y un modelo de nivel evita extrapolaciones complejas. Esto no significa que describa bien la recuperación. Los MAPE entre 35.62 % y 74.32 % de esos ganadores muestran que la capacidad predictiva sigue siendo limitada. El SARIMA estable de vía aérea y de Estados Unidos ya no diverge, pero sus MAE de 73,966 y 42,093 viajeros siguen por encima de SES.

Prophet es el mejor en marítima, pero su MAPE es 86.12 %. Los otros métodos producen valores cercanos a cero debido al cierre observado al final del train. Por eso no aparece la sobrepredicción masiva esperable de un modelo que extrapolara el nivel prepandemia. El riesgo estructural permanece: después de 26,030

viajeros en 2022, la serie cae a 6,617 en 2023, 6,605 en 2024 y 6,944 en 2025. Un ajuste que aprendiera el nivel histórico sobrepredeciría ese régimen.

En conjunto, el corte explica los resultados. El entrenamiento termina en marzo de 2021, con el choque pandémico incluido y la recuperación excluida. La mayoría de los modelos subpredice la reapertura, mientras marítima exige tratar por separado sus ceros y su ruptura de 2023. Las predicciones sirven como evaluación honesta de ese diseño, no como pronósticos operativos definitivos.

6. Análisis comparativo

Criterio de comparación

La comparación entre series exige métricas explícitas, porque la inspección visual favorece siempre a las series de mayor volumen. Cada pregunta se responde con un número calculado bajo la misma definición para las siete series en `notebooks/07_comparativo.ipynb`, y los resultados quedan en `resultados/comparativo_series.csv`.

La estacionalidad se mide con la fuerza estacional de la descomposición aditiva de `log1p` del entrenamiento con periodo 12, definida como uno menos la razón entre la varianza del residuo y la varianza del componente estacional más el residuo. Toma valores entre 0 y 1, y un valor alto indica que la señal anual explica buena parte de la variación que no captura la tendencia. Se complementa con la amplitud de los factores estacionales prepandemia ya reportada en la sección 4. La fuerza de tendencia se calcula de forma análoga sobre el componente de tendencia.

La tendencia de crecimiento se estima con la pendiente de una regresión lineal sobre el tramo de enero de 2009 a diciembre de 2019. La pandemia se excluye porque una caída del orden del 97 % domina cualquier ajuste lineal y convierte la pendiente en una medida del choque y no del crecimiento. La pendiente se reporta en viajeros por mes y también como porcentaje de la media del tramo, ya que en términos absolutos las series de mayor volumen ganan por construcción.

La volatilidad usa dos medidas sobre el mismo tramo prepandemia: el coeficiente de variación, que compara la dispersión con el nivel medio, y la desviación estándar de los retornos logarítmicos mensuales, que mide el tamaño típico del salto de un mes al siguiente. Las dos no tienen que coincidir y su discrepancia es informativa.

El impacto pandémico combina profundidad y velocidad. La profundidad es la caída porcentual del mínimo entre enero de 2020 y diciembre de 2021 respecto de la media de 2019. La velocidad es el primer mes, contado desde abril de 2020, en que la serie alcanza el 80 % de esa media. La segunda métrica es la que discrimina cuando varias series caen a cero.

Serie	Fs	Ft	Pendiente		CV	Vol. retornos	Media 2019	Mínimo pandémico	Caída	Recupera 80 %
			Pendiente (viaj/mes)	(% media)						
Total	0.189	0.505	1,893	0.750	0.335	0.201	390,985	9,779	97.5 %	2022-04
Vía aérea	0.142	0.241	407	0.428	0.216	0.171	123,615	489	99.6 %	2021-12
Vía terrestre	0.169	0.653	1,448	0.974	0.431	0.236	256,470	5,715	97.8 %	2022-04
Vía marítima	0.405	0.690	38	0.444	0.790	2.185	10,899	0	100 %	2022-12
El Salvador	0.105	0.185	641	0.978	0.453	0.267	114,256	0	100 %	2022-04
Estados Unidos	0.109	0.107	112	0.374	0.300	0.318	38,729	0	100 %	2021-12
Honduras	0.119	0.116	56	0.579	0.335	0.219	17,402	0	100 %	2022-03

La serie total aparece como referencia. Las comparaciones se hacen dentro de cada categoría, porque la total es una suma de las vías y no compete con ellas.

Categoría vías de ingreso

La vía marítima es la más estacional, y por un margen que no admite duda: su fuerza estacional es 0.405, más del doble que la de la terrestre, 0.169, y casi el triple que la de la aérea, 0.142. La amplitud de sus factores prepandemia lo confirma, 3.273 en logaritmos frente a 0.578 y 0.953. La figura `comp_estacionalidad.png` muestra el origen del contraste: los cruceros operan entre noviembre y abril, con factor de 3.328 en diciembre, y prácticamente desaparecen entre junio y septiembre, con 0.153 en junio. Las otras dos vías oscilan en una banda estrecha alrededor de la unidad, con el mismo pico de diciembre y un valle poco profundo.




Figure 33: Fuerza estacional por vía de ingreso

En crecimiento gana la vía terrestre. Su pendiente prepandemia es de 1,448 viajeros por mes, equivalente a 0.974 % de su media mensual, y su fuerza de tendencia, 0.653, es la más alta de la categoría. Es el único caso en que la medida absoluta y la normalizada coinciden en el ganador, lo que refuerza la conclusión. La marítima ilustra el riesgo de mirar solo la absoluta: sus 38 viajeros por mes parecen despreciables frente a los 407 de la aérea, pero normalizados son 0.444 % contra 0.428 %, es decir, un ritmo relativo muy similar. La figura `comp_tendencia.png` contrasta las dos lecturas.




Figure 34: Pendiente de crecimiento absoluta y normalizada por vía de ingreso

La marítima también es la más volátil, y aquí las dos medidas concuerdan en el orden: coeficiente de variación de 0.790 frente a 0.431 de la terrestre y 0.216 de la aérea, y desviación de retornos de 2.185 frente a 0.236

y 0.171. La distancia en retornos es desproporcionada y conviene explicarla en vez de presentarla como un hallazgo. La serie acumula 16 observaciones iguales a cero en el entrenamiento y cuatro de ellas caen dentro del tramo prepandemia que usa esta métrica: agosto de 2017, julio de 2018, junio y agosto de 2019. Un mes en cero seguido de un mes con miles de viajeros produce un retorno logarítmico enorme, de modo que el valor de 2.185 mide en parte la intermitencia del registro y no solo la variabilidad de la demanda. El coeficiente de variación, que no depende de la transición entre meses consecutivos, es la medida más comparable, y también sitúa a la marítima en primer lugar. La figura `comp_volatilidad.png` contrasta las dos medidas.




Figure 35: Volatilidad por vía de ingreso: coeficiente de variación y retornos logarítmicos

La más afectada por la pandemia es de nuevo la marítima. Cae 100 % contra su media de 2019 y es la última en cruzar el umbral del 80 %, en diciembre de 2022, doce meses después de la aérea y ocho después de la terrestre. Ese cruce, sin embargo, no es una recuperación. El umbral es de 8,719 viajeros y diciembre de 2022 registra 10,042, pero ese mes es un pico aislado dentro de un año que incluye cuatro meses en cero. El total anual pasa de 130,789 viajeros en 2019 a 26,030 en 2022 y a 6,617, 6,605 y 6,944 entre 2023 y 2025, un nivel veinte veces inferior al prepandemia. La lectura correcta es un cambio de régimen en el registro de cruceros, y la métrica de velocidad de recuperación deja de ser válida para esta serie. La figura `comp_recuperacion.png` muestra la trayectoria plana de la marítima después de 2023 frente a las demás.




Figure 36: Trayectoria de recuperación pospandemia por vía de ingreso

Categoría países de residencia

En esta categoría conviene empezar por lo que las métricas no permiten afirmar. Las tres fuerzas estacionales son bajas y casi idénticas: Honduras 0.119, Estados Unidos 0.109 y El Salvador 0.105. Honduras es el máximo, pero la diferencia con El Salvador es de 0.014 y no sostiene ninguna decisión operativa. Declarar un ganador sería sobreinterpretar el tercer decimal. Lo que sí distingue a las series es el calendario y no la intensidad: El Salvador tiene su pico en diciembre, con factor 1.381, Honduras en enero, con 1.216, y Estados Unidos en julio, con 1.449, y su valle en septiembre, con 0.606. Los dos vecinos centroamericanos siguen el patrón del flujo terrestre de fin de año, mientras el mercado estadounidense responde al verano boreal.

El Salvador presenta la mayor tendencia de crecimiento, con 0.978 % de su media por mes, por delante de Honduras, 0.579 %, y de Estados Unidos, 0.374 %. En este caso el orden relativo coincide con el absoluto, 641 contra 56 y 112 viajeros por mes, porque El Salvador es además la serie de mayor volumen del grupo. Las fuerzas de tendencia de Estados Unidos y Honduras, 0.107 y 0.116, son las más bajas de las siete series, lo que indica trayectorias en las que la variación estacional y el ruido pesan más que el crecimiento.

La volatilidad es el caso donde las dos medidas discrepan. El Salvador tiene el mayor coeficiente de variación, 0.453 frente a 0.335 de Honduras y 0.300 de Estados Unidos, pero Estados Unidos tiene la mayor desviación de retornos, 0.318 frente a 0.267 y 0.219. La explicación está en lo que cada medida captura. El coeficiente de variación mide la dispersión alrededor de una media de once años, y El Salvador la infla porque su nivel casi se duplica en el tramo, de modo que buena parte de esa dispersión es crecimiento y no inestabilidad. La desviación de retornos mide el salto entre meses consecutivos, y ahí Estados Unidos gana por su estacionalidad más contrastada entre julio y septiembre. Para planificación de capacidad interesa la segunda: el mercado estadounidense es el que exige mayor flexibilidad de un mes al siguiente. Para evaluar riesgo de nivel interesa la primera.

En profundidad de impacto pandémico no hay diferencia posible. Las tres series registran cero viajeros de abril a agosto de 2020 por el cierre de fronteras, así que las tres caen 100 % y la métrica se satura. El desempate es la velocidad de recuperación, y ahí el orden es claro: Estados Unidos alcanza el 80 % del nivel de 2019 en diciembre de 2021, Honduras en marzo de 2022 y El Salvador en abril de 2022. Estados Unidos recupera cuatro meses antes que El Salvador pese a haber caído desde un volumen tres veces menor, lo que sugiere que el mercado aéreo de larga distancia reaccionó a la reapertura más rápido que el tráfico fronterizo terrestre.

Descubrimientos útiles para el INGUAT

1. El volumen depende de la frontera terrestre, pero la estabilidad viene de la aérea. La vía terrestre aporta 58.9 % del total entre 2009 y 2019 y 65.5 % desde abril de 2021, mientras la aérea baja de 37.7 % a 34.2 %. La aérea es la vía menos volátil de las tres, con coeficiente de variación de 0.216 contra 0.431 de la terrestre. La planificación de aforo debe dimensionarse por la terrestre, y la de ingresos por gasto turístico apoyarse en la aérea, que es más predecible.
2. Existe un calendario operativo común que permite una sola política estacional. Diciembre es el mes pico en cinco de las siete series, con factores de 1.288 a 3.328, y el valle cae en septiembre o febrero. Las excepciones son Estados Unidos, con pico en julio, y Honduras, en enero. Septiembre, valle en tres series con factores de 0.802 a 0.606, y febrero, valle en las otras tres con factores cercanos a 0.810, son la ventana natural para mantenimiento de infraestructura, capacitación de personal y campañas de temporada baja.
3. Ante un choque, la recuperación llega antes por vía aérea y desde mercados lejanos. Estados Unidos y la vía aérea recuperan el 80 % del nivel de 2019 en diciembre de 2021, cuatro meses antes que El Salvador y la vía terrestre. Si vuelve a producirse una interrupción, el orden de prioridad de la promoción debería empezar por el mercado aéreo de larga distancia, que responde más rápido.
4. El segmento de cruceros no se recuperó y conviene tratarlo como una decisión de reasignación, no de reactivación. La vía marítima pasa de 130,789 viajeros anuales en 2019 a cerca de 6,600 entre 2023 y 2025, con meses completos en cero incluso en 2022. Cualquier meta que use el nivel prepandemia como referencia para esta vía parte de un supuesto que los datos ya rechazan.
5. La operación portuaria es la única que justifica una planificación estacional dedicada. Con fuerza estacional de 0.405 y factor de 3.328 en diciembre frente a 0.153 en junio, la marítima concentra su actividad en pocos meses, mientras las demás series oscilan en una banda estrecha alrededor de su media. Un esquema de personal uniforme durante el año es razonable en las vías terrestre y aérea, pero no en la marítima.
6. Los modelos ajustados sobre historia que cruza la pandemia no sirven como pronóstico operativo. El mejor modelo por serie resultó ser el suavizamiento exponencial simple en seis de las siete, con MAPE entre 35.62 % y 74.32 %, porque el nivel final del entrenamiento está dominado por el cierre. La lectura de política pública es que la planificación cuantitativa debe reestimarse con datos posteriores a la reapertura, y que los pronósticos basados en la serie completa deben acompañarse de su error, no presentarse como cifras puntuales.

Conclusión general

El análisis confirma que el ingreso de viajeros a Guatemala combina un crecimiento estructural sostenido entre 2009 y 2019, una estacionalidad anual marcada con pico en diciembre y valle en septiembre, y un choque pandémico que interrumpió esa trayectoria de forma abrupta. La vía terrestre concentra la mayoría del flujo, cercana al 61% del total histórico, mientras la vía aérea aporta un tercio con un comportamiento más estable. El Salvador, Estados Unidos y Honduras son los mercados de residencia dominantes, cada uno con un calendario propio: los vecinos centroamericanos siguen el pico de fin de año, mientras Estados Unidos responde al verano boreal.

El diagnóstico de las siete series y su comparación cuantitativa muestran que no todas se comportan igual frente al mismo fenómeno. La vía marítima es la más estacional y la más volátil, y es también la que nunca recuperó su nivel prepandemia: se estabilizó en una fracción menor de su volumen histórico, un cambio de régimen y no una recuperación. La vía terrestre lidera el crecimiento relativo, y dentro de los países El Salvador crece más rápido en términos porcentuales, aunque Estados Unidos se recupera primero después del choque de 2020, señal de que los mercados de mayor distancia reaccionan con más velocidad a la reapertura de fronteras.

En cuanto al modelado, la comparación entre SARIMA, Holt-Winters, suavizamiento exponencial simple, seasonal naive y Prophet deja una lección más metodológica que técnica: cuando el entrenamiento termina en medio de un choque estructural, los modelos favorecen el nivel más simple y estable sobre extrapolaciones ambiciosas, con errores porcentuales que siguen siendo altos en todas las series. Esto no invalida el ejercicio, pero sí limita su uso como pronóstico operativo directo y refuerza la necesidad de reestimar los modelos con datos posteriores a la recuperación.

Para el INGUAT, los hallazgos apuntan a una agenda concreta: dimensionar la capacidad fronteriza y hotelera según el patrón estacional común de diciembre y septiembre, diferenciar la política hacia el segmento marítimo de cruceros del resto de vías dado su colapso permanente, y priorizar la promoción hacia mercados aéreos de recuperación más rápida ante un eventual choque futuro. El valor del ejercicio no está solo en los números individuales, sino en la evidencia de que cada vía y cada mercado exige su propio diagnóstico antes de tomar decisiones de política turística.