

Universidad del Valle de Guatemala — Facultad de Ingeniería

CC3084 — Data Science — Semestre II 2026

Laboratorio 4, Parte 2
Análisis de modelos usando datos geoespaciales

Integrantes

Hugo Barillas — carné 23556

Esteban Cárcamo — carné 23016

Ernesto Ascencio — carné 23009

Inciso 1. Preparación de los datos para Machine Learning

Metodología

El punto de partida son los 22 rasters de la Parte I, uno por cada combinación de lago y fecha oficial (11 fechas para Atitlán, 11 para Amatitlán), cubriendo enero de 2025 a julio de 2026. Para este inciso el evalscript de descarga se amplió respecto a la Parte I: además de las 10 bandas originales, el raster ahora incluye las reflectancias B05, B07, B08, B8A, B11 y B12, y las bandas de nube CLM y CLP de Sentinel Hub. Con este evalscript ampliado se volvieron a descargar los 22 rasters antes de construir el dataset tabular, de modo que cada píxel de agua cuenta con un conjunto más completo de bandas espectrales como posibles predictoras.

La construcción del conjunto de datos se implementó en `src/dataset.py` y se ejecuta desde `notebooks/p2_01_preparacion_datos.ipynb`. Por cada combinación lago-fecha se calcula el centro de cada píxel en WGS84 a partir de la transformación geográfica del raster y se reproyecta a UTM 15N, EPSG:32615, con unidades en metros. Esta reproyección se realiza en este inciso, y no se posterga hasta la validación espacial del inciso 6, porque el sistema métrico es el mismo que exige esa validación y porque permite verificar en este mismo inciso que las coordenadas de cada observación caen dentro del área geográfica esperada de su lago.

Sobre cada raster se aplican, en orden, los siguientes filtros de validez:

1. Máscara de datos válidos, descarta valores NoData y área fuera de la huella descargada.
2. Clasificación de agua, descarta tierra firme alrededor del lago, usando la máscara espectral ya calculada en la Parte I.
3. Ausencia de nube o sombra de nube, descarta píxeles con nube confirmada o con probabilidad alta de nube.
4. Reflectancia en rango válido, exige que las nueve bandas ópticas sean finitas y estén en un rango físicamente razonable.
5. Denominador del NDCI estable, descarta el pequeño número de píxeles de borde donde el índice de cianobacteria es matemáticamente inestable.
6. Agua estable, exige que el píxel se haya clasificado como agua en al menos nueve de las once fechas oficiales de su lago.


El último filtro reutiliza el criterio de agua estable definido en el inciso 8 de la Parte I para descartar píxeles de orilla observados como agua en muy pocas fechas, cuyos ratios espectrales resultan inestables. La tabla final conserva, por observación, el lago, la fecha, la fila y columna dentro del raster, las coordenadas en longitud y latitud, las coordenadas en UTM 15N, las nueve

bandas de reflectancia, el NDCI, el índice de cianobacteria, el FAI, el NDVI, el NDWI y la probabilidad residual de nube. Las bandas de máscara de datos válidos, de clasificación de agua y de nube confirmada se usan únicamente como filtros y no se conservan como columnas, porque tras aplicarlos quedan en un valor constante y no aportan información adicional.

Resultados

1.1 a 1.3 Construcción y limpieza del dataset


El dataset final contiene 3,753,732 observaciones válidas. La figura p2_efecto_filtros.png muestra el porcentaje de píxeles retenido tras cada filtro, por lago.



La caída más grande ocurre en el filtro de agua: en Atitlán, cuyo bbox es más ancho respecto al cuerpo del lago, queda alrededor de 26% del raster como agua; en Amatitlán, con un bbox más ajustado al contorno del lago, queda cerca de 12%. Los filtros posteriores retienen prácticamente toda esta agua, con la excepción puntual de fechas con nubosidad real sobre el lago, discutida en la sección de decisiones técnicas.

1.4 Observaciones, variables y valores faltantes

El dataset contiene 3,357,567 observaciones de Atitlán y 396,165 de Amatitlán, distribuidas en las once fechas oficiales de cada lago. La figura p2_observaciones_por_lago_fecha.png muestra el número de observaciones válidas por fecha.




En Atitlán, diez de las once fechas conservan entre 305 mil y 307 mil observaciones; la excepción es 2025-07-17, con 292,390, afectada por nubosidad real sobre el lago, ya explicada en la sección de decisiones técnicas. En Amatitlán las once fechas se mantienen entre 33,578 y 36,390 observaciones, con la fecha 2026-04-28 como la más afectada por nubosidad.

El dataset tiene 23 columnas: identificadores de lago y fecha, posición dentro del raster, coordenadas geográficas y UTM, y las quince bandas de reflectancia e índices. Ninguna variable presenta valores faltantes, ya que los filtros de limpieza descartan todo píxel con NoData, tierra, nube, reflectancia inválida o denominador inestable antes de construir la tabla, de modo que cada observación conservada tiene sus quince bandas completas. Los tipos de dato son consistentes con el contenido de cada columna: categórico para el lago, fecha para la fecha de adquisición, enteros para la posición en el raster y punto flotante para coordenadas, reflectancias e índices.


1.5 Análisis exploratorio

La figura p2_distribuciones_variables.png compara la distribución de seis variables clave entre ambos lagos, con el eje recortado al percentil 1 y 99 únicamente para fines de visualización.




El índice de cianobacteria muestra una separación clara entre lagos: la distribución de Atitlán se concentra entre -2 y 4, con una moda cercana a 1, mientras la de Amatitlán se concentra entre 2 y 8, con una moda cercana a 5 y una cola derecha más larga hacia valores altos. Esta diferencia reproduce, ya a nivel de píxel, el mayor deterioro ambiental de Amatitlán reportado en la Parte I. El NDVI es negativo en la mayoría de píxeles de ambos lagos, coherente con agua abierta sin vegetación emergente, y el NDWI es alto y con distribución similar entre lagos, confirmando que la máscara de agua delimita correctamente el cuerpo de agua en ambos casos. El NDCI y el FAI muestran el mismo patrón de separación entre lagos que el índice de cianobacteria, dado que ambos participan en su construcción. La probabilidad residual de nube se concentra en valores cercanos a cero en los dos lagos, consistente con el filtro de nubosidad ya aplicado.

La figura `p2_boxplots_por_fecha.png` compara la distribución completa del índice de cianobacteria, el NDVI y el NDWI entre las once fechas de cada lago.




En Atitlán la mediana del índice de cianobacteria sube de forma moderada hacia 2026, con una caja notablemente más ancha en 2026-04-13 y 2026-04-28 que en el resto de fechas. En Amatitlán el patrón es más marcado: las medianas se mantienen relativamente estables entre 4 y 6 hasta 2026-03-29, y luego suben con fuerza en 2026-04-28 y 2026-06-19, con cajas mucho más anchas y bigotes que llegan hasta 30, reflejando los picos de floración ya identificados en la Parte I. El NDVI y el NDWI siguen el mismo patrón temporal en dirección opuesta, con NDVI subiendo y NDWI bajando en las fechas de mayor índice de cianobacteria, consistente con la relación entre ambos indicadores reportada en la Parte I.

La figura `p2_correlacion_variables.png` muestra la matriz de correlación de Spearman entre las quince variables candidatas, calculada sobre la totalidad de las observaciones.



El NDCI y el índice de cianobacteria tienen una correlación de 1.00, porque el segundo es una transformación polinomial directa del primero. Ambos correlacionan con fuerza con las bandas rojo y B05, con valores de 0.68 y 0.78 respectivamente, ya que el NDCI se calcula directamente a partir de esas dos bandas. Las nueve bandas de reflectancia correlacionan entre 0.80 y 0.99 entre sí, un nivel de colinealidad esperado dado que todas responden, en distinto grado, a la misma señal de agua. El NDVI y el NDWI tienen una correlación de -0.95, coherente con que ambos se construyen a partir de combinaciones similares de las mismas bandas con signo opuesto. La probabilidad residual de nube correlaciona de forma moderada con las bandas de reflectancia, entre 0.56 y 0.72, y de forma negativa con el NDWI, -0.69, lo que sugiere que incluso tras el filtro de nubosidad queda una señal residual asociada a condiciones atmosféricas parciales sobre el agua.

La figura p2_cobertura_espacial.png clasifica cada píxel de una fecha representativa de cada lago según el primer filtro que lo descarta.



En ambas fechas la categoría de descarte por tierra domina fuera del contorno del lago, como se espera dado que el bbox de descarga incluye área terrestre alrededor del cuerpo de agua. Las observaciones válidas cubren la práctica totalidad del cuerpo de agua en ambos lagos. Los descartes por calidad, nube o sombra, reflectancia inválida, borde con NDCI inestable y borde de agua inestable, aparecen como un borde delgado alrededor del contorno del agua y no como regiones internas extensas, lo que indica que la limpieza no introduce huecos relevantes dentro del área de estudio de ninguno de los dos lagos.

Decisiones técnicas

- El evalscript de descarga se amplió de 10 a 18 bandas de salida, anexando las bandas nuevas después de las diez originales para no alterar el resultado de los notebooks de la Parte I. Sin esta ampliación, las únicas bandas de reflectancia disponibles eran B02, B03 y B04, y dos de esas tres participan en la construcción del índice de cianobacteria, lo que habría dejado casi sin predictores válidos independientes a los incisos de modelado.
- Al construir el dataset se detectó que la banda CLM usa el valor 255 como código de "sin dato" del modelo de detección de nubes, y no como nube. En tres de las 22 fechas, tratar ese valor como nube descartaba entre 48% y 92% de los píxeles de agua, a pesar de que esos píxeles tenían reflectancia y probabilidad de nube, CLP, normales. Por esta razón el filtro final excluye únicamente los píxeles con nube confirmada, CLM igual a uno, y usa CLP, que sí entrega un valor continuo incluso donde CLM es "sin dato", como criterio principal de nubosidad. Esta decisión evita descartar de forma injustificada una fracción grande de observaciones válidas y sustituye, para efectos de limpieza, el porcentaje de nubosidad reportado a nivel de escena completa por una evaluación directa sobre cada píxel del área de estudio.

- La fecha de Amatitlán del 7 de febrero de 2026 había sido señalada en la Parte I con una cobertura parcial de nubes de 57.1% según el catálogo. Los conteos de este inciso confirman lo ya observado en la Parte I: para el área específica del lago la imagen retiene 36,383 de 36,792 píxeles de agua, un 98.9%, prácticamente libre de nubes, por lo que la fecha se mantiene sin ajustes adicionales.
- Las columnas de máscara de datos válidos, clasificación de agua y nube confirmada se usan como filtros pero no se conservan en la tabla final, porque tras aplicar los filtros quedan en un valor constante y no aportan información como predictoras.
- El NDCI, la banda rojo, B04, y la banda B05 quedan comprometidas como predictoras desde este inciso, porque el índice de cianobacteria se calcula directamente a partir de ellas. Esta observación se retoma con mayor detalle en el inciso 2.5, donde se define formalmente la variable respuesta y se excluyen sus predictores directos.
- El dataset completo se guarda en `data/processed/dataset_ml.parquet`. Dado su tamaño, más de 3.7 millones de filas, se genera además `data/processed/dataset_ml_muestra.parquet`, un submuestreo aleatorio reproducible de 150,000 observaciones por lago, repartidas en partes iguales entre las once fechas de cada lago, que se usará como conjunto de trabajo en los incisos de ajuste de hiperparámetros, validación espacial y explicabilidad, donde el volumen completo resultaría lento sin aportar precisión adicional relevante.

Inciso 2. Construcción de la variable respuesta

Metodología

La variable respuesta se construye en `src/modelado.py` (`construir_respuesta`) y se aplica desde `notebooks/p2_02_variable_respuesta.ipynb` sobre el dataset completo del inciso 1, `data/processed/dataset_ml.parquet`. Se define `alta_cianobacteria = 1` cuando `clorofila` ≥ 10 $\mu\text{g/L}$, y 0 en caso contrario, donde `clorofila` es la concentración de clorofila-a estimada en el inciso 1 mediante el polinomio NDCI de Mishra & Mishra.

Resultados

2.1 y 2.2 Umbral y justificación científica


Se adopta el umbral de **10 $\mu\text{g/L}$ de clorofila-a**, sustentado en tres fuentes independientes que convergen en el mismo rango:

- La Organización Mundial de la Salud (WHO, 2003, *Guidelines for Safe Recreational Water Environments*, Vol. 1: *Coastal and Fresh Waters*) define el **Alert Level 1** para aguas recreativas en clorofila-a ≥ 10 $\mu\text{g/L}$, típicamente acompañado de cianobacterias $\geq 20,000$ células/mL, umbral a partir del cual recomienda vigilancia activa por riesgo de irritación de piel y síntomas gastrointestinales leves. Es el criterio principal adoptado, por estar directamente ligado a riesgo sanitario y ser el más usado en monitoreo operativo de floraciones.
- La clasificación trófica de la OECD (1982, *Eutrophication of Waters: Monitoring, Assessment and Control*) ubica el estado **eutrófico** en clorofila-a media de 8 a 25 $\mu\text{g/L}$.
- El Índice de Estado Trófico de Carlson (1977, *A trophic state index for lakes*, $\text{TSI}(\text{Chl}) = 9.81 \cdot \ln(\text{Chl}) + 30.6$) marca el límite mesotrófico-eutrófico ($\text{TSI} = 50$) en clorofila-a ≈ 7 $\mu\text{g/L}$.

El umbral se aplica sobre `clorofila`, ya en unidades físicas ($\mu\text{g/L}$) comparables con la bibliografía citada, y no sobre `ndci`, que es adimensional y solo tiene interpretación relativa.

2.3 Distribución de la variable respuesta

La figura `p2_distribucion_respuesta.png` muestra la proporción de observaciones con `alta_cianobacteria = 1` por lago y por fecha.



Globalmente, de las 3,753,732 observaciones del dataset, 43,269 (**1.15 %**) quedan clasificadas como alta presencia.

Por lago, la diferencia es de dos órdenes de magnitud:

Lago	Observaciones	Alta presencia	Proporción
Amatitlán	396,165	42,405	10.70 %
Atitlán	3,357,567	864	0.026 %

Es decir, el 98 % de las observaciones positivas del dataset provienen de Amatitlán, que aporta apenas el 10.6 % de las observaciones totales.

Por fecha, la proporción positiva en Amatitlán recorre casi todo el rango posible: desde 0.00 % (2026-02-02, 1 píxel de 36,010) hasta **53.7 %** (2026-06-19) y 36.9 % (2026-04-28), con valores intermedios de 7-8 % en 2025-04-28, 2026-01-08 y 2026-03-29. En Atitlán ninguna fecha supera el 0.11 % (máximo 2026-07-22, con 335 píxeles), y siete de las once fechas quedan por debajo de 0.05 %. Los dos picos de Amatitlán coinciden con los eventos de floración identificados en la Parte I.

2.4 Desbalance de clases

Existe un desbalance de clases severo: la razón global es de **85.8 : 1** a favor de la clase 0 (3,710,463 observaciones de clase 0 contra 43,269 de clase 1). Ese promedio, además, esconde dos regímenes muy distintos: en Amatitlán la razón es de **8.3 : 1**, un desbalance moderado y manejable, mientras que en Atitlán llega a **3,885 : 1**, un caso extremo en el que la clase positiva es prácticamente anecdótica. Las consecuencias sobre el entrenamiento y la evaluación de los modelos son:

- **Entrenamiento:** un clasificador puede minimizar la función de pérdida global prediciendo casi siempre la clase mayoritaria (0), logrando *accuracy* alto sin aprender a distinguir la clase de interés. Se mitiga con `class_weight="balanced"` en Regresión Logística y Random Forest (inciso 4) y con la división estratificada del inciso 4.2.
- **Evaluación:** el *accuracy* deja de ser informativo, porque un modelo trivial que siempre predice 0 obtendría un *accuracy* cercano a la proporción de la clase mayoritaria. Por eso el inciso 5 reporta también *precision*, *recall*, *F1* y *ROC-AUC*, y prioriza el *recall* de la clase 1 dado el mayor costo ambiental de no detectar una floración real frente al de una falsa alarma (inciso 5.3).

2.5 Variables excluidas como predictoras

Quedan excluidas como predictoras: `clorofila`, `ndci`, `rojo` (B04) y `b05` (B05).

`clorofila` es la variable a partir de la cual se construye directamente `alta_cianobacteria`; incluirla haría que el modelo aprenda literalmente el umbral, no un patrón espectral. `ndci` queda excluida porque `clorofila` es una transformación polinomial directa de `ndci` (correlación de Spearman de 1.00, reportada en el inciso 1). `rojo` y `b05` quedan excluidas porque $ndci = (B05 - B04) / (B05 + B04)$ se calcula directamente a partir de ellas, produciendo fuga de información indirecta.

`fai` y `ndvi` sí se conservan como predictoras a pesar de que su fórmula también usa B04: a diferencia de `ndci`, no son la variable a partir de la cual se definió el umbral de la respuesta, combinan B04 con otras bandas (B07, B8A) y capturan una señal distinta (materia flotante y vegetación) que aporta información adicional sin ser una transformación directa de la respuesta.

Decisiones técnicas

- El umbral (10 µg/L) es fijo y absoluto, no relativo a percentiles de la muestra, para conservar interpretación ambiental directa y comparabilidad entre lagos y fechas.
- Además de las cuatro variables excluidas por fuga directa, `clp` (probabilidad residual de nube) no se incluye en el conjunto de predictoras definido en `src/modelado.py`: no participa en la construcción de la respuesta, pero es un remanente de la limpieza de nubes del inciso 1 sin señal ambiental relevante para cianobacteria. Esta decisión se detalla en el inciso 3.

Inciso 3. Selección y construcción de variables predictoras

Metodología

PREDICTORES (src/modelado.py) reúne las bandas e índices que no participan en la construcción de la variable respuesta (inciso 2.5). A partir de este inciso los notebooks trabajan sobre data/processed/dataset_ml_muestra.parquet, la muestra de trabajo de 300,000 observaciones generada en el inciso 1, que también usarán los incisos de modelado siguientes.

Resultados

3.1 y 3.2 Conjunto de variables predictoras

Variable	Tipo	Qué representa	Por qué contribuye a detectar cianobacteria
verde	banda espectral (B03, 560 nm)	Reflectancia verde-amarilla	El pico de reflectancia verde es característico de la absorción de ficocianina y clorofila-a en cianobacterias; base de los algoritmos clásicos de color oceánico
azul	banda espectral (B02, 490 nm)	Reflectancia azul	Junto con verde forma la base de las razones de color oceánico (OC2/OC3) para estimar clorofila en agua abierta; disminuye con mayor concentración de pigmentos
b07	banda espectral (Red Edge 3, 783 nm)	Reflectancia en el filo rojo	Zona de transición entre absorción de clorofila y dispersión celular; insumo del FAI
b08	banda espectral (NIR, 842 nm)	Reflectancia infrarroja cercana	La dispersión por partículas y biomasa suspendida eleva la reflectancia NIR; distingue acumulaciones densas de fitoplancton o espuma del agua limpia
b8a	banda espectral (NIR angosta, 865 nm)	Reflectancia infrarroja cercana, banda angosta	Insumo directo del FAI; sensible a materia orgánica flotante en superficie
b11	banda espectral (SWIR1, 1610 nm)	Reflectancia infrarroja de onda corta 1	Sensible al contenido de humedad/turbidez; ayuda a diferenciar agua limpia de agua con alta carga orgánica o sedimentaria
b12	banda espectral (SWIR2, 2190 nm)	Reflectancia infrarroja de onda corta 2	Sensibilidad complementaria a b11 frente a turbidez y materiales flotantes

Variable	Tipo	Qué representa	Por qué contribuye a detectar cianobacteria
fai	índice espectral derivado	Floating Algae Index	Diseñado para detectar acumulaciones de materia flotante, incluidas floraciones superficiales
ndvi	índice espectral derivado	Normalized Difference Vegetation Index	En agua abierta toma valores negativos; su magnitud es sensible a biomasa flotante y algas superficiales densas
ndwi	índice espectral derivado	Normalized Difference Water Index	Delimita el cuerpo de agua; covaría de forma inversa con la turbidez y la carga de biomasa
verde_azul_ratio	característica derivada (3.3)	Razón verde/azul	Análoga simplificada a las razones OC2/OC3 de color oceánico para estimar pigmentos fotosintéticos


3.3 Ingeniería de características

Se agrega una única variable derivada, `verde_azul_ratio` (`src/modelado.agregar_features`), razón entre las bandas verde y azul. Es análoga simplificada a las razones de color oceánico OC2/OC3 (O'Reilly et al., 1998, *Ocean color chlorophyll algorithms for SeaWiFS*), diseñadas para estimar la concentración de pigmentos fotosintéticos a partir de reflectancias visibles, y no comparte bandas con `ndci/clorofila`, por lo que no introduce fuga de información.

Se consideraron y descartaron razones adicionales entre `b11`, `b12`, `b07` y `b8a` (por ejemplo `b11/b12` como proxy de turbidez, o una pendiente del red edge con `b07/b8a`): esas cuatro bandas ya entran individualmente como predictoras, y una razón entre ellas sería casi colineal con las bandas que la componen sin aportar señal independiente adicional, por lo que se mantiene el conjunto de predictoras simple.

Correlación de cada predictora con la variable respuesta

La figura `p2_correlacion_predictoras_respuesta.png` muestra la correlación de Spearman de cada predictora con `alta_cianobacteria`.



Las correlaciones positivas más fuertes son fai (0.39) y ndvi (0.38), seguidas de b07 (0.35), verde_azul_ratio (0.34) y b08 (0.34): todas capturan, por vías distintas, la señal de biomasa flotante y pigmentos fotosintéticos que también produce el NDCI. ndwi es la única con correlación negativa (-0.32), coherente con que las floraciones dispersan y reflejan más luz en el visible/NIR, reduciendo la señal de "agua limpia" que captura ese índice. Las bandas SWIR (b11 0.12, b12 0.08) muestran las correlaciones más débiles, aportando información complementaria más que señal dominante.

Ninguna predictora individual supera 0.39 en valor absoluto, lo que confirma que la relación entre firma espectral y alta presencia de cianobacteria no es capturable por una sola variable de forma lineal-monótona; es un argumento a favor de los modelos no lineales del inciso 4 frente a un simple umbral sobre un índice.

Decisiones técnicas

- El conjunto de predictoras se limita a 11 variables (10 bandas/índices del inciso 1 más verde_azul_ratio) para mantener el modelo interpretable y evitar colinealidad redundante; no se agregaron razones adicionales entre bandas ya incluidas individualmente.

- El análisis de correlación de este inciso es descriptivo, no un filtro de selección: todas las 11 variables se llevan al inciso 4, y es en la evaluación e interpretabilidad (incisos 5 y 8) donde se identifica su aporte real dentro de cada modelo.

Inciso 4. Construcción de modelos de Machine Learning

Metodología

Los tres modelos mínimos requeridos (`src/modelado.py`, `notebooks/p2_04_modelos.ipynb`) se construyen sobre `data/processed/dataset_ml_muestra.parquet` con las 11 predictoras del inciso 3. Regresión Logística usa un Pipeline con escalado (`StandardScaler`) por ser sensible a la escala de los predictores; Random Forest y Gradient Boosting, al basarse en árboles, no lo requieren. Regresión Logística y Random Forest reciben `class_weight="balanced"`; `GradientBoostingClassifier` no admite ese parámetro, así que su entrenamiento se compensa con `sample_weight` calculado como "balanced" sobre `y_train`.

Resultados

4.1 Modelos base

Se instancian Regresión Logística, Random Forest y Gradient Boosting con `src.modelo.construir_modelos_base`.

4.2 División 70/30 y entrenamiento inicial

`dividir_datos` aplica una división estratificada por `alta_cianobacteria`, con semilla fija (`SEMILLA = 42`), sobre las 299,992 observaciones de la muestra de trabajo: 209,994 de entrenamiento y 89,998 de prueba, ambas con 5.5 % de clase positiva. Estratificar preserva en ambos subconjuntos la proporción de clases documentada en el inciso 2.4; la semilla fija permite recalcular el mismo conjunto de prueba en cualquier notebook posterior sin necesidad de persistir índices, siempre que se parta del mismo `dataset_ml_muestra.parquet`.

4.3 Ajuste de hiperparámetros

Cada modelo se ajusta con `RandomizedSearchCV` (validación cruzada de 3 particiones, `scoring="roc_auc"`) sobre un grid pequeño centrado en sus hiperparámetros de mayor impacto en el balance sesgo/varianza:

Modelo	Hiperparámetros evaluados
Regresión Logística	C (regularización): 0.01, 0.1, 1, 10

Modelo	Hiperparámetros evaluados
Random Forest	n_estimators: 200, 400; max_depth: 8, 16, sin límite; min_samples_leaf: 1, 5, 20
Gradient Boosting	n_estimators: 100, 200; learning_rate: 0.05, 0.1; max_depth: 2, 3, 4

El criterio de selección es **ROC-AUC**: es la métrica menos sensible al desbalance de clases del inciso 2.4, a diferencia de accuracy, y no exige fijar de antemano un umbral de decisión como sí lo requieren precision/recall/F1.

Los hiperparámetros seleccionados (data/processed/p2_hiperparametros.csv) fueron:

Modelo	Hiperparámetros seleccionados
Regresión Logística	C = 10.0
Random Forest	n_estimators = 400, min_samples_leaf = 5, max_depth = None (sin límite)
Gradient Boosting	n_estimators = 100, learning_rate = 0.1, max_depth = 4

La búsqueda elige, en los tres casos, la configuración de mayor capacidad dentro del grid: la regularización más débil en Regresión Logística (C = 10), el bosque más grande y sin límite de profundidad en Random Forest, y la profundidad máxima disponible en Gradient Boosting. Con 210,000 observaciones de entrenamiento y solo 11 predictoras, la relación observaciones/parámetros es lo bastante holgada como para que el sobreajuste no penalice en validación cruzada, y el ligero min_samples_leaf = 5 de Random Forest actúa como la única restricción efectiva contra hojas de un solo píxel.

4.4 Conjunto de prueba compartido

El mismo X_test/y_test, generado en una sola llamada a dividir_datos, se usa para evaluar los tres modelos en el inciso 5. Los tres modelos ajustados se guardan en data/processed/modelos/ (guardar_modelo) y el conjunto de prueba en data/processed/p2_test_set.parquet, para reutilizarlos en los incisos 5, 7, 8 y 9 sin reentrenar.

Decisiones técnicas

- Se usa Gradient Boosting de scikit-learn en lugar de XGBoost: cumple el requisito del enunciado ("Gradient Boosting o XGBoost") sin agregar una dependencia nueva al proyecto, y es directamente compatible con shap.TreeExplainer en el inciso 8.

- El desbalance de clases se compensa en el entrenamiento (`class_weight/sample_weight`), no mediante sobremuestreo u submuestreo, para no alterar la distribución espacial y temporal real de las observaciones, relevante para los incisos 6 y 9.
- La búsqueda de hiperparámetros toma ~5.5 minutos sobre la muestra de trabajo con 32 núcleos; el costo lo domina Gradient Boosting, cuya implementación en scikit-learn construye los árboles de forma secuencial y no se paraleliza dentro de un mismo ajuste.

Inciso 5. Evaluación de los modelos

Metodología

Los tres modelos ajustados en el inciso 4 se evalúan (notebooks/p2_05_evaluacion.ipynb) sobre el mismo conjunto de prueba (data/processed/p2_test_set.parquet), calculando Accuracy, Precision, Recall, F1, ROC-AUC y matriz de confusión (src.modelo.evaluar).


Resultados


5.1 Métricas de evaluación

Sobre el conjunto de prueba compartido (89,998 observaciones, 5.5 % de clase positiva), los tres modelos obtienen:

Modelo	Accuracy	Precision	Recall	F1	F2	ROC-AUC
Random Forest	0.9915	0.8739	0.9878	0.9274	0.9627	0.9994
Gradient Boosting	0.9890	0.8375	0.9909	0.9077	0.9558	0.9993
Regresión Logística	0.9843	0.7800	0.9917	0.8732	0.9406	0.9988

La figura p2_matrices_confusion.png muestra la matriz de confusión de cada modelo y p2_curvas_roc.png compara sus curvas ROC.





5.2 Comparación de modelos

Los tres modelos alcanzan un desempeño alto y muy parecido entre sí: el ROC-AUC va de 0.9988 a 0.9994, un rango de seis diezmilésimas. La separación real entre ellos no está en la capacidad de ordenar observaciones por riesgo, sino en el **compromiso entre Precision y Recall**, y ese compromiso ordena a los modelos de forma inversa:

- **Random Forest** domina en ROC-AUC (0.9994), Precision (0.874) y F1 (0.927), y es el que menos falsas alarmas produce.
- **Regresión Logística** domina en Recall (0.9917), pero al costo de la Precision más baja (0.780): detecta casi todo, y a cambio marca como alta presencia bastantes zonas que no lo son.
- **Gradient Boosting** queda en medio en todas las métricas.

Es decir, **no hay un modelo que domine en todo**: el mejor en ROC-AUC no es el mejor en Recall. La diferencia de Recall entre el mejor (0.9917) y el peor (0.9878) es de apenas 0.4 puntos

porcentuales, mientras que la diferencia de Precision es de 9.4 puntos. En la práctica, mover el criterio hacia Recall puro compra muy poca detección adicional y paga mucho en falsas alarmas, lo que se refleja en el F2 del apartado siguiente: **Random Forest gana también en F2 (0.9627)**, y es el modelo seleccionado como mejor para los incisos 8 y 9.

5.3 Consecuencias ambientales de los errores y métrica más adecuada

Los dos tipos de error de clasificación no tienen el mismo costo ambiental:

- **Falso positivo** (clasificar como alta presencia una zona que no lo es): genera una alerta innecesaria, con costo de cerrar temporalmente una zona de baño, generar preocupación pública injustificada o desviar recursos de monitoreo hacia un punto sin riesgo real. Es un costo principalmente económico y de confianza en el sistema de monitoreo.
- **Falso negativo** (no detectar una zona que sí presenta alta presencia de cianobacteria): implica que una floración tóxica real queda sin alerta, con riesgo directo para la salud de bañistas y usuarios del lago, sin activar medidas de mitigación.

El falso negativo tiene un costo potencial más alto (riesgo sanitario) que el falso positivo (costo operativo), por lo que se prioriza **minimizar los falsos negativos**, es decir, maximizar el **Recall** de la clase "alta presencia". La comparación final entre modelos para su uso como herramienta de alerta usa el Recall de la clase 1 como criterio principal, complementado con un **F2-score** (que pondera el Recall el doble que la Precision) y con ROC-AUC como criterio secundario entre modelos con Recall similar.

Decisiones técnicas

- Se usa F2-score, no solo F1, como métrica compuesta de desempate: F1 pondera Precision y Recall por igual, mientras que el análisis ambiental del inciso 5.3 concluye que el Recall debe pesar más.
- El accuracy se reporta por completitud del enunciado, pero no se usa como criterio de comparación entre modelos, dado el desbalance de clases documentado en el inciso 2.4.
- La selección del mejor modelo se hace por F2 y no por Recall crudo: como los tres modelos están dentro de 0.4 puntos porcentuales de Recall, elegir por Recall crudo equivaldría a elegir por ruido, mientras que el F2 sí discrimina al penalizar la Precision muy inferior de la Regresión Logística.
- Un accuracy de 0.98-0.99 no es evidencia de buen desempeño en este problema: un clasificador trivial que siempre predijera "baja presencia" obtendría 0.945 de accuracy sobre este mismo conjunto de prueba. Lo que distingue a los modelos es el Recall sobre el 5.5 % positivo, no el accuracy global.

Inciso 6. Validación espacial y temporal

Metodología

Se divide cada lago en una cuadrícula regular de $\sim 1 \text{ km} \times 1 \text{ km}$ (`src/espacial.py`, `notebooks/p2_06_validacion_espacial.ipynb`) sobre las coordenadas `x_utm/y_utm` en EPSG:32615, ya calculadas en el inciso 1 al construir el dataset, por lo que este inciso no requiere una reproyección adicional. Cada observación se asigna a un bloque "`<lago>_<col>_<fila>`" (`asignar_bloques`), calculado por separado en cada lago para no mezclar identificadores entre Atitlán y Amatitlán. La validación espacial usa `StratifiedGroupKFold`: agrupa por bloque (ninguna observación de un mismo bloque queda repartida entre entrenamiento y validación dentro de un fold) y, dentro de esa restricción, intenta mantener la proporción de clases de cada fold cercana a la global.

A esa validación espacial se agrega su contraparte **temporal** (`asignar_grupos_temporales`, `cv_temporal`), con la misma mecánica de grupos pero usando la **fecha de adquisición** como agrupador: cada fold se evalúa sobre escenas completas que el modelo no vio durante su entrenamiento. Las dos responden a preguntas distintas: la espacial pregunta si el modelo predice *zonas* nuevas del lago; la temporal, si predice *días* nuevos, en los que cambian la iluminación solar, la nubosidad residual y el estado de la floración.

Resultados

6.1 Cuadrícula de bloques y evaluación del tamaño

Con el tamaño de $1 \text{ km} \times 1 \text{ km}$ del enunciado, la cuadrícula produce **203 bloques con observaciones válidas** en la muestra de trabajo:

Lago	Bloques	Obs. por bloque (mín / mediana / máx)
Atitlán	165	2 / 1,181 / 1,344
Amatitlán	38	42 / 3,128 / 10,859


El tamaño de 1 km **se conserva sin modificar**, porque incluso el lago más pequeño (Amatitlán, 38 bloques) queda muy por encima de los 5 grupos que exige una validación cruzada de 5 folds; `n_splits_seguro` confirmó que 5 folds son viables y ese es el número usado. La diferencia de forma entre ambos lagos es notoria y esperable: Atitlán, más extenso y de contorno regular, reparte sus observaciones de manera homogénea (mediana 1,181, máximo 1,344, es decir bloques casi

todos "llenos"); Amatitlán, más pequeño y alargado, concentra hasta 10,859 observaciones en un solo bloque y baja a 42 en los bloques de borde, que apenas rozan la orilla del lago.

Reducir el bloque a 500 m habría multiplicado por cuatro el número de bloques, pero también habría acercado el tamaño del bloque a la escala espacial de las propias manchas de floración, debilitando el objetivo de la validación espacial: separar entrenamiento y validación a una distancia mayor que la autocorrelación que se quiere neutralizar.

6.2 Bloques espaciales

La figura p2_bloques_espaciales.png visualiza los bloques asignados a cada lago sobre sus coordenadas UTM.




Para la validación temporal, el agrupador son las **11 fechas de cada lago**, con exactamente 13,636 observaciones por fecha y por lago en la muestra de trabajo (data/processed/p2_resumen_grupos_temporales.csv), gracias al muestreo balanceado del inciso 1.

6.3 y 6.4 Validación cruzada espacial, temporal y aleatoria

Los tres modelos (con los mismos hiperparámetros por defecto usados como punto de partida en el inciso 4.1) se evalúan bajo las tres estrategias, con 5 folds cada una (data/processed/p2_cv_aleatoria_vs_espacial.csv, figura p2_comparacion_cv.png):

Modelo	Estrategia	ROC-AUC medio	Desv. est.	Recall medio	F1 medio
Regresión Logística	aleatoria	0.9989	0.0001	0.9932	0.8711
Regresión Logística	espacial	0.9987	0.0007	0.9927	0.8713

Modelo	Estrategia	ROC-AUC medio	Desv. est.	Recall medio	F1 medio
Regresión Logística	temporal	0.9977	0.0019	0.9758	0.7633
Random Forest	aleatoria	0.9993	0.0002	0.9700	0.9465
Random Forest	espacial	0.9991	0.0006	0.9604	0.9400
Random Forest	temporal	0.9968	0.0023	0.6839	0.7428
Gradient Boosting	aleatoria	0.9992	0.0001	0.9391	0.9410
Gradient Boosting	espacial	0.9991	0.0005	0.9304	0.9347
Gradient Boosting	temporal	0.9973	0.0028	0.8045	0.8414



6.5 y 6.6 Comparación e interpretación

El desempeño sí disminuyó, pero la magnitud depende por completo de qué dimensión se bloquee y de qué métrica se mire.

La validación espacial casi no cambia nada. La caída de ROC-AUC respecto a la aleatoria es de 0.0002 en Regresión Logística y Random Forest y de 0.0001 en Gradient Boosting — diferencias del orden de la desviación estándar entre folds, es decir, ruido. El Recall cae algo más (Random Forest, de 0.970 a 0.960; Gradient Boosting, de 0.939 a 0.930), pero sigue siendo una diferencia de aproximadamente un punto porcentual.

Este resultado, contrario a lo que suele esperarse en datos geoespaciales, tiene una explicación concreta: **el modelo no usa las coordenadas como predictoras**. Las 11 predictoras del inciso 3 son bandas espectrales e índices, no posición. La autocorrelación espacial de los píxeles vecinos existe, pero se manifiesta como similitud espectral, no como una regla del tipo "esta zona del lago

siempre tiene floración" que el modelo pudiera memorizar. Al retirar un bloque completo de 1 km, el modelo sigue viendo, en el resto del lago y en las demás fechas, píxeles con firmas espectrales muy parecidas, así que no pierde información relevante.

La validación temporal sí golpea, y con fuerza desigual entre modelos. El ROC-AUC baja poco (de 0.9993 a 0.9968 en Random Forest, 2.5 diezmilésimas), pero el **Recall de Random Forest se desploma de 0.970 a 0.684**: al evaluarse sobre fechas nunca vistas, el mejor modelo del inciso 5 deja de detectar casi un tercio de las zonas con alta presencia. Gradient Boosting cae de 0.939 a 0.805, y la Regresión Logística, el modelo más simple, es el más robusto (0.993 a 0.976). La variabilidad entre folds también se multiplica por diez (desviación estándar de ROC-AUC de 0.0002 a 0.0023).

La razón es que **la verdadera unidad de dependencia en estos datos no es la vecindad espacial, sino la escena**. Todos los píxeles de una misma fecha comparten ángulo solar, condiciones atmosféricas, nubosidad residual y estado de la floración; una escena no es una colección de observaciones independientes sino, en la práctica, una sola observación de alta dimensión. Con solo 11 fechas por lago, retirar una fecha completa retira un régimen de condiciones entero. El caso extremo es 2026-06-19 en Amatitlán, con 53.7 % de píxeles positivos frente a fechas casi sin positivos: un fold entrenado sin esa fecha nunca vio una floración de esa intensidad.

También explica la inversión del ranking de modelos: Random Forest, con 400 árboles sin límite de profundidad, es el que más partido saca de particiones finas del espacio espectral, y esas particiones son precisamente lo que deja de ser válido cuando cambian las condiciones de adquisición. La Regresión Logística, al imponer una frontera lineal, no puede sobreajustarse a las particularidades de una escena y por eso degrada menos.

Cuál estimación es más realista. Para el uso previsto del modelo —aplicarlo a una imagen nueva de un día futuro— la estimación más realista es la de la **validación temporal**, no la espacial ni la aleatoria. La validación aleatoria del inciso 4 y la espacial de este inciso reparten píxeles de las mismas 11 fechas entre entrenamiento y prueba, de modo que el modelo siempre ha visto ya el "día" que se le pide predecir. Un Recall operativo del orden de **0.68**, y no el 0.99 del inciso 5, es la cifra que debe usarse para decidir si el modelo sirve como herramienta de monitoreo (inciso 10).

Decisiones técnicas

- Se usa StratifiedGroupKFold en lugar de GroupKFold simple: agrupar únicamente por bloque, sin estratificar, podría producir folds con muy pocas o ninguna observación de la clase minoritaria dado el desbalance del inciso 2.4, especialmente en Atitlán.
- La cuadrícula se construye por división entera sobre x_utm/y_utm en lugar de con una librería de geometría (p. ej. geopandas), evitando una dependencia nueva para una operación

que, sobre una grilla regular alineada a los ejes UTM, se resuelve con aritmética simple.

- La validación temporal agrupa por fecha **sola**, sin combinarla con el lago: las dos fechas compartidas por ambos lagos (2026-04-13 y 2026-04-28) caen así en el mismo fold. Separarlas dejaría que el modelo viera la escena de un lago mientras se le evalúa en la del otro el mismo día, que es exactamente la fuga que esta validación busca evitar.
- El número de folds no se fija en 5 de forma incondicional: `n_splits_seguro` lo reduce si el lago con menos bloques o la clase minoritaria no alcanzan para 5 grupos. En esta ejecución no fue necesario reducirlo.

Inciso 7. Generalización entre lagos

Metodología

notebooks/p2_07_generalizacion_lagos.ipynb evalúa si un modelo entrenado en un lago generaliza al otro, comparado contra una línea base de "mismo lago": los tres modelos base (`src.modelo.construir_modelos_base`, hiperparámetros por defecto, iguales a los del inciso 6) se entrenan y evalúan en cuatro configuraciones:

- **Baseline Atitlán / Amatitlán:** entrenamiento y prueba 70/30 dentro del mismo lago (`dividir_datos`), la referencia de "mismo lago".
- **Experimento A:** entrenamiento con la totalidad de las observaciones de Atitlán, evaluación con la totalidad de Amatitlán.
- **Experimento B:** entrenamiento con la totalidad de Amatitlán, evaluación con la totalidad de Atitlán.

Resultados

7.1 a 7.3 Experimentos y métricas

`data/processed/p2_generalizacion_lagos.csv` reúne Accuracy, Precision, Recall, F1 y ROC-AUC de las cuatro configuraciones para los tres modelos:

Líneas base (mismo lago, división 70/30)

Lago	Modelo	Precision	Recall	F1	ROC-AUC
Atitlán	Regresión Logística	0.423	1.000	0.595	1.000
Atitlán	Random Forest	0.579	1.000	0.733	1.000
Atitlán	Gradient Boosting	0.533	0.727	0.615	0.818
Amatitlán	Regresión Logística	0.830	0.983	0.900	0.998
Amatitlán	Random Forest	0.933	0.969	0.951	0.999
Amatitlán	Gradient Boosting	0.857	0.989	0.918	0.999


Experimentos cruzados

Experimento	Modelo	Precision	Recall	F1	ROC-AUC
A: Atitlán → Amatitlán	Regresión Logística	0.797	0.788	0.792	0.978

Experimento	Modelo	Precision	Recall	F1	ROC-AUC
A: Atitlán → Amatitlán	Random Forest	0.976	0.010	0.020	0.837
A: Atitlán → Amatitlán	Gradient Boosting	0.943	0.016	0.032	0.497
B: Amatitlán → Atitlán	Regresión Logística	0.242	1.000	0.390	1.000
B: Amatitlán → Atitlán	Random Forest	0.469	0.811	0.594	0.9999
B: Amatitlán → Atitlán	Gradient Boosting	0.231	1.000	0.376	0.9996

7.4 Comparación con mismo lago

La figura p2_generalizacion_lagos.png compara, para cada lago evaluado, el ROC-AUC del modelo entrenado en ese mismo lago contra el del modelo entrenado en el otro lago.



7.5 ¿Un modelo entrenado en un lago generaliza adecuadamente al otro?

No, y el fracaso es asimétrico: los dos experimentos fallan por razones opuestas.

Experimento A (entrenar en Atitlán, evaluar en Amatitlán): colapso del Recall. Random Forest pasa de un Recall de 0.969 en su línea base de Amatitlán a **0.010** cuando se entrena en Atitlán: detecta 1 de cada 100 zonas con alta presencia. Gradient Boosting queda igual de mal (0.016) y su ROC-AUC cae a **0.497**, indistinguible de lanzar una moneda. Nótese que la Precision se mantiene altísima (0.94-0.98): cuando estos modelos se atreven a marcar algo, aciertan; el problema es que casi nunca se atreven. La causa es directa: en el entrenamiento con Atitlán, la clase positiva representa el 0.026 % de las observaciones (razón 3,885 : 1). El modelo aprende, correctamente para ese lago, que la alta presencia de cianobacteria es un evento prácticamente inexistente, y traslada ese apriori a un lago donde ocurre en el 10.7 % de los píxeles.

Experimento B (entrenar en Amatitlán, evaluar en Atitlán): colapso de la Precision. Aquí el ROC-AUC se mantiene altísimo (0.9996-1.0000) y el Recall es excelente (0.81-1.00), pero la Precision se derrumba a 0.23-0.47. El modelo entrenado en Amatitlán ordena perfectamente los píxeles de Atitlán por riesgo —de ahí el ROC-AUC— pero coloca su umbral de decisión donde tenía sentido para un lago hipereutrófico, y termina marcando como alta presencia entre dos y cuatro veces más píxeles de los que realmente lo son. Es un problema de **calibración del umbral**, no de capacidad discriminativa.

Esto contradice la expectativa inicial, que anticipaba una caída mayor en B que en A. Ocurre lo contrario en términos de utilidad operativa: B produce un modelo demasiado sensible pero recuperable con un simple recalibrado del umbral, mientras que A produce un modelo inservible como sistema de alerta, porque no detecta las floraciones que debe detectar y ningún ajuste de umbral lo arregla en los modelos de árboles, cuya probabilidad predicha casi nunca supera niveles significativos.

El único modelo que generaliza de forma aceptable en ambas direcciones es la Regresión Logística (F1 de 0.79 en A y ROC-AUC de 1.00 en B), el mismo patrón observado en la validación temporal del inciso 6: la frontera lineal, al no poder ajustarse a las particularidades del lago de entrenamiento, transfiere mejor. Es un recordatorio de que el modelo con mejores métricas dentro de su dominio no es necesariamente el que mejor se traslada fuera de él.

7.6 Diferencias geográficas, ambientales y espectrales

- **Tamaño y profundidad:** Atitlán es un lago volcánico profundo y de gran superficie; Amatitlán es considerablemente más pequeño y somero, con mayor influencia relativa de las descargas urbanas e industriales de su cuenca. Estas diferencias físicas cambian la relación entre reflectancia superficial y concentración real de pigmentos.
- **Estado trófico de base:** la Parte I y el inciso 2 de esta parte documentan que Amatitlán opera en un régimen de clorofila-a sistemáticamente más alto que Atitlán; un modelo entrenado solo en Atitlán casi no observa ejemplos de "alta presencia" durante el entrenamiento, y uno entrenado solo en Amatitlán casi no observa ejemplos de "baja presencia" claramente estables.
- **Firma espectral de fondo:** diferencias en profundidad, sedimento en suspensión y composición del fondo del lago alteran la reflectancia de las bandas SWIR (b11, b12) y NIR (b08, b8a) incluso en ausencia de cianobacteria, por lo que un modelo puede confundir la firma espectral "normal" de un lago con una señal de floración en el otro.
- **Consecuencia práctica:** un modelo de este tipo debe entrenarse y calibrarse con datos del lago específico donde se va a usar, o al menos incluir observaciones de ambos lagos en el

entrenamiento, en lugar de asumir que un modelo ajustado para un lago es directamente transferible al otro.

Decisiones técnicas

- Los experimentos A y B entrenan con la totalidad de las observaciones del lago de origen, no con un 70%, porque en estos experimentos el conjunto de prueba es el otro lago completo; no hay riesgo de fuga entre entrenamiento y prueba al usar el 100% de un lago para entrenar y el 100% del otro para evaluar.
- Se usan los tres modelos con hiperparámetros por defecto, sin repetir la búsqueda del inciso 4.3, para mantener la comparación enfocada en el efecto del lago de entrenamiento y no en variaciones de ajuste fino entre modelos.
- Las líneas base de Atitlán deben leerse con cautela: su conjunto de prueba contiene apenas unas decenas de observaciones positivas (0.026 % de clase positiva), de modo que Precision y Recall se calculan sobre una muestra muy pequeña y son inestables. Es la razón por la que Atitlán muestra Recall de 1.000 con Precision de 0.42-0.58: basta con marcar generosamente para capturar los pocos positivos existentes.

Inciso 8. Interpretación y explicabilidad del modelo

Metodología


notebooks/p2_08_interpretabilidad.ipynb toma el modelo con mejor F2-score del inciso 5 (data/processed/p2_metricas_modelos.csv), el criterio orientado a Recall definido en el 5.3, y lo interpreta con importancia global de variables (src.modelo.importancia_global) y con SHAP. Random Forest y Gradient Boosting exponen feature_importances_ directamente; Regresión Logística, envuelta en un Pipeline con escalado, se interpreta con el valor absoluto de sus coeficientes estandarizados. Para SHAP, los modelos de árboles usan shap.TreeExplainer (exacto y eficiente); Regresión Logística usa el shap.Explainer genérico sobre predict_proba, con una muestra de referencia. Los valores SHAP se calculan sobre una submuestra de 2,000 observaciones del conjunto de prueba del inciso 4, suficiente para un resumen estable sin el costo de explicar el conjunto completo.

Resultados

8.1 Importancia global de variables


El mejor modelo por F2-score es **Random Forest** (F2 = 0.9627). Su importancia global de variables (data/processed/p2_importancia_variables.csv) queda concentrada en cuatro predictoras, que reúnen el 78 % de la importancia total:

Variable	Importancia	Variable	Importancia
fai	0.330	b12	0.033
ndvi	0.222	b8a	0.030
verde_azul_ratio	0.131	b11	0.022
b07	0.097	ndwi	0.020
verde	0.052	azul	0.015
b08	0.048		



8.2 SHAP Summary Plot

La figura `p2_shap_summary.png` muestra la dispersión de valores SHAP de cada predictora sobre la submuestra explicada. El orden de variables coincide exactamente con el de la importancia global, lo que indica que la jerarquía no es un artefacto del método de medición.



8.3 y 8.4 Variables de mayor influencia e interpretación ambiental

Las cuatro variables de mayor dispersión SHAP son **fai**, **ndvi**, **verde_azul_ratio** y **b07**, y en las cuatro **los valores altos (rojo) empujan la predicción hacia alta presencia y los bajos (azul) hacia baja presencia**, con una separación limpia entre ambos grupos:

- **fai (0.330)** es la variable dominante, con el rango de impacto más amplio del gráfico (SHAP de -0.42 a $+0.24$). El Floating Algae Index fue diseñado precisamente para detectar materia flotante en superficie, y en Amatlán las floraciones de cianobacteria forman natas visibles que se acumulan en la superficie del agua. Que el modelo apoye su decisión principalmente en **fai** es coherente con la fenomenología del problema: no está detectando clorofila disuelta en la columna de agua, sino biomasa acumulada arriba. Es relevante notar que la mayor densidad de puntos azules se concentra en $\text{SHAP} \approx -0.18$: el **fai** bajo es la señal más frecuente y estable de "agua sin floración".
- **ndvi (0.222)** funciona como confirmación independiente. En agua limpia el NDVI es negativo; una floración densa lo empuja hacia valores propios de vegetación, porque una nata de algas se comporta ópticamente como vegetación flotante. Los valores altos producen SHAP de hasta $+0.22$.

- **verde_azul_ratio (0.131)**, la única variable derivada construida en el inciso 3.3, resulta ser la tercera más influyente, por encima de siete bandas espectrales originales. Esto valida la decisión de construirla: la razón verde/azul es análoga a los algoritmos de color oceánico OC2/OC3 y capta la absorción diferencial de los pigmentos fotosintéticos, información que ninguna banda individual expresa por sí sola.
- **b07 (0.097)**, el red edge en 783 nm, aporta la transición entre la absorción de clorofila y la dispersión celular, la región del espectro donde el fitoplancton se distingue mejor del agua.

Dos comportamientos invertidos merecen atención: en b12 y azul, los valores **altos** (rojo) empujan hacia baja presencia, con SHAP de hasta -0.30 . En el caso de azul es directamente interpretable: una alta concentración de pigmentos absorbe fuertemente en el azul, así que un azul alto indica agua sin floración. En b12 (SWIR2, 2190 nm), donde el agua absorbe casi toda la radiación, una reflectancia alta indica más bien sedimento en suspensión o mezcla espectral con la orilla — es decir, el modelo aprendió a usar b12 como señal de "esto es turbidez, no algas", una discriminación útil que evita confundir agua sucia con agua con floración.

ndwi es la variable menos influyente (0.020), pese a haber mostrado la correlación negativa más fuerte con la respuesta en el inciso 3 (-0.32). No es una contradicción: NDWI delimita agua frente a no-agua, y como el dataset ya está restringido a píxeles de agua estable por los filtros del inciso 1, esa información resulta redundante dentro del dominio en que opera el modelo. Es un buen ejemplo de que una correlación marginal alta no implica aporte marginal alto en presencia de otras variables.

Lectura ambiental de conjunto: el modelo no descubrió un mecanismo nuevo, sino que reconstruyó, a partir de bandas independientes de la variable respuesta, la misma física que sustenta los índices de floración publicados — materia flotante (fai), comportamiento tipo vegetación (ndvi) y absorción de pigmentos en el visible (verde_azul_ratio, azul). Esto refuerza la credibilidad del modelo: sus predicciones se apoyan en señal espectral con significado físico, no en correlaciones espurias del conjunto de entrenamiento.

Decisiones técnicas

- SHAP se calcula sobre una submuestra de 2,000 observaciones del conjunto de prueba, no sobre el conjunto completo: TreeExplainer es exacto pero su costo crece con el número de observaciones explicadas, y una submuestra de este tamaño ya da un resumen visual estable.
- Para Regresión Logística se usa el shap.Explainer genérico sobre predict_proba en lugar de LinearExplainer, para tener una única ruta de código (aplicable a cualquier

modelo con `predict_proba`) en vez de una rama adicional específica para modelos lineales.

- El criterio de selección del "mejor modelo" es el F2-score del inciso 5.3 (orientado a Recall), no ROC-AUC, para mantener la interpretabilidad alineada con la prioridad ambiental ya establecida: minimizar falsos negativos.
- La coincidencia entre el orden de `feature_importances_` y el de dispersión SHAP no era garantizada: la importancia por impureza de Random Forest tiende a favorecer variables continuas de alta cardinalidad, mientras que SHAP mide contribución marginal al resultado. Que ambos coincidan aquí da confianza en la jerarquía reportada.

Inciso 9. Generación de mapas predictivos

Metodología


notebooks/p2_09_mapas_predictivos.ipynb usa el mejor modelo del inciso 5 (mismo criterio de selección del inciso 8: mayor F2-score) sobre el **dataset completo** (data/processed/dataset_ml.parquet, no la muestra de trabajo), para poder reconstruir una imagen densa de probabilidad por píxel. Para cada lago se usa fecha_pico, la fecha con mayor clorofila promedio, con la misma definición que la Parte I (notebooks/05_analisis_espacial.ipynb) usa para identificar la fecha de floración más intensa, lo que permite comparar directamente contra los mapas de cianobacteria ya generados en esa parte. src/mapas.py reconstruye la imagen 2D a partir de las columnas fila/columna guardadas desde el inciso 1 (rejilla_desde_columns), dejando en NaN las celdas sin observación válida.

Resultados

9.1 a 9.4 Probabilidad por observación y mapa de probabilidad

El modelo aplicado es Random Forest (mejor F2 del inciso 5). Las fechas pico seleccionadas son **2026-04-13 para Atitlán** y **2026-06-19 para Amatitlán**, con 306,794 y 36,327 observaciones válidas respectivamente. El contraste entre ambos lagos es total: la probabilidad media predicha es de **0.000 en Atitlán** y **0.587 en Amatitlán**.

La figura p2_mapa_probabilidad.png muestra, para cada lago en su fecha_pico, la probabilidad predicha de alta presencia de cianobacteria en una escala discreta de 4 niveles (muy baja, baja, alta, muy alta), delimitados en [0, 0.25, 0.5, 0.75, 1].



9.5 Comparación con los mapas de cianobacteria de la Parte I

El mapa predictivo **reproduce fielmente el patrón espacial reportado en la Parte I**, sin haber usado ninguna de las variables con las que se construyó ese mapa:

- En **Amatitlán (2026-06-19)**, las zonas de probabilidad "muy alta" cubren el brazo norte completo, el estrecho que lo conecta con el cuerpo principal y la bahía sur — exactamente las tres zonas que la Parte I identificó como puntos persistentes de acumulación por su poca profundidad y circulación reducida. La franja central del lago, entre el cuerpo principal y la bahía sur, aparece en "muy baja", coincidiendo con la zona abierta y de mayor circulación.
- En **Atitlán (2026-04-13)**, prácticamente toda la superficie queda en "muy baja", consistente con el índice de cianobacteria uniformemente bajo que la Parte I documentó para ese lago, incluso en su fecha de mayor promedio.


La concordancia es significativa metodológicamente: las 11 predictoras excluyen *ndci*, *clorofila*, *rojo* y *b05* (inciso 2.5), de modo que el modelo llegó a la misma geografía de la floración por una vía espectral independiente de la que produjo el mapa de referencia.

9.6 Zonas correctamente detectadas, falsos positivos y falsos negativos

La figura `p2_mapa_errores.png` clasifica cada observación en verdadero positivo (VP), falso positivo (FP), falso negativo (FN) o verdadero negativo (VN), comparando la predicción del modelo contra *alta_cianobacteria*. El conteo por lago es:

Lago	VP	VN	FP	FN	Total
Amatitlán (2026-06-19)	19,415	14,863	1,970	79	36,327
Atitlán (2026-04-13)	4	306,744	39	7	306,794

En Amatitlán, el modelo detecta 19,415 de las 19,494 zonas con alta presencia real: un **Recall de 0.996**, con solo 79 falsos negativos. El precio son 1,970 falsos positivos (Precision 0.908). Dada la prioridad establecida en el inciso 5.3 —minimizar falsos negativos por su costo sanitario— este reparto de errores es el deseable. En Atitlán las cifras absolutas son minúsculas (11 positivos reales en 306,794 píxeles) y no permiten conclusiones estadísticas sólidas, aunque los 39 falsos positivos sobre 306,783 negativos reales representan una tasa de falsa alarma de 0.013 %, operativamente despreciable.



9.7 Regiones con dificultad sistemática

Sí, y el patrón es inequívoco: los errores forman una orla en el contorno del lago. En el mapa de Amatitlán, los falsos positivos (naranja) aparecen casi exclusivamente como una franja delgada y continua a lo largo de la línea de costa y en el perímetro de las zonas verdes (VP), mientras que el interior de las zonas de floración y el interior de las zonas limpias están prácticamente libres de error. En Atitlán ocurre lo mismo a escala mucho menor: los pocos falsos positivos se sitúan en la orilla de las bahías del sur.

Se identifican dos regímenes de dificultad, ambos de borde:

- **Borde tierra-agua (mezcla espectral).** En el límite con la máscara de agua, un píxel de 20 m contiene una mezcla de agua, vegetación ribereña y sedimento costero. Esa mezcla eleva

ndvi y fai —las dos variables dominantes del inciso 8— por razones que no tienen nada que ver con cianobacteria, y el modelo interpreta esa firma como floración. Los filtros de calidad del inciso 1 (agua estable en ≥ 9 de 11 fechas) reducen pero no eliminan este efecto, porque un píxel puede ser agua en todas las fechas y aun así estar espectralmente contaminado por la orilla adyacente.

- **Borde de la mancha de floración (transición gradual).** En el perímetro de las zonas de alta concentración, la clorofila real cruza el umbral de 10 $\mu\text{g/L}$ de forma continua, mientras que el modelo debe emitir una decisión binaria con un umbral fijo de 0.5. Cualquier clasificador produce error justo ahí, y ese error es en buena medida un artefacto de haber binarizado una variable continua (inciso 2.1), no una falla del modelo.

Consecuencia operativa: la orla de falsos positivos costeros no invalida el mapa, pero sí sugiere que un uso operativo debería o bien aplicar una erosión morfológica de un píxel a la máscara de agua, o bien reportar el riesgo agregado por zona (bahía, brazo) en lugar de píxel a píxel, para que el ruido de borde no domine la alerta.

Decisiones técnicas

- El mapa se construye sobre el dataset completo, no sobre la muestra de trabajo de 300,000 observaciones usada en los incisos 4 a 8: una reconstrucción espacial densa requiere todos los píxeles válidos de la fecha elegida, no un submuestreo aleatorio, que dejaría huecos artificiales en la imagen.
- fecha_pico se define con el mismo criterio que la Parte I (mayor clorofila promedio por lago), en lugar de una fecha arbitraria, para que la comparación del inciso 9.5 sea directa contra un mapa de cianobacteria ya generado previamente para esa misma fecha.
- Las celdas sin observación válida se dejan en NaN, no en 0, para que imshow las distinga visualmente de una probabilidad real de 0 (agua sin riesgo) en lugar de mostrarlas como parte del cuerpo de agua.
- El umbral de clasificación para el mapa de error es 0.5 (el que usa modelo.predict por defecto), consistente con el usado para calcular las métricas del inciso 5, aunque el mapa de probabilidad (9.1-9.4) sigue mostrando el valor continuo antes de aplicar ese umbral.
- Los mapas de este inciso se generan con el modelo entrenado en el inciso 4, cuyo conjunto de entrenamiento incluye píxeles de estas mismas dos fechas. Las cifras de error de 9.6 son, por tanto, optimistas respecto a lo que el modelo lograría sobre una escena futura; la estimación honesta para ese escenario es la de la validación temporal del inciso 6 (Recall $\approx$ 0.68), no el 0.996 de este mapa.

Inciso 10. Análisis y conclusiones

10.1 ¿Tiene el modelo capacidad suficiente para apoyar el monitoreo de cianobacteria?

El modelo desarrollado **sí tiene capacidad suficiente para ser una herramienta de apoyo** al monitoreo de cianobacteria, pero con una condición estricta: solo si se lo evalúa y se lo usa entendiendo que su desempeño real es el que reporta la validación temporal, no el que reporta la división aleatoria convencional.

La evidencia a favor. Sobre el conjunto de prueba del inciso 5, Random Forest alcanza un Recall de 0.988 con una Precision de 0.874 y un ROC-AUC de 0.9994; en el mapa predictivo de Amatitlán del inciso 9 detecta 19,415 de 19,494 zonas con alta presencia real, dejando solo 79 sin detectar. Más importante que las métricas es *cómo* las consigue: el inciso 8 muestra que las cuatro variables dominantes son *fai* (0.330), *ndvi* (0.222), *verde_azul_ratio* (0.131) y *b07* (0.097), todas con significado físico directo — materia flotante, comportamiento tipo vegetación y absorción de pigmentos. El modelo reconstruyó la física de las floraciones a partir de bandas independientes de las que se usaron para construir la variable respuesta, y el mapa resultante reproduce las mismas tres zonas de acumulación de Amatitlán (brazo norte, estrecho y bahía sur) que la Parte I identificó por una vía completamente distinta. No está explotando una fuga de información ni una correlación espuria.

La evidencia en contra, y es la que decide el alcance de uso. El hallazgo central de este laboratorio es que **la dimensión que degrada el modelo no es la espacial sino la temporal:**

- La validación espacial por bloques de 1 km, que era la preocupación anticipada del enunciado, resultó **casi irrelevante:** el ROC-AUC cae 0.0002 y el Recall alrededor de un punto porcentual. La razón es que el modelo no usa coordenadas como predictoras, de modo que retirar una zona del lago no le quita información que estuviera memorizando.
- La validación temporal, en cambio, **hunde el Recall de Random Forest de 0.970 a 0.684.** Al evaluarse sobre fechas nunca vistas, el mejor modelo deja de detectar casi un tercio de las zonas con alta presencia. La unidad real de dependencia en estos datos es la escena completa —ángulo solar, atmósfera, estado de la floración compartidos por todos sus píxeles—, no la vecindad espacial, y con solo 11 fechas por lago retirar una retira un régimen entero de condiciones.
- El inciso 7 añade que el modelo **no transfiere entre lagos**, y falla de forma asimétrica: entrenado en Atitlán y evaluado en Amatitlán, Random Forest colapsa a un Recall de 0.010 (detecta 1 de cada 100 floraciones) porque aprendió de un lago donde la clase positiva es el

0.026 % de los píxeles; en la dirección contraria conserva el poder discriminativo (ROC-AUC 0.9999) pero pierde la calibración del umbral (Precision 0.47).

Conclusión operativa. El modelo sirve como **primer filtro de vigilancia** sobre los lagos y en el rango de fechas con los que fue entrenado: es útil para priorizar qué zonas revisar, para generar mapas de riesgo continuos entre visitas de campo y para reproducir el índice de cianobacteria sin necesidad de las bandas que lo componen. **No sirve**, en su estado actual, como sistema de alerta automático sobre escenas futuras (un Recall de 0.68 significa que una de cada tres floraciones pasaría desapercibida), ni como fuente única de decisión sanitaria, ni aplicado a un lago para el que no tenga datos de entrenamiento propios. Cualquier despliegue debe reentrenarse incorporando cada nueva escena disponible, y su umbral de decisión debe recalibrarse por lago.

Un apunte metodológico que se desprende de todo lo anterior: **la métrica que se reporta importa menos que el esquema de validación con el que se calcula**. Los tres modelos están dentro de 0.0006 de ROC-AUC entre sí bajo validación aleatoria, una diferencia irrelevante; en cambio, el mismo modelo pasa de 0.970 a 0.684 de Recall según se bloquee o no la fecha. Elegir bien el esquema de validación discriminó más que elegir bien el modelo.

10.2 Limitaciones principales

- **Cantidad de fechas:** 11 fechas por lago en año y medio son insuficientes para que el modelo aprenda la variabilidad estacional completa documentada en la Parte I (patrón seco/lluvioso, tendencia ascendente). Con tan pocas fechas, el riesgo de sobreajustar a las condiciones particulares de esas 22 escenas es alto.
- **Nubosidad:** aunque el inciso 1 filtra píxeles con nube confirmada o alta probabilidad de nube, la cobertura de nubes reduce la cantidad de observaciones válidas en fechas puntuales (por ejemplo, la fecha de mayor pico en Amatitlán coincide con la de mayor nubosidad oficial, según la Parte I), lo que introduce incertidumbre justo en los eventos más relevantes de detectar.
- **Resolución espacial:** los 20 m de resolución de Sentinel-2 mezclan, en un mismo píxel, agua con distintas condiciones (orilla, afluentes, zonas de circulación distinta), lo que puede explicar parte de los errores sistemáticos identificados en el inciso 9.7.
- **Diferencias entre lagos:** el inciso 7 muestra que Atitlán y Amatitlán tienen regímenes espectrales y tróficos suficientemente distintos como para que un modelo entrenado en uno no transfiera bien al otro, lo que limita la generalización del modelo a otros cuerpos de agua no incluidos en el entrenamiento.
- **Metodología de validación:** la validación aleatoria del inciso 4 sobreestima fuertemente el desempeño real sobre escenas nuevas (Recall 0.970 frente a 0.684 bajo validación temporal). La validación espacial por bloques, pese a ser la que pedía el enunciado, resultó

insuficiente para revelar ese problema: con solo 11 fechas por lago, la validación temporal tiene además muy pocos grupos, de modo que sus propios resultados tienen un margen de incertidumbre amplio (desviación estándar de ROC-AUC diez veces mayor que la de la validación aleatoria).

- **Umbral fijo de decisión:** el modelo se evalúa siempre con el umbral de 0.5 por defecto. El inciso 7 muestra que ese umbral es lo primero que deja de ser válido al cambiar de lago, y el inciso 9 muestra que buena parte del error residual está en el borde de las manchas de floración, donde la clorofila real cruza el umbral de 10 $\mu\text{g/L}$ de forma continua. Parte del error medido es un artefacto de haber binarizado una variable continua.
- **Ausencia de verdad de campo independiente:** la variable respuesta se deriva del propio índice satelital (clorofila), no de mediciones de laboratorio en el lago. El modelo aprende a reproducir el índice espectral, no una medición físico-química validada de forma independiente.

10.3 Información adicional que podría mejorar el modelo

- **Datos meteorológicos:** temperatura y precipitación (por ejemplo, de las fuentes de WeatherSpark referenciadas en el enunciado) permitirían modelar directamente el mecanismo estacional ya identificado en la Parte I (estancamiento y calentamiento en temporada seca), en lugar de que el modelo intente inferirlo indirectamente solo a partir de bandas espectrales.
- **Datos hidrológicos:** caudal de afluentes, tiempo de residencia del agua y niveles del lago ayudarían a explicar las zonas de acumulación por baja circulación ya identificadas en la Parte I (el estrecho y la bahía sur de Amatitlán), y podrían mejorar la predicción en esas zonas de mayor error (inciso 9.7).
- **Muestreos físicos de calibración:** mediciones de clorofila-a o de conteo de cianobacterias en campo, aunque sean puntuales, permitirían validar el umbral de 10 $\mu\text{g/L}$ del inciso 2 con datos independientes del propio satélite, y detectar si el índice NDCI se desvía de la concentración real bajo ciertas condiciones (por ejemplo, alta turbidez no asociada a cianobacteria).
- **Mayor frecuencia temporal:** es la mejora de mayor impacto esperado, a la luz del inciso 6. Más fechas por año, especialmente alrededor de los picos de floración de marzo a junio ya identificados en la Parte I, atacarían directamente la causa de la caída de Recall bajo validación temporal: con 11 escenas por lago, el modelo dispone de muy pocos regímenes de condiciones de adquisición distintos, y cada fecha retirada en validación se lleva un régimen completo. Sentinel-2 ofrece revisitas de 5 días, así que el límite no es el satélite sino la nubosidad y el volumen de descarga.

- **Datos de otros lagos o cuerpos de agua:** dado que el inciso 7 muestra generalización limitada entre solo dos lagos, incorporar datos de más cuerpos de agua con regímenes tróficos distintos ayudaría a que el modelo aprenda un patrón espectral más general de cianobacteria, en lugar de memorizar la firma particular de Atitlán y Amatitlán.