

Contents

Universidad del Valle de Guatemala	2
Laboratorio 2: Redes LSTM y caracterización con catch22	2
Índice	3
1. Metodología LSTM	4
Series seleccionadas	4
Preprocesamiento	4
Ventaneo y tamaño de la muestra	4
Estrategias de pronóstico	5
Validación y criterio de selección	5
Rejilla de hiperparámetros	5
Reproducibilidad	6
2. Modelado LSTM de la serie total	7
La rejilla ejecutada y su costo	7
Configuraciones seleccionadas	7
Las dos arquitecturas de referencia	7
¿Qué hiperparámetro movió el error	8
Curvas de entrenamiento	8
Predicción sobre el test	10
¿Reproduce la recuperación pospandemia?	10
Lectura honesta de la calidad predictiva	11
3. Modelado LSTM de la vía aérea	12
La rejilla ejecutada y su costo	12
Configuraciones seleccionadas	12
Las dos arquitecturas de referencia	12
¿Qué hiperparámetro movió el error	13
Curvas de entrenamiento	13
Predicción sobre el test	13
¿Reproduce la recuperación pospandemia?	15
Lectura honesta de la calidad predictiva	16
4. Análisis comparativo: LSTM contra los modelos del Laboratorio 1	17
Criterio de comparación	17
Por qué no se usan AIC ni BIC	17
Resultados	17
Serie total	18
Cuál de las dos estrategias LSTM predijo mejor	18
Si son mejores que los del Laboratorio 1	18
Vía aérea	19
Cuál de las dos estrategias LSTM predijo mejor	19
Si son mejores que los del Laboratorio 1	20
La reserva que las métricas de error no muestran	20
¿Qué significa el resultado dado el diseño temporal del split	21
5. Caracterización de las series con catch22	23
5.1 La idea detrás de catch22	23
5.2 Extracción, matriz y estandarización	23
5.3 PCA, clustering, heatmap, correlaciones y distancias	23
5.4 ¿Cuáles series presentan comportamientos más similares?	27
5.5 ¿Qué características fueron las más importantes para diferenciar las series?	28
5.6 ¿Existen grupos naturales de series?	28

5.7 ¿Las series de una misma categoría tienden a agruparse?	29
5.8 ¿Qué series presentan el comportamiento más atípico?	29
5.9 Comparación con el análisis exploratorio del Laboratorio 1	30
5.10 Tres descubrimientos que el análisis exploratorio tradicional no había mostrado	31
5.11 Un LSTM con características catch22 de ventana móvil	31

Universidad del Valle de Guatemala

Facultad de Ingeniería Departamento de Ciencias de la Computación CC3084 Data Science,
Semestre II 2026

Laboratorio 2: Redes LSTM y caracterización con catch22

Modelado con redes LSTM de dos series mensuales de viajeros internacionales a Guatemala (total y vía aérea), con tuneo de hiperparámetros, dos estrategias de pronóstico y comparación contra los modelos del Laboratorio 1. Se añade la caracterización de las siete series del laboratorio anterior con el algoritmo catch22 (22 características canónicas por serie), su análisis mediante PCA, clustering, mapa de calor, correlaciones y distancias, y un LSTM adicional que usa esas características de ventana móvil como entrada.

Series analizadas: total de viajeros y vía aérea, seleccionadas por no tener meses en cero durante el entrenamiento (requisito de `log1p`) y por contrastar entre sí: total es la peor predicha del Laboratorio 1 (MAPE 58.11 %) y vía aérea la mejor (MAPE 35.62 %).

Split: heredado sin modificaciones del Laboratorio 1: entrenamiento de enero de 2009 a marzo de 2021 (147 meses) y prueba de abril de 2021 a junio de 2026 (63 meses).

Integrantes

Nombre	Carné
Esteban Cárcamo	23016
Hugo Daniel Barillas	23556
Ernesto Ascencio	23009

Fecha: 30 de julio de 2026 **Repositorio:** <https://github.com/ecarcamo/CC3084-DATA-SCIENCE/tree/lab2>

Índice

- 1. Metodología LSTM
- 2. Modelado LSTM de la serie total
- 3. Modelado LSTM de la vía aérea
- 4. Análisis comparativo: LSTM contra los modelos del Laboratorio 1
- 5. Caracterización de las series con catch22

1. Metodología LSTM

Series seleccionadas

El Laboratorio 1 construyó siete series mensuales de viajeros. El enunciado de este laboratorio pide trabajar con dos de ellas, sobre la misma partición, para que la comparación entre familias de modelos sea directa.

El criterio de descarte fue la presencia de meses en cero dentro del entrenamiento. Un cero obliga a `log1p` a devolver 0 y arrastra el mínimo del escalador hasta ese punto, lo que comprime el resto de la serie, y además deja el MAPE indefinido en esos meses. Solo tres series cumplen la condición: total, vía aérea y vía terrestre. Vía marítima acumula 16 ceros en entrenamiento y las tres series por país de residencia acumulan 5 cada una.

De las tres candidatas se descartó vía terrestre. Total y vía aérea ya tenían análisis preliminar propio en `notebooks/03_series_preliminar.ipynb`, y contrastan mejor entre sí: total es la serie agregada de referencia y la que peor se predijo en el Laboratorio 1, con un MAPE de 58.11 % en el mejor modelo, mientras que vía aérea fue la mejor predicha, con 35.62 %. Las dos ponen a prueba la red en condiciones distintas.

Serie	Ceros en train	Mejor modelo del Lab 1	MAE	RMSE	MAPE
Total	0	SES	175,088	194,791	58.11 %
Vía aérea	0	SES	36,109	41,368	35.62 %

La partición es la del Laboratorio 1 y no se rehace: entrenamiento de enero de 2009 a marzo de 2021 (147 meses) y prueba de abril de 2021 a junio de 2026 (63 meses). El conjunto de prueba no interviene en ninguna etapa del ajuste ni del tuneo.

Preprocesamiento

La transformación es la misma del Laboratorio 1, `log1p`, lo que mantiene comparables los dos conjuntos de resultados. Estabiliza la varianza, que en estas series crece con el nivel, y tolera valores en cero.

Sobre la serie transformada se ajusta un `MinMaxScaler` que lleva el entrenamiento al intervalo $[0, 1]$, rango en el que la LSTM converge sin saturar sus activaciones. El escalador se ajusta únicamente con las 147 observaciones de entrenamiento. Para la serie total sus límites son 9.1881 y 13.1535 en escala `log1p`, exactamente el mínimo y el máximo del entrenamiento; uno de los 63 meses de prueba cae fuera de ese intervalo al transformarse, prueba de que el escalador nunca lo vio.

La reversión de cualquier pronóstico aplica `inverse_transform`, luego `expm1` y finalmente un recorte en cero, porque un conteo de viajeros negativo no tiene sentido.

Ventaneo y tamaño de la muestra

La red se alimenta con ventanas deslizantes sobre el vector escalado. Cada observación de entrenamiento es una secuencia de `ventana` meses consecutivos y su objetivo son los `horizonte_salida` meses siguientes. Las ventanas se construyen en orden temporal y no se barajan.

Estrategia	Ventana	Ventanas totales	Ajuste	Validación
Recursiva	12	135	115	20
Recursiva	24	123	105	18
Directa	12	73	62	11
Directa	24	61	52	9

El tamaño de muestra es la restricción dominante del laboratorio. Con 147 observaciones mensuales, la estrategia directa dispone de 73 ventanas con ventana de 12 meses, una cifra baja para una red recurrente, y eso acota tanto la profundidad de la arquitectura como el tamaño de la rejilla.

Estrategias de pronóstico

El horizonte de 63 meses se cubre de dos formas, y el laboratorio las compara en lugar de suponer cuál conviene.

La estrategia recursiva entrena un modelo de un paso, **Dense(1)**, y realimenta cada predicción como último elemento de la ventana para producir la siguiente. Aprovecha las 135 ventanas disponibles, pero acumula error a lo largo de 63 iteraciones: cualquier sesgo inicial se propaga y la trayectoria tiende a aplanarse.

La estrategia directa entrena un modelo con salida **Dense(63)** que emite el horizonte completo en una sola pasada. No acumula error, pero aprende 63 salidas con apenas 73 ventanas y multiplica los parámetros de la capa densa.

Validación y criterio de selección

La validación es el último 15 % de las ventanas, tomado en orden temporal y sin barajar, de modo que el modelo se evalúa siempre sobre meses posteriores a los que vio. El entrenamiento usa Adam con tasa de aprendizaje 1e-3, pérdida mse y hasta 300 épocas, con **EarlyStopping** de paciencia 20 sobre **val_loss** y restauración de los mejores pesos. Se registra el número de épocas efectivas de cada combinación.

El error de validación se calcula en viajeros, no en escala escalada, y con la misma mecánica que se usará en el test:

- En la estrategia recursiva se toman los meses previos al tramo de validación como contexto y se pronostica recursivamente el tramo completo. Así se tunea contra el error multi-paso, que es el objetivo real, y no contra el error a un paso, que siempre parece bueno.
- En la estrategia directa se evalúan todas las ventanas de validación, cada una con sus 63 salidas, y el error se calcula sobre el conjunto completo de predicciones revertidas.

Se selecciona la combinación de menor **rmse_val**; si ninguna converge, la de menor **val_loss**. Este **rmse_val** solo ordena configuraciones **dentro** de una misma estrategia, porque el tramo evaluado no es el mismo en las dos: veinte meses consecutivos en la recursiva frente a once ventanas de 63 valores en la directa. La comparación entre estrategias se resuelve hasta el conjunto de prueba, con las mismas métricas del Laboratorio 1.

La configuración ganadora se reentrena sobre las 147 observaciones completas, ya sin partición de validación, fijando las épocas en las efectivas registradas durante el tuneo. Ese modelo produce el pronóstico de los 63 meses de prueba.

Rejilla de hiperparámetros

La rejilla es idéntica para las dos series y las dos estrategias, y se recorre por producto cartesiano con **itertools**, igual que la rejilla SARIMA del Laboratorio 1.

Hiperparámetro	Valores
Ventana	12, 24
Unidades por capa	32, 64
Capas LSTM	1, 2
Dropout	0.0, 0.2
Tasa de aprendizaje	1e-3
Tamaño de lote	16

Son 16 combinaciones por estrategia, 32 por serie y 64 ajustes en el laboratorio, muy por encima del mínimo de dos configuraciones distintas que pide el enunciado. Dos de ellas se destacan como referencias de arquitectura: la LSTM de una capa con 32 unidades y sin dropout, que es el modelo más pequeño, y la apilada de dos capas con 64 unidades y dropout 0.2, que es el más grande.

Las ventanas de 12 y 24 meses cubren uno y dos ciclos estacionales completos, la dimensión relevante en series mensuales de turismo. El resto de valores se mantuvo acotado por dos razones: la muestra es pequeña y arquitecturas mayores sobreajustan, y TensorFlow no dispone de GPU en Windows nativo desde la versión 2.11, de modo que todo el laboratorio corre en CPU. Cada ajuste toma entre ocho y doce segundos según la ventana y el número de capas, lo que sitúa cada rejilla completa en el orden de tres minutos.

Reproducibilidad

El enunciado exige que los resultados sean reproducibles. Antes de cada ajuste se fija la semilla 42 con `keras.utils.set_random_seed`, que cubre los generadores de Python, NumPy y TensorFlow, y se activa `tf.config.experimental.enable_op_determinism()`, que elimina el no determinismo de las operaciones sobre CPU. La sesión de Keras se limpia entre combinaciones para que los grafos no se acumulen a lo largo de la rejilla.

Con eso, dos ejecuciones seguidas de `notebooks/08_lstm_preparacion.ipynb` devuelven exactamente los mismos valores de `val_loss`, `mae_val`, `rmse_val` y épocas efectivas. Ese cuaderno documenta el protocolo, verifica los conteos de ventanas y comprueba la ausencia de fuga de información antes de que los cuadernos 09 y 10 ejecuten la rejilla completa.

2. Modelado LSTM de la serie total

La serie total es la agregada de referencia del estudio y la peor predicha del Laboratorio 1, con un MAPE de 58.11 % en su mejor modelo. Todo lo que sigue está en `notebooks/09_lstm_total.ipynb`, sobre el protocolo descrito en la sección 1 y con el split del Laboratorio 1 sin modificar: entrenamiento de enero de 2009 a marzo de 2021, 147 meses, y prueba de abril de 2021 a junio de 2026, 63 meses.

La rejilla ejecutada y su costo

Se recorrieron las 16 combinaciones de la rejilla para cada una de las dos estrategias, 32 ajustes en total. La rejilla completa costó 1.9 minutos de CPU, entre 2.8 y 5.8 segundos por ajuste, y el detalle de las 32 filas quedó en `resultados/lstm_tuneo_total.csv`.

Ninguna combinación falló. Las 32 entrenaron hasta que **EarlyStopping** las detuvo, restauraron sus mejores pesos y produjeron un pronóstico finito; el bloque de captura de excepciones de `grid_lstm` no se activó ni una vez y no hay filas con `rmse_val` infinito. Tampoco hubo pronósticos negativos ni valores nulos.

Lo que sí hubo fue estancamiento, y conviene reportarlo porque afecta la lectura de los resultados. Las 16 combinaciones de la estrategia recursiva pararon entre las épocas 21 y 25, y como la paciencia del **EarlyStopping** es de 20 épocas, eso significa que su mejor época de validación estuvo entre la 1 y la 5. El modelo de un paso alcanza su mejor error de validación casi de inmediato y después solo mejora sobre el entrenamiento. Las combinaciones directas se comportaron mejor: épocas efectivas entre 28 y 78, con la mejor época entre la 8 y la 58.

Configuraciones seleccionadas

Estrategia	Ventana	Unidades	Capas	Dropout	Épocas efectivas	Parámetros	MAE val.	RMSE val.
Recursiva	24	64	1	0.2	24	16,961	121,320	149,716
Directa	24	64	2	0.0	42	54,015	97,483	130,075

Las dos ganadoras coinciden en la ventana de 24 meses y en las 64 unidades por capa, y se separan en la profundidad y la regularización: la recursiva prefiere una sola capa con dropout de 0.2 y la directa dos capas sin dropout. Los dos valores de `rmse_val` de la tabla no son comparables entre sí, porque cada estrategia valida sobre un tramo distinto; la comparación entre estrategias se resuelve en el test.

Dentro de cada estrategia, en cambio, la dispersión sí es informativa. Entre la mejor y la peor configuración recursiva hay un 39.9 % de diferencia en `rmse_val`, de 149,716 a 209,463 viajeros. Entre la mejor y la peor directa hay un 15.3 %, de 130,075 a 149,939. La elección de hiperparámetros importa más cuando el error se realimenta 63 veces.

Las dos arquitecturas de referencia

El enunciado pide al menos dos modelos con configuraciones distintas por serie. La rejilla contiene 16 por estrategia, y dos de ellas delimitan el rango de arquitecturas exploradas: la LSTM de una capa con 32 unidades y sin dropout, la más pequeña, y la apilada de dos capas con 64 unidades y dropout 0.2, la más grande.

Estrategia	Arquitectura	Ventana	Parámetros	RMSE val.
Recursiva	1 capa, 32 unidades, dropout 0.0	24	4,385	187,605

Estrategia	Arquitectura	Ventana	Parámetros	RMSE val.
Rekursiva	2 capas, 64 unidades, dropout 0.2	24	49,985	155,304
Directa	1 capa, 32 unidades, dropout 0.0	24	6,431	136,507
Directa	2 capas, 64 unidades, dropout 0.2	24	54,015	132,213

El contraste entre las dos arquitecturas depende de la estrategia. En la recursiva la arquitectura mayor mejora el error de validación en 17 %; en la directa la diferencia baja a 3 %. La salida **Dense(63)** ya concentra la mayor parte de la capacidad del modelo directo, y agregar profundidad recurrente aporta poco.

Qué hiperparámetro movió el error

La comparación toma la mediana de **rmse_val** entre los dos valores de cada hiperparámetro, dentro de cada estrategia, para que un solo ajuste afortunado no defina la lectura.

Estrategia	Hiperparámetro	Valor bajo	RMSE val.	Valor alto	RMSE val.	Brecha
Rekursiva	Unidades	32	180,907	64	155,652	16.2 %
Rekursiva	Dropout	0.0	181,810	0.2	162,257	12.1 %
Rekursiva	Capas	1	175,112	2	156,732	11.7 %
Rekursiva	Ventana	12	162,257	24	171,988	6.0 %
Directa	Ventana	12	138,634	24	131,920	5.1 %
Directa	Dropout	0.0	135,615	0.2	139,625	3.0 %
Directa	Unidades	32	138,971	64	135,615	2.5 %
Directa	Capas	1	137,244	2	136,215	0.8 %

En la estrategia recursiva manda el número de unidades, con una brecha de 16.2 % a favor de 64, seguido del dropout, 12.1 % a favor de 0.2, y del número de capas, 11.7 % a favor de dos. Los tres apuntan en la misma dirección: un modelo de un paso que se realimentará 63 veces necesita capacidad y regularización, porque cualquier sesgo sistemático se acumula a lo largo del horizonte. La ventana es el único hiperparámetro cuya mediana favorece al valor bajo, 12 meses, aunque la configuración ganadora usa 24; la brecha de 6.0 % en la mediana convive con el mejor resultado individual en el otro extremo, señal de que la ventana interactúa con el resto y no domina por sí sola.

En la estrategia directa el orden se invierte y todas las brechas se achican. Manda la ventana, con 5.1 % a favor de 24 meses, y el resto queda por debajo del 3 %. El número de capas es prácticamente irrelevante, con 0.8 %. Con la salida completa emitida en una sola pasada, lo determinante es cuánta historia ve la red, no cuán profunda es.

La figura muestra las cinco mejores de cada estrategia y no las diez mejores del conjunto, porque **rmse_val** no es comparable entre estrategias: la recursiva se valida sobre veinte meses consecutivos y la directa sobre once ventanas de 63 valores cada una. Un ranking global mezclaría dos escalas distintas.

Curvas de entrenamiento

Las dos curvas describen problemas distintos. En la recursiva la pérdida de validación toca su mínimo en la época 4, en 0.129, y a partir de ahí se queda plana mientras la de entrenamiento sigue bajando hasta 0.006, más de veinte veces menor. Es sobreajuste puro desde la quinta época: el modelo memoriza las 105 ventanas




Figure 1: Cinco mejores configuraciones por estrategia




Figure 2: Curvas de pérdida del mejor modelo por estrategia

de ajuste sin mejorar su capacidad de generalizar. En la directa la validación baja durante una docena de épocas hasta 0.068 y a partir de ahí apenas se mueve, con su mínimo formal en la época 22, mientras la de entrenamiento termina en 0.004; la brecha final es de 16 veces en lugar de 22 y hay más aprendizaje real antes del estancamiento.

La lectura práctica es que el **EarlyStopping** con paciencia 20 hizo su trabajo en las dos estrategias, y que ampliar el número máximo de épocas no habría cambiado nada: ninguna de las 32 combinaciones se acercó al tope de 300.

Predicción sobre el test

Cada configuración ganadora se reentrenó sobre las 147 observaciones completas, sin partición de validación, con las épocas fijadas en las efectivas del tuneo, y ese modelo produjo los 63 meses de prueba. Las dos predicciones están en `resultados/predicciones/total_lstm_recursoivo.csv` y `total_lstm_directo.csv`.

Modelo	MAE	RMSE	MAPE	Media pronosticada	Sesgo medio
lstm_recursoivo	143,303	164,706	46.90 %	133,712	−142,973
lstm_directo	76,957	100,290	33.76 %	232,356	−44,329

El test real promedia 276,685 viajeros mensuales. La estrategia directa gana en las tres métricas: 46.30 % menos MAE, 39.11 % menos RMSE y 13.13 puntos porcentuales menos de MAPE. La diferencia es demasiado grande para atribuirle al azar del ajuste y no se explica por la muestra, porque la estrategia directa entrena con menos de la mitad de las ventanas, 61 contra 123 con ventana de 24 meses. Se explica por el sesgo: la recursiva subestima 62 de los 63 meses, con un error medio de −142,973 viajeros, un 51.7 % del nivel medio del test, mientras que la directa subestima 45 de 63, con −44,329, un 16.0 %. Realimentar 63 veces un modelo entrenado con datos que terminan en el punto más bajo de la pandemia arrastra el pronóstico hacia ese nivel, y ni la ventana de 24 meses ni las 64 unidades lo evitan. La acumulación de error pesó más que el tamaño de la muestra.




Figure 3: Predicciones LSTM de la serie total

¿Reproduce la recuperación pospandemia?

Esta es la pregunta que el Laboratorio 1 dejó abierta, porque los cinco modelos anteriores subestimaron la recuperación sin excepción.

Año	Test real	lstm_directo	Diferencia	lstm_recursoivo	Diferencia
2021 (abr-dic)	110,282	198,112	+79.6 %	81,033	−26.5 %
2022	359,680	213,867	−40.5 %	112,870	−68.6 %
2023	270,726	236,230	−12.7 %	136,809	−49.5 %
2024	299,490	263,214	−12.1 %	151,202	−49.5 %
2025	299,770	263,777	−12.0 %	159,088	−46.9 %
2026 (ene-jun)	280,439	188,390	−32.8 %	162,489	−42.1 %

La estrategia recursiva no la reproduce, y falla igual que los modelos del Laboratorio 1: su trayectoria es una curva monótona que sube de 64,931 a 163,165 viajeros y se detiene ahí, sin estacionalidad visible, entre un 47 % y un 69 % por debajo del real en los cuatro años completos. Su correlación con el test es de 0.507, de modo que acierta la dirección general y nunca el nivel.

La estrategia directa sí la reproduce parcialmente, y es el primer modelo de esta serie en las dos entregas que lo consigue. Emite un perfil estacional con picos y valles, alcanza el nivel correcto desde 2023 y se estabiliza en un error anual de entre 12.0 % y 12.7 % en el tramo 2023-2025. Sus dos zonas de error son los extremos del horizonte: sobreestima 2021 en 79.6 %, cuando la serie real todavía estaba deprimida, y se queda 40.5 % corta en el rebote de 2022, el año del pico de 526,190 viajeros que ningún modelo entrenado hasta marzo de 2021 podía anticipar.

Lectura honesta de la calidad predictiva

El resultado es una mejora sustancial y sigue siendo un pronóstico de calidad limitada. Un MAPE de 33.76 % significa que el error típico es de un tercio del valor real: sirve para dimensionar órdenes de magnitud y para planificación agregada, no para asignación fina de capacidad sin intervalos amplios ni reentrenamiento periódico.

Tres reservas que conviene dejar escritas:

La primera es que el modelo no captura el pico de 2022 y ese es justamente el evento de mayor interés operativo del periodo. Su acierto está en el régimen estable posterior, no en la transición.

La segunda es que la mejora frente al Laboratorio 1 depende de una coincidencia favorable entre lo que el modelo aprendió y lo que ocurrió. La LSTM directa reconstruye el patrón prepandemia en lugar de prolongar el nivel deprimido del final del entrenamiento, y el test resultó ser un retorno a niveles prepandemia. Si la serie no se hubiera recuperado, esa misma propiedad habría producido una sobreestimación sistemática y el orden del ranking sería el inverso.

La tercera es de tamaño de muestra. La estrategia ganadora estima 54,015 parámetros con 61 ventanas de entrenamiento, y sus curvas muestran sobreajuste desde la época doce. El resultado del test es sólido porque el protocolo nunca vio ese tramo, pero la varianza de la estimación es alta y no debería leerse como una medida precisa de la capacidad de la arquitectura.

3. Modelado LSTM de la vía aérea

La vía aérea es la serie mejor predicha del Laboratorio 1, con un MAPE de 35.62 % usando SES, la vía menos volátil (CV de 0.216) y la de recuperación más rápida: alcanzó el 80 % del nivel de 2019 en diciembre de 2021. También es la serie donde 18 de las 36 especificaciones SARIMA se descartaron por pronóstico explosivo, así que la vara a superar es la más alta de las siete series y el fracaso de los modelos paramétricos lineales ya está documentado. Todo lo que sigue está en `notebooks/10_lstm_via_aerea.ipynb`, sobre el protocolo descrito en la sección 1 y con el split del Laboratorio 1 sin modificar: entrenamiento de enero de 2009 a marzo de 2021, 147 meses, y prueba de abril de 2021 a junio de 2026, 63 meses.

La rejilla ejecutada y su costo

Se recorrieron las 16 combinaciones de la rejilla para cada una de las dos estrategias, 32 ajustes en total. La rejilla completa costó 2.4 minutos de CPU, entre 3.2 y 9.3 segundos por ajuste, y el detalle de las 32 filas quedó en `resultados/lstm_tuneo_via_aerea.csv`.

Ninguna combinación falló. Las 32 entrenaron hasta que **EarlyStopping** las detuvo, restauraron sus mejores pesos y produjeron un pronóstico finito; no hay filas con `rmse_val` infinito ni pronósticos negativos o nulos.

El estancamiento temprano de la estrategia recursiva se repite en esta serie: las 16 combinaciones pararon entre las épocas 21 y 26, así que con una paciencia de 20 épocas su mejor época de validación estuvo entre la 1 y la 6. La estrategia directa volvió a comportarse mejor: épocas efectivas entre 29 y 59, con la mejor época estimada entre la 9 y la 39.

Configuraciones seleccionadas

Estrategia	Ventana	Unidades	Capas	Dropout	Épocas efectivas	Parámetros	MAE val.	RMSE val.
Recursiva	12	32	1	0.0	26	4,385	39,360	45,464
Directa	24	32	2	0.0	49	14,751	25,853	38,698

Las dos ganadoras coinciden en 32 unidades por capa y en dropout 0.0, y se separan en la ventana y la profundidad: la recursiva prefiere la ventana corta de 12 meses con una sola capa, y la directa la ventana larga de 24 meses con dos capas. A diferencia de la serie total, ninguna de las dos estrategias eligió aquí la configuración más grande de la rejilla (64 unidades, dropout 0.2): la vía aérea es más regular y no exige esa capacidad extra.

Dentro de cada estrategia la dispersión sigue siendo informativa. Entre la mejor y la peor configuración recursiva hay un 50.6 % de diferencia en `rmse_val`, de 45,464 a 68,450 viajeros. Entre la mejor y la peor directa hay un 33.5 %, de 38,698 a 51,648.

Las dos arquitecturas de referencia

El enunciado pide al menos dos modelos con configuraciones distintas por serie. La rejilla contiene 16 por estrategia; estas dos delimitan el rango explorado: la LSTM de una capa con 32 unidades y sin dropout, la más pequeña, y la apilada de dos capas con 64 unidades y dropout 0.2, la más grande.

Estrategia	Ventana	Arquitectura	Parámetros	RMSE val.
Recursiva	12	1 capa, 32 unidades, dropout 0.0	4,385	45,464
Recursiva	12	2 capas, 64 unidades, dropout 0.2	49,985	58,576
Recursiva	24	1 capa, 32 unidades, dropout 0.0	4,385	68,450
Recursiva	24	2 capas, 64 unidades, dropout 0.2	49,985	50,901
Directa	12	1 capa, 32 unidades, dropout 0.0	6,431	41,248

Estrategia	Ventana	Arquitectura	Parámetros	RMSE val.
Directa	12	2 capas, 64 unidades, dropout 0.2	54,015	44,593
Directa	24	1 capa, 32 unidades, dropout 0.0	6,431	44,508
Directa	24	2 capas, 64 unidades, dropout 0.2	54,015	45,875

Aquí el contraste no es monótono como en la serie total. En la estrategia recursiva la arquitectura grande pierde con ventana de 12 meses (28.8 % peor) pero gana con ventana de 24 (34.5 % mejor): el efecto de la capacidad depende de cuánta historia ve la red, no solo de su tamaño. En la estrategia directa la arquitectura pequeña gana en las dos ventanas, aunque por márgenes moderados: 8.1 % con ventana de 12 y 3.1 % con ventana de 24. Para esta serie, más parámetros no compran de forma consistente mejor validación.

Qué hiperparámetro movió el error

La comparación toma la mediana de `rmse_val` entre los dos valores de cada hiperparámetro, dentro de cada estrategia, para que un solo ajuste afortunado no defina la lectura.

Estrategia	Hiperparámetro	Valor bajo	RMSE val.	Valor alto	RMSE val.	Brecha
Recursiva	Capas	1	56,641	2	49,337	14.8 %
Recursiva	Dropout	0.0	48,979	0.2	51,233	4.6 %
Recursiva	Ventana	12	49,155	24	51,233	4.2 %
Recursiva	Unidades	32	49,337	64	50,461	2.3 %
Directa	Dropout	0.0	42,102	0.2	45,234	7.4 %
Directa	Capas	1	43,629	2	45,072	3.3 %
Directa	Ventana	12	44,754	24	43,963	1.8 %
Directa	Unidades	32	44,712	64	43,963	1.7 %

En la estrategia recursiva el factor dominante es el número de capas, con 14.8 % a favor de dos capas; le siguen el dropout, 4.6 % a favor de 0.0, y la ventana, 4.2 % a favor de 12 meses. El orden es distinto al de la serie total, donde mandaban las unidades: aquí una segunda capa recurrente ayuda más que ensanchar la primera.

En la estrategia directa manda el dropout, con 7.4 % a favor de 0.0, y el resto queda por debajo del 3.5 %. La regularización explícita no aporta en una serie ya de por sí menos volátil: con 147 observaciones y una serie estable, el dropout resta capacidad sin compensarla con menos sobreajuste.

La figura muestra las cinco mejores de cada estrategia y no las diez mejores del conjunto, porque `rmse_val` no es comparable entre estrategias: la recursiva se valida sobre un tramo consecutivo y la directa sobre varias ventanas de 63 valores cada una.

Curvas de entrenamiento

Las dos curvas describen el mismo problema en escalas distintas. En la recursiva la pérdida de validación toca su mínimo en la época 6, en 0.124, y a partir de ahí se queda plana en 0.137 mientras la de entrenamiento sigue bajando hasta 0.0006, más de doscientas veces menor: sobreajuste puro desde la sexta época. En la directa la validación baja durante unas 28 épocas hasta 0.058 y ahí se estabiliza, mientras la de entrenamiento termina en 0.0025; hay más aprendizaje real antes del estancamiento, igual que en la serie total.

El **EarlyStopping** con paciencia 20 volvió a hacer su trabajo en las dos estrategias: ninguna de las 32 combinaciones se acercó al tope de 300 épocas.

Predicción sobre el test

Cada configuración ganadora se reentrenó sobre las 147 observaciones completas, sin partición de validación, con las épocas fijadas en las efectivas del tuneo, y ese modelo produjo los 63 meses de




Figure 4: Cinco mejores configuraciones por estrategia




Figure 5: Curvas de pérdida del mejor modelo por estrategia

prueba. Las dos predicciones están en `resultados/predicciones/via_aerea_lstm_recurativo.csv` y `via_aerea_lstm_directo.csv`.

Modelo	MAE	RMSE	MAPE	Media pronosticada	Sesgo medio	Correlación con test
lstm_recurativo	31,638	37,766	31.14 %	63,494	−31,110	0.391
lstm_directo	22,635	29,623	24.93 %	85,409	−9,196	−0.150

El test real promedia 94,605 viajeros mensuales. La estrategia directa gana en las tres métricas: 28.5 % menos MAE, 21.6 % menos RMSE y 6.21 puntos porcentuales menos de MAPE. La brecha entre estrategias es menor que en la serie total, porque aquí la recursiva ya parte de un sesgo más chico, pero el orden es el mismo: la salida completa en una sola pasada evita la acumulación de error de la recursiva a lo largo de 63 pasos.

El sesgo agregado confirma la historia: −32.9 % del nivel medio en la recursiva, que subestima 59 de los 63 meses, contra −9.7 % en la directa, que subestima 34 de 63. Pero la correlación negativa de la directa es la advertencia que el MAE y el RMSE no muestran por sí solos: el modelo gana en error agregado porque su nivel medio está cerca del real, no porque reproduzca la dirección del movimiento mes a mes. Esto se desarrolla en la sección siguiente.




Figure 6: Predicciones LSTM de la vía aérea

¿Reproduce la recuperación pospandemia?

La vía aérea fue la vía de recuperación más rápida en el Laboratorio 1. La tabla anual muestra si el LSTM captura esa dinámica o solo su nivel promedio.

Año	Test real	lstm_recurativo	lstm_directo
2021 (abr-dic)	65,700	37,905	82,331
2022	117,232	56,206	85,084
2023	82,153	66,793	89,985
2024	95,279	71,494	96,849
2025	99,081	73,403	87,270
2026 (ene-jun)	107,307	74,041	54,920

La estrategia recursiva falla igual que en la serie total: una trayectoria monótona creciente que nunca despegue de los 74,000 viajeros, muy por debajo del pico de 117,232 en 2022 y del nivel de 2026. Su correlación de 0.391 con el test viene de la tendencia general al alza, no de acertar niveles.

La estrategia directa cuenta una historia distinta a la de la serie total. Sobreestima 2021 en 25.3 % (82,331 contra 65,700, el año todavía deprimido), y desde ahí se acerca al nivel real en 2023 y 2024, dentro de un 10 % de diferencia, pero vuelve a alejarse al final: subestima 2025 en 11.9 % y colapsa en el primer semestre de 2026, con 54,920 contra 107,307, un 48.8 % por debajo. Ese colapso final es lo que produce la correlación negativa pese al buen MAE agregado: el modelo aprendió un nivel medio razonable para el tramo intermedio de la serie, pero no anticipa que la recuperación siguiera acelerando hacia 2026.

Lectura honesta de la calidad predictiva

El LSTM directo mejora la mejor referencia del Laboratorio 1 (SES) en las tres métricas: 37.3 % menos MAE, 28.4 % menos RMSE y 10.68 puntos porcentuales menos de MAPE, de 35.62 % a 24.93 %. Es la primera vez en las dos entregas que un modelo de la vía aérea baja del 25 % de MAPE. Pero conviene dejar tres reservas escritas, porque las métricas de error agregado esconden más de lo que muestran en esta serie.

La primera es la correlación negativa de la estrategia ganadora con el test, -0.150 . El modelo bate a SES en MAE y RMSE porque su nivel medio (85,409) está más cerca del real (94,605) que el de la recursiva, no porque reproduzca la dirección del movimiento mes a mes. Un pronóstico que acertara la dinámica de la serie tendría correlación positiva incluso con métricas de error algo peores; este es el caso inverso.

La segunda es el colapso en el tramo final: 48.8 % por debajo del real en el primer semestre de 2026, justo el periodo más reciente y el de mayor interés operativo. El modelo aprendió el nivel de 2023-2024 y lo proyectó hacia adelante, sin anticipar que la recuperación siguiera acelerando.

La tercera es de tamaño de muestra, igual que en la serie total: la estrategia ganadora estima 14,751 parámetros con relativamente pocas ventanas de entrenamiento, y su curva de validación se estabiliza temprano, en la época 28. El resultado del test es sólido porque el protocolo nunca vio ese tramo, pero la varianza de la estimación es alta y el buen MAPE de esta serie no debería leerse como evidencia de que el LSTM directo entiende la trayectoria de la vía aérea mejor de lo que entiende la de la serie total: en ambas, gana por cancelación de errores en direcciones opuestas más que por seguimiento fiel de la dinámica.

4. Análisis comparativo: LSTM contra los modelos del Laboratorio 1

Esta sección responde el punto 1.4 del enunciado. El desarrollo está en `notebooks/11_comparativo_lstm.ipynb`, que no reentrena nada: lee las métricas de los cuadernos 09 y 10, las métricas del Laboratorio 1 en `resultados/metricas_modelos.csv` y las predicciones guardadas en `resultados/predicciones/`, y deja dos tablas consolidadas, `metricas_lstm.csv` y `comparativo_lstm_lab1.csv`.

Criterio de comparación

Las dos familias se comparan sobre exactamente el mismo conjunto de prueba, los 63 meses de abril de 2021 a junio de 2026, con las mismas tres métricas y calculadas por la misma función, `src.evaluacion.metricas`, que se usó en el Laboratorio 1. MAE y RMSE van en viajeros y MAPE en porcentaje. El modelo ganador de cada serie es el de menor suma de los rangos de MAE y RMSE, el mismo criterio con el que el laboratorio anterior eligió entre SARIMA, Holt-Winters, SES, seasonal naive y Prophet.

Las tres métricas se reportan juntas porque miden cosas distintas. El MAE promedia el error en viajeros y trata todos los meses por igual; el RMSE penaliza los errores grandes, que en estas series se concentran en los picos estacionales y en el rebote de 2022; el MAPE normaliza por el nivel real y es la única de las tres comparable entre series de distinto volumen. Un modelo que ganara en una sola de ellas exigiría una discusión; en los resultados de abajo no hace falta, porque el ganador lo es en las tres.

Ninguna de las dos familias vio el conjunto de prueba durante el ajuste. En el Laboratorio 1 las órdenes SARIMA se eligieron por AIC sobre el entrenamiento y los demás modelos se ajustaron solo con esas 147 observaciones; en este laboratorio la rejilla LSTM se tuneó contra un tramo de validación tomado del final del entrenamiento. La comparación es limpia en los dos sentidos.

Por qué no se usan AIC ni BIC

El enunciado del Laboratorio 1 pedía comparar modelos ARIMA por AIC y BIC, y aquí esos criterios no aparecen por dos razones.

La primera es que no están definidos para una red neuronal. AIC y BIC se construyen sobre la verosimilitud maximizada del modelo, y una LSTM entrenada por descenso de gradiente sobre un error cuadrático no tiene una verosimilitud que reportar ni un número de parámetros efectivos interpretable de la misma forma; los 54,015 parámetros del modelo directo de la serie total o los 14,751 del de vía aérea no son comparables con los 8 o 10 coeficientes de un SARIMA.

La segunda es que, aun si estuvieran definidos, no serían el criterio adecuado. Los dos miden ajuste dentro de muestra penalizado por complejidad, no capacidad predictiva fuera de muestra, y el Laboratorio 1 documentó el caso extremo: el SARIMA(2,1,2)(0,1,1)₁₂ de vía aérea fue el de menor AIC de su rejilla, 169.72, y produjo el peor pronóstico a 63 pasos de esa serie, con un MAE de 73,966 frente a los 36,109 de SES. Elegir por AIC habría empeorado el resultado. Toda la comparación de esta sección se resuelve, por eso, sobre el conjunto de prueba.

Resultados

Serie	Familia	Mejor modelo	MAE	RMSE	MAPE
Total	Lab 1	SES	175,088	194,791	58.11 %
Total	LSTM	lstm_directo	76,957	100,290	33.76 %
Vía aérea	Lab 1	SES	36,109	41,368	35.62 %
Vía aérea	LSTM	lstm_directo	22,635	29,623	24.93 %

El LSTM de estrategia directa es el mejor modelo global de las dos series considerando las dos familias, y lo es en las tres métricas a la vez, así que el criterio de desempate no llega a aplicarse. Queda marcado como `mejor_global` en `comparativo_lstm_lab1.csv`.




Figure 7: Mejor modelo de cada familia sobre los 63 meses de prueba

Serie total

Cuál de las dos estrategias LSTM predijo mejor

La estrategia directa, con `Dense(63)`, gana con claridad a la recursiva.

Modelo	MAE	RMSE	MAPE
<code>lstm_directo</code>	76,957	100,290	33.76 %
<code>lstm_recurso</code>	143,303	164,706	46.90 %
Margen	46.30 %	39.11 %	13.13 pp

El margen es demasiado grande para atribuirlo al azar del ajuste, y va en contra de la ventaja muestral: la estrategia recursiva entrena con 123 ventanas y la directa con 61, la mitad. Lo que inclina la balanza es el sesgo acumulado. La recursiva subestima 62 de los 63 meses, con un error medio de $-142,973$ viajeros, el 51.7 % del nivel medio del test; la directa subestima 45 de 63, con $-44,329$, el 16.0 %. Realimentar 63 veces un modelo de un paso entrenado sobre datos que terminan en el punto más bajo de la pandemia arrastra toda la trayectoria hacia ese nivel.

Conviene señalar de dónde no sale esta conclusión. Los `rmse_val` del tuneo, 149,716 en la recursiva y 130,075 en la directa, apuntan en la misma dirección, pero no sirven como argumento: se miden sobre tramos distintos, veinte meses consecutivos en un caso y once ventanas de 63 valores en el otro, y solo ordenan configuraciones dentro de una misma estrategia. La comparación entre estrategias se resuelve únicamente en el test.

Si son mejores que los del Laboratorio 1

Sí, y por el mayor margen registrado en las dos entregas para esta serie.

Comparación	MAE	RMSE	MAPE
SES, Lab 1	175,088	194,791	58.11 %
<code>lstm_directo</code>	76,957	100,290	33.76 %
Mejora	56.05 %	48.51 %	24.35 pp

Para dimensionar el salto: en el Laboratorio 1, la distancia entre SES y el segundo mejor modelo de esta serie, Holt-Winters, era de 21,868 viajeros de MAE. Aquí la distancia entre SES y el LSTM directo es de 98,131,

cuatro veces y media mayor. No es una diferencia que exija matices ni que pueda explicarse por la semilla: es un cambio de régimen en la calidad del pronóstico. Y no depende de haber elegido bien la estrategia, porque incluso la perdedora supera a SES: la recursiva registra 143,303 de MAE y 164,706 de RMSE, por debajo de los 175,088 y 194,791 de SES.

El LSTM directo es, en consecuencia, el mejor modelo global de la serie total entre las dos familias, y el primero de esta serie, en las dos entregas, que baja del 50 % de MAPE.




Figure 8: Trayectorias de la serie total sobre el test

La figura muestra por qué. SES es una recta horizontal en 105,145 viajeros durante 63 meses: por construcción prolonga el último nivel suavizado del entrenamiento, que es un mes de pandemia. El SARIMA(2,1,2)(1,1,1)₁₂ es peor todavía, porque a un nivel inicial bajo le suma una tendencia estimada que apunta hacia abajo, y termina rozando el cero desde 2023; su correlación con el test es de -0.597 , es decir que se mueve de forma sistemática al revés que la serie real. El LSTM directo es el único de los tres que traza un perfil estacional con el nivel correcto, y en el tramo 2023-2025 se superpone con el test en buena parte de los meses.

Ahora bien, la ventaja no es uniforme a lo largo del horizonte, y decirlo importa tanto como reportar el promedio. El LSTM directo sobreestima 2021 en 79.6 %, con 198,112 viajeros mensuales frente a 110,282 reales, mientras que SES, por estar anclado en el nivel deprimido, acierta ese tramo mucho mejor. La ventaja del LSTM se construye de 2022 en adelante y se estabiliza en un error anual de entre 12.0 % y 12.7 % en 2023-2025. Un usuario interesado solo en los primeros doce meses del horizonte no habría obtenido de esta comparación la misma conclusión que uno interesado en los 63.

Vía aérea

La vara aquí es más alta que en la serie total. SES parte de un MAPE de 35.62 % en esta serie, casi el mismo 33.76 % que el LSTM directo alcanzó en la agregada, así que una mejora del orden de la anterior no estaba dada por descontada. El LSTM gana de todas formas, pero con márgenes más chicos y con una reserva de fondo que la serie total no tiene.

Cuál de las dos estrategias LSTM predijo mejor

La directa, otra vez, y otra vez en las tres métricas.

Modelo	MAE	RMSE	MAPE
lstm_directo	22,635	29,623	24.93 %
lstm_recurso	31,638	37,766	31.14 %
Margen	28.46 %	21.56 %	6.21 pp

El margen es aproximadamente la mitad del de la serie total, y la razón está en el punto de partida de la recursiva. Su sesgo medio aquí es de $-31,110$ viajeros, el 32.9 % del nivel medio del test, contra el 51.7 % que acumulaba en la serie agregada. La vía aérea es la menos volátil de las siete series, con un CV de 0.216 frente a 0.335 de la total, y fue la de recuperación más rápida: alcanzó el 80 % del nivel de 2019 en diciembre de 2021. Sobre una serie más plana y con menos distancia por recorrer, aplanar el pronóstico cuesta menos error.

El orden entre estrategias, en cambio, es el mismo en las dos series y por el mismo motivo: realimentar 63 veces un modelo de un paso arrastra la trayectoria hacia el nivel del último mes de entrenamiento, que es un mes de pandemia.

Si son mejores que los del Laboratorio 1

Sí, pero el margen es de otro orden que en la serie total.

Comparación	MAE	RMSE	MAPE
SES, Lab 1	36,109	41,368	35.62 %
lstm_directo	22,635	29,623	24.93 %
Mejora	37.31 %	28.39 %	10.68 pp

Es la primera vez en las dos entregas que un modelo de esta serie baja del 25 % de MAPE, y la mejora es consistente en las tres métricas. Conviene ponerla en perspectiva con el mismo criterio que se usó arriba. En la serie total el salto de SES al LSTM directo, 98,131 viajeros de MAE, era cuatro veces y media la distancia que separaba a SES del segundo mejor modelo del Laboratorio 1. Aquí el salto es de 13,474 y esa distancia era de 11,935: apenas 1.13 veces. En la serie agregada el LSTM abre una categoría nueva; en la vía aérea se coloca un escalón por delante del mejor modelo anterior, dentro del rango de variación que ya existía entre los modelos de esa entrega.

Como en la serie total, la estrategia perdedora también supera a SES: la recursiva registra 31,638 de MAE y 37,766 de RMSE, por debajo de los 36,109 y 41,368 de SES.

La reserva que las métricas de error no muestran

La figura explica por qué el buen MAPE de esta serie no debe leerse como un buen seguimiento de la serie. SES es una recta en 60,160 viajeros, exactamente el último mes del entrenamiento, y el SARIMA(2,1,2)(0,1,1)₁₂, el de menor AIC de su rejilla, se queda en una media de 20,639 y subestima los 63 meses del horizonte. Contra esas dos referencias, cualquier modelo con el nivel correcto gana.

Y el nivel del LSTM directo es correcto: promedia 85,409 viajeros contra 94,605 del test, un sesgo de -9.7 %, y subestima 34 de 63 meses, casi la mitad. El problema es la amplitud. Su CV es de 0.157 frente a 0.244 del test, de modo que comprime a menos de dos tercios la variación real, y su correlación con el test es de -0.150 . Gana en MAE y RMSE por cancelación de errores en direcciones opuestas, no porque reproduzca la dinámica mes a mes.

Los dos tramos donde eso se ve son los extremos del horizonte. En el pico de diciembre de 2022 el test llega a 158,463 viajeros y el modelo se queda en 84,002; de hecho su máximo en los 63 meses es de 104,058, un 34 % por debajo del pico real. Y en el primer semestre de 2026 colapsa a 54,920 frente a 107,307 reales, un 48.8 % por debajo, justo el tramo más reciente y el de mayor interés operativo.




Figure 9: Trayectorias de la vía aérea sobre el test

El contraste con la serie total cierra la lectura. Allí el LSTM directo dibuja un perfil estacional con el nivel correcto y su correlación con el test es positiva, 0.249. Aquí el nivel es más preciso todavía, con un sesgo de -9.7% contra -16.0% , pero la forma se pierde. Las métricas agregadas premian a la vía aérea, con 24.93% de MAPE contra 33.76% , y sin embargo es el modelo de la serie total el que sigue mejor la dinámica de su serie.

Qué significa el resultado dado el diseño temporal del split

El split se heredó del Laboratorio 1 sin modificarlo, y esa decisión condiciona la lectura de todo lo anterior. El entrenamiento termina en marzo de 2021 y el test recorre la recuperación completa: la serie total pasa de 105,145 viajeros en el último mes de entrenamiento a una media de 276,685 en el horizonte, y la vía aérea de 60,160 a 94,605. La frontera cae en el peor punto posible: el modelo aprende con una serie cuyo tramo final es atípico respecto de todo lo que vendrá después.

Ese diseño explica el resultado en las dos direcciones. Explica por qué los modelos del Laboratorio 1 fallaron: SES, Holt-Winters, seasonal naive, SARIMA y Prophet anclan el pronóstico en las últimas observaciones o en la tendencia estimada sobre ellas, y las últimas observaciones eran pandemia. El informe anterior ya lo documentó al señalar que SES ganó seis de las siete series precisamente por no extrapolar, es decir, por equivocarse menos que los demás y no por acertar.

Y explica también por qué el LSTM directo gana. La red aprende un patrón sobre ventanas de 24 meses que en su mayoría provienen del periodo prepandemia, once años de los doce del entrenamiento, y al pronosticar reconstruye ese patrón en lugar de prolongar el nivel del último mes. Sobre un test que efectivamente vuelve a niveles prepandemia, esa forma de equivocarse resulta ser la correcta.

De ahí se sigue la reserva más importante de esta sección. La superioridad del LSTM medida aquí es real y está calculada de forma limpia, pero se apoya en una coincidencia favorable entre lo que el modelo aprendió y lo que ocurrió. Si la serie no se hubiera recuperado, o si el test hubiera cubierto un periodo de deterioro sostenido, la misma propiedad que hoy lo hace ganar habría producido una sobreestimación sistemática, y el ranking se habría invertido. Lo que estos 63 meses demuestran no es que una LSTM sea mejor que un SARIMA en general, sino que un modelo capaz de reconstruir el patrón histórico completo supera a uno anclado en el último nivel observado cuando el horizonte contiene una vuelta a ese patrón histórico.

La conclusión operativa para INGUAT es más modesta que el 56% y el 37% de mejora en el MAE. Un MAPE de 33.76% en la serie total sigue significando un error típico de un tercio del valor real, y el 24.93%

de la vía aérea, de una cuarta parte: sirven para dimensionar órdenes de magnitud y planificación agregada, no para asignación fina de capacidad sin intervalos de confianza ni reentrenamiento periódico. Y en vía aérea la cifra agregada es incluso más engañosa que en total, porque el mejor modelo se mueve al revés que la serie en el mes a mes y subestima a la mitad el tramo más reciente. La recomendación es reentrenar con datos posteriores a la recuperación en cuanto haya suficientes, porque ninguno de los modelos comparados aquí, de ninguna de las dos familias, tuvo forma de aprender el régimen que efectivamente rige las series desde 2023.

5. Caracterización de las series con catch22

El enunciado pide, además del modelado LSTM, explorar la similitud de las siete series construidas en el Laboratorio 1 con el algoritmo catch22. El desarrollo completo está en `notebooks/12_catch22_caracteristicas.ipynb`, que a diferencia de los cuadernos 09 y 10 no pronostica: describe y compara la dinámica de las siete series completas, de enero de 2009 a junio de 2026 (210 meses), sin respetar la partición de entrenamiento y prueba, porque no hay nada que pronosticar. Produce los `resultados/catch22_*.csv` y las figuras `catch22_*.png` que se citan en esta sección.

5.1 La idea detrás de catch22

Lubba et al. (2019) partieron de una versión filtrada de `hctsa`, 4,791 características de series de tiempo, y las evaluaron sobre 93 conjuntos de clasificación con más de 147,000 series. Descartaron las que no superan al azar, agruparon las restantes por la similitud de su desempeño entre conjuntos —dos características que aciertan y fallan en los mismos problemas son redundantes— y conservaron un representante por grupo. De 4,791 quedaron 22. La reducción cuesta en promedio 7 % de exactitud de clasificación y devuelve un factor cercano a 1,000 en tiempo de cómputo.

La importancia práctica para este laboratorio es que catch22 convierte una serie de longitud arbitraria en un vector de 22 valores interpretables y **invariante a escala y nivel**: pone en el mismo plano a la serie total, con una media de 248,990 viajeros mensuales, y a vía marítima, con 5,851, sin necesidad de normalizar cada indicador a mano como hizo el comparativo del Laboratorio 1. La limitación declarada es que catch22 se diseñó para benchmarks de clasificación y varias de sus 22 características necesitan series largas; las nuestras tienen 210 observaciones mensuales. La verificación del inciso 5.2 confirma que, aun así, ninguna de las 22 resultó constante entre las siete series.

5.2 Extracción, matriz y estandarización

Las características se calculan sobre la serie completa —no sobre el conjunto de entrenamiento—, con `pycatch22`, el binding oficial en C de los autores. La extracción devuelve 0 valores faltantes, confirma la invariancia de escala ($2 \cdot \text{serie} + 1000$ reproduce exactamente los mismos 22 valores) y no encuentra ninguna característica constante entre las siete series.

La matriz resultante tiene **7 filas (series) por 22 columnas (características)**, guardada en `resultados/catch22_caracteristicas.csv`. Sus columnas viven en escalas incomparables: la racha media más larga por encima del promedio (`SB_BinaryStats_mean_longstretch1`) va de 9 a 50 meses y el coeficiente de la matriz de transición (`SB_TransitionMatrix_3ac_sumdiagcov`) se mueve entre 0.006 y 0.111. Estandarizar con `StandardScaler` —ajustado sobre las siete series, con `ddof=0`, la misma convención usada para escalar las series antes de la LSTM— es indispensable antes de cualquier distancia, PCA o clustering; sin eso, dos o tres columnas decidirían el resultado. La matriz estandarizada queda en `resultados/catch22_estandarizado.csv`.

Con solo **siete observaciones**, ningún resultado de esta sección tiene respaldo inferencial convencional: no hay pruebas de hipótesis con poder razonable y una sola serie distinta cambiaría varias conclusiones. El análisis es descriptivo y cada afirmación se acompaña del número que la sostiene.

5.3 PCA, clustering, heatmap, correlaciones y distancias

Los cinco análisis que pide el inciso 2.5 del enunciado parten de la misma matriz 7×22 estandarizada.

PCA. Las dos primeras componentes explican el **63.4 %** de la varianza (39.2 % la primera, 24.3 % la segunda). PC1 es un eje de memoria y predictibilidad: en un extremo, series con error de pronóstico local alto, espectro concentrado en frecuencias altas y autocorrelación que se extingue rápido; en el otro, series con memoria larga y rachas prolongadas. PC2, en cambio, existe en buena medida para describir a una sola serie —Estados Unidos, con $PC2 = -5.22$ cuando ninguna otra pasa de 2.65—, un punto que retoma el inciso 5.6.




Figure 10: Varianza explicada y plano principal de las siete series

Clustering. El agrupamiento corre sobre las 22 características estandarizadas, no sobre las coordenadas del PCA, para no descartar el 36.6 % de varianza restante antes de medir la primera distancia. Con $k = 3$ (silueta media 0.163, el máximo entre $k = 2$ y $k = 5$) Ward produce {total, vía aérea, vía marítima}, {vía terrestre, El Salvador, Honduras} y {Estados Unidos} en solitario. K-means con el mismo k coincide solo parcialmente (Rand ajustado 0.444): mueve a total al grupo del trío terrestre y deja a vía aérea y vía marítima juntas. La coincidencia parcial entre algoritmos es la primera señal de que no los tres grupos son igual de sólidos, algo que el inciso 5.7 confirma con pruebas de estabilidad.




Figure 11: Dendrograma de Ward y silueta por número de grupos

Mapa de calor. Las 22 características, agrupadas por familia, contra las siete series, ordenadas según el dendrograma. Confirma visualmente los tres grupos y señala las celdas más extremas: Estados Unidos en las dos características de escalamiento de fluctuaciones y Honduras en la de la matriz de transición.

Correlaciones entre características. Calculada sobre la matriz estandarizada, aunque el resultado es idéntico al de la matriz cruda por la invariancia afín de Pearson. Con solo siete series, correlaciones altas entre características no contradicen el diseño de catch22 —sus autores minimizaron la redundancia por desempeño de clasificación sobre 93 conjuntos distintos, no por correlación lineal en siete series mensuales de turismo—, y significan solo que, para este conjunto en particular, aportan la misma información.




Figure 12: Matriz estandarizada, series ordenadas por el dendrograma




Figure 13: Correlación de Pearson entre las 22 características

Distancias entre series. La matriz euclidiana sobre las 22 características estandarizadas es la contraparte numérica del dendrograma: Ward decide qué fusionar primero con esta misma distancia. Sirve de base a los incisos 5.6 a 5.9.

Distancia euclidiana entre series, sobre las 22 características estandarizadas




Figure 14: Distancias euclidianas entre las siete series

5.4 ¿Cuáles series presentan comportamientos más similares?

El par más similar es vía terrestre y El Salvador, a 3.77, un 21 % por debajo del siguiente par más cercano (El Salvador–Honduras, 4.77). Las tres fuentes de evidencia coinciden: es la distancia mínima de los 21 pares, es la primera fusión del dendrograma (altura 3.766) y sobrevive tanto a Ward como a k-means, y las dos series quedan contiguas en el plano PC1-PC2. La explicación de dominio, ya documentada en el Laboratorio 1, es que El Salvador es el principal país de residencia que ingresa por vía terrestre —los pasos fronterizos de mayor tráfico del país son salvadoreños—, así que las dos series comparten calendario y respuesta a la pandemia casi por construcción. catch22 llega a la misma conclusión sin conocer geografía, solo la forma de las curvas.

La serie total queda a medio camino entre vía terrestre (5.02) y vía aérea (5.24), coherente con ser la suma de ambas: no se parece de forma particular a ninguna, lo que explica su silueta negativa (−0.102) y el desacuerdo entre Ward y k-means precisamente en su asignación.

5.5 ¿Qué características fueron las más importantes para diferenciar las series?

No hay una lista única, porque las características importan de tres maneras distintas.

Para el eje dominante (PC1, 39.2 % de varianza): FC_LocalSimple_mean3_stderr ($r = +0.958$, comunalidad 0.980, la característica más informativa del conjunto) y CO_flecac ($r = -0.910$) en extremos opuestos.

Para separar grupos: PD_PeriodicityWang_th0_01, con una razón F de **321**, dos órdenes de magnitud por encima de la siguiente y sin ninguna serie atípica inflándola —una separación genuina—. En unidades originales: periodo dominante de 11 meses en total, vía aérea y vía marítima, contra 3, 3 y 2 meses en vía terrestre, El Salvador y Honduras. El ciclo anual frente a ciclos sub-anales es lo que produce los grupos.

Para aislar una sola serie: las dos de escalamiento de fluctuaciones aíslan a Estados Unidos (brecha 1.92 y 1.87 sobre un máximo de 2.4), y son las que construyen PC2.

Las que no sirvieron: DN_HistogramMode_10 (comunalidad 0.026) y SB_BinaryStats_diff_longstretch0, casi constantes entre las siete series —esperable con solo siete series de un mismo país, no un fallo del método.




Figure 15: Contribución de cada característica: plano principal y separación de grupos

5.6 ¿Existen grupos naturales de series?

Sí, pero solo uno de los tres grupos de Ward merece llamarse natural. Cuatro pruebas —cohesión interna, saltos en las alturas de fusión, estabilidad ante la remoción de una serie y perfil de características— coinciden en distinguir un trío cohesionado, dos series aisladas y un residuo.

El grupo natural es vía terrestre, El Salvador y Honduras: distancia interna de 4.90 contra 7.35 hacia afuera, silueta media +0.316 (la más alta), idéntico en Ward y k-means, estable con $k = 3$ y $k = 4$. Su perfil combina periodo dominante corto (z medio -1.00), potencia concentrada en frecuencias bajas ($+0.95$) y el menor error de pronóstico local del conjunto (-0.94): series dominadas por tendencia y nivel, muy predecibles, sin que el calendario turístico anual sea su rasgo dominante. Es, en la lectura de dominio, el tráfico fronterizo terrestre centroamericano.

El grupo total/vía aérea/vía marítima no es natural: es un residuo. Su cohesión interna es apenas 11 % mayor que su distancia hacia afuera (6.71 contra 7.55), contra el 33 % del trío, y contiene la única silueta negativa. Lo único que comparten es el rasgo opuesto al trío: ciclo anual dominante (z medio $+1.13$ en PD_PeriodicityWang_th0_01).

Las alturas de fusión sugieren cuatro grupos, no tres: el salto mayor del dendrograma (2.088) ocurre al pasar de 4 a 3, cuando se fusiona vía marítima con total y vía aérea. Con $k = 4$ la partición es {trío

terrestre}, {total, vía aérea}, {vía marítima} y {Estados Unidos}, más fiel al resto de la evidencia. La silueta prefirió $k = 3$ por una diferencia de 0.0019, sin contenido con siete observaciones.

La prueba de estabilidad —quitar una serie y reagrupar las seis restantes— es la más honesta. Sin cualquier serie ajena al trío, la partición sobrevive intacta (Rand ajustado +1.000). Sin El Salvador cae a +0.118: es el vecino más cercano de los otros dos y sin él el trío se desarma. El grupo es real *dado este conjunto de siete series* y depende de un miembro central, no de una estructura que sobreviva a cualquier recomposición de la muestra. En las tres reorganizaciones donde la partición se rompe, vía marítima queda sola las tres veces: su aislamiento es más robusto que cualquiera de los grupos.

5.7 ¿Las series de una misma categoría tienden a agruparse?

No. Con solo siete series repartidas en tres categorías (una de referencia, tres vías de ingreso, tres países de residencia), la distribución nula puede enumerarse por completo: 140 asignaciones posibles, lo que permite un valor p **exacto** en lugar de aproximado —la única inferencia legítima de toda esta sección.

Evidencia	Valor	Lectura
Distancia media dentro de categoría	7.003	Prácticamente idéntica a la general (7.015)
p exacto de permutación	0.486	Casi la mitad de las 140 asignaciones al azar agrupan igual o mejor
Rand ajustado categoría / grupo de Ward	0.067	Coincidencia nula

Vía de ingreso es incluso peor que el azar: sus tres pares internos promedian 7.398, por encima de la media general. País de residencia queda apenas por debajo (6.609) solo porque une a El Salvador y Honduras (4.77) sin lograr acercarse a Estados Unidos (6.78 y 8.28 de ellos).

Lo que sí organiza el espacio es el **régimen de viaje**, que cruza las categorías administrativas: el par más parecido de todo el conjunto (vía terrestre–El Salvador) une categorías distintas, y los tres pares más lejanos también las cruzan. Un modelo o una política diseñada “para las vías de ingreso” como bloque estaría juntando series con dinámicas incompatibles, mientras que vía terrestre, El Salvador y Honduras —hoy reportadas por separado— admitirían un tratamiento común.

5.8 ¿Qué series presentan el comportamiento más atípico?

Dos series son atípicas por razones distintas, y el resultado no depende del indicador: vía marítima ocupa el primer lugar en los cinco criterios calculados (norma z , distancia media, distancia al vecino, celdas extremas, silueta) y Estados Unidos el segundo en los cinco.

Vía marítima es atípica en todos los sentidos a la vez. Distancia media de 8.41 contra un promedio general de 6.92, cuatro características con $|z| > 2$. Es tráfico de cruceros: pasa 27 de sus 210 meses en cero, con coeficiente de variación de 1.147, más del doble que cualquier otra serie. Un centroide espectral casi tres veces más alto que el resto y la dependencia de retardo 2 más débil del conjunto describen una serie con menos memoria y menos estructura temporal aprovechable: eventos discretos, no un flujo continuo. Es también la serie que el Laboratorio 1 excluyó del modelado LSTM porque sus meses en cero rompían $\log 1p$.

Estados Unidos es atípica en una sola dimensión, pero radicalmente. Solo dos características superan $|z| > 2$, contra las cuatro de vía marítima, pero pertenecen a la misma familia y la separación es de régimen, no de grado: sus dos características de escalamiento de fluctuaciones caen a un quinto del valor de las otras seis (0.143–0.167 contra 0.738–0.857). Esa singularidad es la que explica que PC2 (24.3 % de la varianza total) exista casi enteramente para describirla. Es también la única serie que forma un grupo unipersonal en Ward y en k -means, y en el Laboratorio 1 fue de las más difíciles de modelar: 24 de sus 36 especificaciones SARIMA se descartaron por trayectorias explosivas.

Dos series parecen atípicas y no lo son. Honduras tiene la celda más extrema del mapa de calor, pero su vecino está a 4.77 (el segundo más cercano del conjunto) y pertenece con claridad al grupo natural del inciso 5.6: un rasgo extremo, no un comportamiento aislado. La serie total tiene la silueta más negativa (-0.102) pero su norma (3.90) está por debajo del promedio y su distancia media es la quinta de siete: está en el centro, no afuera; su silueta negativa refleja que, siendo la suma de las demás, queda equidistante entre los grupos y ninguno la reclama. En el otro extremo, vía terrestre es la serie más típica del conjunto: la menor norma, la menor distancia media y ninguna característica con $|z| > 2$.

5.9 Comparación con el análisis exploratorio del Laboratorio 1

La pregunta es si los agrupamientos de catch22 son consistentes con la tendencia, la estacionalidad, la volatilidad, el impacto de la pandemia y las funciones de autocorrelación que el Laboratorio 1 ya había medido a mano. La respuesta es **parcial y desigual entre las cinco dimensiones**, no un sí o un no único.

Serie	Grupo Ward	ft (tendencia)	fs (estacional)	cv_2009_2019 (volatilidad)	caida_pct (pandemia)	CO_f1ecac (ACF)
Total	1	0.505	0.189	0.335	97.50 %	8.58
Vía aérea	1	0.241	0.142	0.216	99.60 %	6.44
Vía marítima	1	0.690	0.405	0.790	100.00 %	2.77
Vía terrestre	2	0.653	0.169	0.431	97.77 %	9.00
El Salvador	2	0.185	0.105	0.453	100.00 %	13.87
Honduras	2	0.116	0.119	0.335	100.00 %	18.93
Estados Unidos	3	0.107	0.109	0.300	100.00 %	9.22

El impacto de la pandemia no discrimina nada. caida_pct va de 97.50 % a 100.00 %, un rango de 2.50 puntos entre las siete series: no puede explicar por qué Ward separa tres grupos. Es coherente con la invariancia de escala de catch22 (sección 5.2): dos series con caídas de 97.5 % y 100 % son indistinguibles para el algoritmo, aunque una haya llegado literalmente a cero.

La tendencia tampoco se alinea. Dentro del grupo 2, ft va de 0.116 a 0.653, un rango tan amplio como el de todo el conjunto.

La estacionalidad, la volatilidad y la autocorrelación sí se alinean, pero solo en el grupo 2. Sus tres miembros comparten fs bajo y compacto (0.105–0.169), cv_2009_2019 compacto (0.335–0.453) y CO_f1ecac uniformemente lento (9.0–18.9, ninguno por debajo de nueve meses): memoria larga, estacionalidad discreta, volatilidad moderada. Es el mismo trío que la sección 5.6 ya había identificado como el grupo más cohesionado (distancias internas de 3.77 a 4.77, contra 5.02 a 7.07 del grupo 1).

El grupo 1 es la evidencia de que Ward con $k = 3$ obliga a un residuo. Total, vía aérea y vía marítima no comparten decaimiento de autocorrelación (2.77 a 8.58), ni fs (0.142–0.405), ni cv_2009_2019 (0.216–0.790, dominado por vía marítima). Las distancias al vecino más cercano dentro del grupo confirman una cohesión mucho más débil que la del grupo 2, exactamente lo que la sección 5.6 ya había advertido sobre vía marítima como miembro forzado.

En conjunto: **los agrupamientos de catch22 son consistentes con la estacionalidad, la volatilidad y la autocorrelación del grupo terrestre-El Salvador-Honduras, ciegos al impacto de la pandemia por diseño, y no capturan la fuerza de tendencia en ningún grupo.**

5.10 Tres descubrimientos que el análisis exploratorio tradicional no había mostrado

1. Estados Unidos es indistinguible en el EDA tradicional y radicalmente atípica en catch22. Sus indicadores clásicos —`ft` = 0.107, `fs` = 0.109, `cv_2009_2019` = 0.300— están los tres en el rango medio de las siete series, sin nada que la señale. `catch22` mostró lo contrario: un cambio de régimen, no de grado, en sus características de escalamiento de fluctuaciones, algo que el comparativo del Laboratorio 1 no tenía forma de detectar porque mide dispersión y tendencia, no la estructura de las fluctuaciones a distintas escalas temporales.

2. Vía marítima no es solo “una serie con muchos ceros”: es un proceso de eventos discretos. El diagnóstico del Laboratorio 1 la había señalado por sus 27 meses en cero y la excluyó del modelado LSTM por eso. `catch22` explica *por qué* tiene esa forma: centroide espectral casi tres veces más alto que el resto y la dependencia de retardo 2 más débil del conjunto son la firma de tráfico de cruceros —eventos puntuales, no un flujo continuo— y no una simple anomalía de conteo.

3. El impacto de la pandemia, la variable más dramática del análisis exploratorio, resultó invisible para catch22. `caida_pct` varía menos de tres puntos entre las siete series y no separa ningún grupo (sección 5.9). No es un fallo del método; es la consecuencia directa de la invariancia de escala, que el análisis exploratorio tradicional no tenía —cada serie del Laboratorio 1 se leyó con su propio eje— y que aquí queda demostrada con números: `catch22` compara *forma*, no *profundidad del choque*.

5.11 Un LSTM con características catch22 de ventana móvil

Los incisos anteriores usan `catch22` sobre siete series completas —un vector de 22 valores por serie—, insuficiente para entrenar una LSTM. Aquí `catch22` se recalcula por **ventana móvil**: para cada ventana de 24 meses que ve la LSTM de la serie `total`, se extraen sus 22 características y se agregan como canales adicionales de entrada, junto al valor escalado, repetidas en los 24 pasos de tiempo porque describen la ventana completa.

El protocolo es idéntico al del modelo ganador de la sección 2 salvo por los canales de entrada: ventana de 24 meses, dos capas LSTM de 64 unidades, sin dropout, estrategia directa (`Dense(63)`), tuneo de épocas por paro anticipado sobre una validación del 15 % y reentrenamiento final sobre las 61 ventanas completas por ese número de épocas —exactamente el procedimiento de `ajustar_final`—. Las 22 características se calculan sobre los mismos 24 meses de contexto, nunca sobre el futuro, y se estandarizan con un `StandardScaler` ajustado solo con las ventanas de entrenamiento.

Modelo	Canales	Épocas	Parámetros	MAE	RMSE	MAPE
LSTM directo (base)	1	42	54,015	76,957	100,290	33.76 %
LSTM directo + catch22	23	37	59,647	216,932	239,228	78.56 %

Agregar `catch22` como canales de entrada empeoró el pronóstico, y de forma sustancial. El modelo base reproduce exactamente la métrica publicada en la sección 2 (33.76 % de MAPE), confirmando que la comparación es limpia. El modelo con los 23 canales llega a 78.56 %, más del doble de error. El resultado es reproducible: dos corridas con la misma semilla dan exactamente los mismos números en ambos modelos.

La causa más probable es el tamaño de muestra, no la arquitectura. Ambos modelos tienen un número de parámetros similar (incremento de solo 10 %), pero el volumen de entrada por ventana pasa de 24 valores a 552 (24 pasos × 23 canales) sin agregar una sola observación nueva a las 61 ventanas de entrenamiento que la sección 2 ya había señalado como pequeñas, con sobreajuste desde la época doce en




Figure 16: Serie total: LSTM base vs. LSTM con canales catch22 de ventana móvil

el modelo base. Multiplicar por 23 el número de valores de entrada agrava exactamente ese problema: el paro anticipado se activó antes en el modelo con catch22 (37 épocas contra 42), consistente con una red que encuentra un mínimo de validación más rápido pero que generaliza peor.

Las 22 características no aportan información temporal nueva dentro de la ventana. Se calculan sobre los mismos 24 valores que ya recibe el canal base y se repiten idénticas en los 24 pasos de tiempo: no describen algo que ocurra *dentro* de la ventana en un momento distinto, sino un resumen constante de la ventana completa. Una LSTM con acceso a los 24 valores crudos ya puede, en principio, aprender cualquier función de ellos, incluida su propia estadística resumida; los canales catch22 no añaden grados de libertad a lo que el modelo puede representar, y sí diluyen la señal, porque 22 de 23 canales llevan la misma constante en cada paso de tiempo y desplazan parte de la capacidad de la primera capa LSTM hacia pesos que multiplican una descripción redundante en lugar de aprender la dinámica secuencial.

Conclusión. Para la serie *total*, con 61 ventanas de entrenamiento, agregar características catch22 de ventana móvil no mejora el mejor LSTM del laboratorio: lo empeora, y la explicación más defendible es el tamaño de muestra, no la utilidad de catch22 como descriptor. El resultado es coherente con el uso que sí funcionó en las secciones 5.1 a 5.10: catch22 aporta valor para **comparar series entre sí** con pocas observaciones por serie y muchas series (7 filas, 22 columnas), no para alimentar directamente un modelo secuencial que ya tiene acceso a la serie cruda y muy pocas ventanas de entrenamiento.